

الله
بِسْمِ اللّٰهِ الرَّحْمٰنِ الرَّحِيْمِ
اللّٰهُمَّ اهْدِنَا
شَرِّ هَذِهِ الْأَرْضِ
شَرِّ مَنْ أَنْتَ لَنَا
شَرِّ مَا كَانَ
شَرِّ مَا يَعْلَمُ
شَرِّ مَا يَخْفَى



دانشگاه خوارزمی

دانشگاه خوارزمی

دانشکده فنی و مهندسی

پایان نامه کارشناسی ارشد رشته علوم کامپیوتر گرایش داده کاوی

عنوان

تشخیص اختلال شناختی خفیف با استفاده از شبکه های عصبی گراف برپایه داده های طیف نگاری کارکردی مادون قرمز نزدیک

نگارش

محمد صادق فتحی اوزنبلغ

استاد راهنما

دکتر میرمحسن پدرام

استاد مشاور

دکتر مریم طایفه محمودی

شهریور ۱۴۰۳

ب

تعهدنامه اصالت رساله / پایان نامه

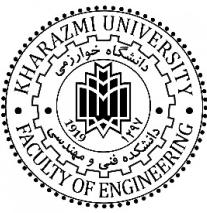
اینجانب محمد صادق فتحی اوزنبلاغ دانشجوی مقطع کارشناسی ارشد رشته علوم کامپیوتر گرایش داده کاوی که در تاریخ ۱۴۰۳/۰۶/۲۸ از رساله/ پایان نامه خود تحت عنوان : تشخیص اختلال شناختی خفیف با استفاده از شبکه های عصبی گراف برپایه داده های طیف نگاری کار کردی مادون قمز نزدیک

و با کسب نمره ۱۹ و درجه عالی دفاع نمودم، بدینوسیله متعهد می شوم:

- این رساله/ پایان نامه حاصل از تحقیق و پژوهش انجام شده توسط اینجانب بوده و در مواردی که از دستاوردهای علمی و پژوهشی دیگران (اعم از پایان نامه، کتاب، مقاله و نظایر آن) استفاده نمایم کاملا رعایت امانت کرده ، مطابق مقررات ارجاع و در فهرست منابع و مأخذ اقدام به ذکر آنها کنم .
- مقالات مستخرج از این رساله/ پایان نامه کاملا حاصل کار اینجانب باشد و از هر گونه جعل داده و یا تغییر اطلاعات پرهیز نمایم .
- کلیه حقوق مادی و معنوی حاصل از این رساله/ پایان نامه متعلق به دانشگاه خوارزمی بوده و متعهد می شوم در زمان هر گونه بهره مندی و یا نشر دستاوردهای حاصل از این تحقیق اعم از چاپ کتاب ، مقاله ، ثبت اختراع و غیره (چه در زمان دانشجویی و یا بعد از فراغت از تحصیل) ضمن کسب اجازه از تیم استادان راهنمای و مشاور، از حوزه معاونت پژوهشی دانشگاه مجوز لازم را اخذ و در کلیه انتشارات خود نام دانشگاه و استاد راهنمایم را درج کنم .
- تمامی یا بخشی از این رساله/ پایان نامه قبلاً برای دریافت هیچ گونه مدرک تحصیلی (هم سطح، پایین تر یا بالاتر) در سایر دانشگاهها و مؤسسات آموزش عالی ارائه نشده است . در صورتی که اثبات شود که این رساله به شخص دیگری تعلق داشته است، دانشگاه می تواند مدرک تحصیلی اینجانب را ابطال نماید. در آن صورت اینجانب اقدام دانشگاه را می پذیرم و حق هر گونه اعتراضی را از خود سلب می کنم.

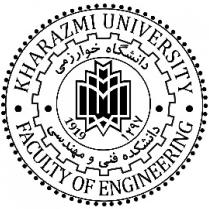
امضاء

نام و نام خانوادگی: محمد صادق فتحی اوزنبلاغ



فرم مشخصات دفاع دانشجو

ردیف	موضوع	شرح
۱	نام و نام خانوادگی داشجو	محمدصادق فتحی اوزنبلاغ
۲	شماره داشجویی	۴۰۰۳۱۱۵۶۰۵
۳	رشته - گرایش تحصیلی	علوم کامپیوتر - داده کاوی
۴	مقطع دانشجو	کارشناسی ارشد
۵	نوع دفاع	<input checked="" type="checkbox"/> پایان نامه ارشد <input type="checkbox"/> پروپوزال دکتری <input type="checkbox"/> پیش دفاع دکتری <input type="checkbox"/> رساله دکتری
۶	عنوان پایان نامه	تشخیص اختلال شناختی خفیف با استفاده از شبکه های عصبی گراف برای داده های طیف نگاری کار کرده مادون قرمز نزدیک
۷	تاریخ تصویب پیشنهادیه (پروپوزال) پایان نامه	۱۴۰۲/۰۴/۲۷
۸	نام استاد راهنمای (یا استاد راهنمای اول)	آقای دکتر میرمحسن پدرام
۹	نام استاد راهنمای دوم (در صورت وجود)	
۱۰	نام استاد مشاور (در صورت وجود)	خانم دکتر مریم طایفه محمودی
۱۱	نام استاد داور داخلی اول	
۱۲	نام استاد داور داخلی دوم	
۱۳	نام استاد ممتحن خارجی (پیشنهادی)	
۱۴	مرتبه علمی ممتحن خارجی	آقای دکتر سعید ستایشی
۱۵	محل کار ممتحن خارجی	دانشگاه صنعتی امیرکبیر
۱۶	تاریخ برگزاری جلسه دفاع	۱۴۰۳/۰۶/۲۸
۱۷	ساعت برگزاری جلسه دفاع	۱۵ تا ۱۴
۱۸	سالن و محل برگزاری جلسه دفاع	دانشکده فنی و مهندسی - کرج
۱۹	نماينده تحصيلات تكميلي	آقای دکتر منوچهر کلاستاني
۲۰	چکیده: اختلال شناختی خفیف به زوال جزئی حافظه یا تفکر، بدون تاثیر بر توانایی زندگی مستقل و انجام بیشتر وظایف اطلاق می شود. در اختلال شناختی خفیف، خود فرد یا نزدیکان او متوجه ایجاد تعییراتی در نحوه تفکر یا به خاطر سپردن موارد می شوند. اختلال شناختی خفیف، علائم اولیه اختلال شناختی شدید یا بیماری آلزایمر را نشان می دهد و با افزایش سن مرتبط است. در همین حال، تشخیص زودهنگام اختلال شناختی خفیف می تواند مانع از پیشرفت بیماری آلزایمر شود. هنگام کار با افرادی که دارای اختلالات شناختی هستند، ابزارهای ارزیابی شناختی کمی برای تشخیص عملکرد پایه، اختلال شناختی خفیف و بیماری آلزایمر وجود دارد. از آنجا که این بیماری ها پیشرونده هستند، تشخیص زودهنگام اختلال شناختی خفیف برای مدیریت بیماری و انتخاب روش های درمانی که می تواند پیشرفت بیماری آلزایمر را به تأخیر بیندازد، ضروری است. در حالی که برخی از معیارهای رفتاری موجود است، ابزارهایی نیز برای بررسی و تشخیص اختلال شناختی خفیف و دیگر اختلال های شناختی وجود دارد، این مجموعه از ابزارها و روش ها باید کسترش یابند. یکی از ابزارهای بررسی و تشخیص اختلال های شناختی طیف نگاری کار کرده مادون قرمز نزدیک است. این مطالعه روشی مبتنی بر یادگیری عمیق گرافی را پیشنهاد می دهد. این مطالعه هدف دارد تا با تحلیل داده های حالت استراحت که با استفاده از داده های طیف سنجی نزدیک به مادون قرمز عملکردی ضبط شده، بین افراد سالم تمایز قائل شود. شبکه های عصبی گراف زمانی برای درک وابستگی های پیچیده زمانی و الگوهای ساختاری در داده های مغزی ضبط شده به کار گرفته شدند. تحقیقات بیشتری باید برای بررسی نواحی دیگر مغز انجام شود تا بینش بهتری از مکانیزم های عملکردی مغز در اختلال شناختی خفیف و بیماری آلزایمر به دست آید تا ابزارهای ارزیابی مفید تری تعیین شود. داده های fNIRS حالت استراحت از هر دو گروه دارای MCI و افراد سالم جمع آوری شدند. داده های حالت استراحت بطور ویژه ارزشمند هستند زیرا فعالیت ذاتی مغز را بدون مجرک های خارجی منعکس می کنند و یک پایه برای عملکرد فراهم می کنند. از طرف دیگر، گاهی اوقات انجام وظیفه طراحی شده برای تشخیص بیماری، برای بیماران سخت و اذیت کننده است. داده های ظبط شده هنگام استراحت می توانند تفاوت های ظرفی در الگوهای اتصال و فعل سازی را که ممکن است در ارزیابی های مبتنی بر وظیفه آشکار نباشد، نشان دهد. گراف های زمانی از داده های ظبط شده fNIRS ساخته شدند تا تعاملات پویا و الگوهای اتصال نواحی مختلف را در طول زمان مدل سازی کنند. شبکه گرافی پیشنهادی بر اساس این گراف های زمانی ساخته شده، شرکت کنندگان را طبقه بندی کردند. نتایج نشان می دهد که شبکه های گرافی زمانی به طور موثری بین افراد دارای اختلال شناختی خفیف و افراد سالم تمایز قابل می شود و الگوهای فعل سازی و اتصال نواحی متمایز را نشان می دهد. استفاده از رویکردهایی همچون اعتبار سنجی مقابله بندی شده ۵ لایه ای، عمومیت پذیری مدل را تأیید می کند. نتایج حاصل شده، نشان دهنده اثربخشی رویکرد پیشنهادی است و بهترین نتیجه از مدل GconvGRU که عملکرد بسیار خوبی را نشان می دهد	



و به صحت (۹۲.۶۷٪)، دقت (۹۵.۰۰٪)، امتیاز F1 (۹۳.۱۴٪)، فراخوانی (۹۳.۳۳٪) دست یافته است، بدست آمده است. این یافته‌ها یک معیار دقیق برای تشخیص اختلال شناختی غیرتھاجمی و مبتنی بر هوش مصنوعی ایجاد کرده که از دقت مدل‌های مشابه و رویکردهای پیشین تا حدودی پیشی می‌گیرد. این مطالعه پتانسیل تحلیل مبتنی بر گراف زمانی از داده‌های fNIRS حالت استراحت را در تمایز بین افراد مبتلا به اختلال شناختی خفیف و افراد سالم نشان می‌دهد و به تشخیص زودهنگام و نظارت بر بیماران دارای اختلال شناختی خفیف کمک می‌کند.

تقدیم به روح پاک مادربزرگ عزیزم که خوشروی را به من آموخت.

با سپاس فراوان از استاد گرانقدر، جناب آقای دکتر میرمحسن پدرام که همواره با راهنمایی‌های خود
مرا در این امر یاری فرمودند. همچنین، از استاد مشاورم، سرکار خانم دکتر میرطایفه محمودی، که زحمت
مشاوره این پایان‌نامه را بر عهده گرفتند، صمیمانه تشکر می‌نمایم.

چکیده:

اختلال شناختی خفیف^۱ به زوال جزئی حافظه یا تفکر، بدون تاثیر بر توانایی زندگی مستقل و انجام بیشتر وظایف اطلاق می‌شود. در اختلال شناختی خفیف، خود فرد یا نزدیکان او متوجه ایجاد تغییراتی در نحوه تفکر یا به خاطر سپردن موارد می‌شوند. اختلال شناختی خفیف، علائم اولیه اختلال شناختی شدید یا بیماری آلزایمر^۲ را نشان می‌دهد و با افزایش سن مرتبط است. در همین حال، تشخیص زودهنگام اختلال شناختی خفیف می‌تواند مانع از پیشرفت بیماری آلزایمر شود. هنگام کار با افرادی که دارای اختلالات شناختی هستند، ابزارهای ارزیابی شناختی کمی برای تشخیص عملکرد پایه، اختلال شناختی خفیف و بیماری آلزایمر وجود دارد. از آنجا که این بیماری‌ها پیشرونده هستند، تشخیص زودهنگام اختلال شناختی خفیف برای مدیریت بیماری و انتخاب روش‌های درمانی که می‌تواند پیشرفت بیماری آلزایمر را به تأخیر بیندازد، ضروری است. در حالی که برخی از معیارهای رفتاری موجود است، ابزارهایی نیز برای بررسی و تشخیص اختلال شناختی خفیف و دیگر اختلال‌های شناختی وجود دارد، این مجموعه از ابزارها و روش‌ها باید گسترش یابند. یکی از ابزارهای بررسی و تشخیص اختلال‌های شناختی طیف نگاری کارکردی مادون قرمز نزدیک^۳ است. این مطالعه روشی مبتنی بر یادگیری عمیق گرافی^۴ را پیشنهاد می‌دهد. این مطالعه هدف دارد تا با تحلیل داده‌های حالت استراحت که با استفاده از داده‌های طیفسنجی نزدیک به مادون قرمز عملکردی ضبط شده، بین افراد مبتلا به MCI و افراد سالم تمایز قائل شود. شبکه‌های عصبی گراف زمانی برای درک وابستگی‌های پیچیده زمانی و الگوهای ساختاری در داده‌های مغزی ضبط شده به کار گرفته شدند. تحقیقات پیشتری باید برای بررسی نواحی دیگر مغز انجام شود تا بینش بهتری از مکانیزم‌های عملکردی مغز در اختلال شناختی خفیف و بیماری آلزایمر به دست آید تا ابزارهای ارزیابی مفیدتری تعیین شود. داده‌های fNIRS حالت استراحت از هر دو گروه دارای MCI و افراد سالم جمع‌آوری شدند. داده‌های حالت استراحت بطور ویژه ارزشمند هستند زیرا فعالیت ذاتی مغز را بدون محرك‌های خارجی منعکس می‌کنند و یک پایه برای عملکرد فراهم می‌کنند. از طرف دیگر، گاهی اوقات انجام وظیفه طراحی شده برای تشخیص بیماری، برای بیماران سخت و اذیت‌کننده است. داده‌های ظبط شده هنگام استراحت می‌تواند تفاوت‌های ظریف در الگوهای اتصال و فعال‌سازی را که ممکن است در ارزیابی‌های مبتنی بر وظیفه آشکار نباشد، نشان دهد. گراف‌های زمانی از داده‌های ظبط شده fNIRS ساخته شدند تا تعاملات پویا و الگوهای اتصال نواحی مختلف را در طول زمان مدل‌سازی کنند. شبکه‌گرافی پیشنهادی بر اساس این گراف‌های زمانی ساخته شده، شرکت‌کنندگان را طبقه‌بندی کردند. نتایج نشان می‌دهد که شبکه‌های گرافی زمانی به طور موثری بین افراد دارای اختلال شناختی خفیف و افراد سالم تمایز قائل می‌شود و الگوهای فعال‌سازی و اتصال نواحی تمایز را نشان می‌دهد. استفاده از رویکردهایی همچون اعتبارسنجی متقلب طبقه‌بندی شده^۵ ای، عمومیت‌پذیری مدل را تأیید می‌کند. نتایج حاصل شده، نشان‌دهنده اثربخشی رویکرد پیشنهادی است و بهترین نتیجه از مدل GconvGRU که عملکرد بسیار خوبی را نشان می‌دهد و به صحت (۹۲.۶۷٪)، دقت (۹۵.۰۰٪)، امتیاز F1 (۹۳.۱۴٪)، فراخوانی (۹۳.۳۳٪) دست یافته است، بدست آمده است. این یافته‌ها یک معیار دقیق برای تشخیص اختلال شناختی غیرتھاجمی و مبتنی بر هوش مصنوعی ایجاد کرده که از دقت مدل‌های مشابه و رویکردهای پیشین تا حدودی پیشی

¹ Mild Cognitive Impairment (MCI)

² Alzheimer's Disease (AD)

³ Functional near-infrared spectroscopy (fNIRS)

⁴ Graph Deep-Learning

می‌گیرد. این مطالعه پتانسیل تحلیل مبتنی بر گراف زمانی از داده‌های fNIRS حالت استراحت را در تمایز بین افراد مبتلا به اختلال شناختی خفیف و افراد سالم نشان می‌دهد و به تشخیص زودهنگام و نظارت بر بیماران دارای اختلال شناختی خفیف کمک می‌کند.

کلید واژه‌ها

اختلال شناختی خفیف، MCI، طیف نگاری کارکردی مادون قرمز نزدیک، fNIRS، مدل‌های یادگیری ماشین شبکه‌های عصبی گراف‌زمانی، GTNN، داده حالت استراحت، Rest

فهرست مطالب

۵	چکیده:
۱۱	فصل ۱: کلیات پژوهش و مسائل
۱۲	۱-۱- مقدمه
۱۲	۱-۲- اختلال شناختی خفیف (MCI)
۱۳	۱-۳- تغییرات نوروفیزیولوژیک در MCI
۱۴	۱-۴- روش‌های تشخیص اختلال شناختی خفیف
۱۵	۱-۴-۱- روش‌های بالینی
۱۵	۱-۴-۲- روش‌های مبتنی بر یادگیری ماشین
۱۶	۱-۵- چالش‌های تشخیص اختلال شناختی خفیف
۱۷	۱-۵-۱- ماهیت طریق و ناهمگون اختلال شناختی خفیف
۱۷	۱-۵-۲- تغییرپذیری در حساسیت آزمون شناختی
۱۸	۱-۵-۳- تکیه بر قضاوت بالینی و ارزیابی‌های ذهنی
۱۸	۱-۵-۴- درمان اختلال شناختی خفیف
۱۹	۱-۶-۱- مداخله دارویی
۱۹	۱-۶-۲- ایده حفظ
۱۹	۱-۶-۳- ورزش بدنی
۲۰	۱-۶-۴- الگوهای غذايی
۲۰	۱-۶-۵- آموزش روانی اجتماعی
۲۰	۱-۶-۶- بیان مسئله
۲۱	۱-۶-۷- ساختار پایان‌نامه
۲۴	فصل ۲: بررسی پیشینه و ادبیات پژوهش
۲۵	۲-۱- مقدمه
۲۵	۲-۲- طیف‌نگاری کارکردی فروسرخ نزدیک fNIRS
۳۰	۲-۲-۱- مزایا و معایب fNIRS
۳۳	۲-۲-۲- fNIRS در علوم اعصاب شناختی
۳۵	۲-۲-۳- استفاده از fNIRS در تحقیقات MCI
۳۶	۲-۲-۴- ضبط در حالت استراحت
۳۷	۲-۲-۵- شبکه‌های عصبی گرافی
۴۱	۲-۲-۶- GNN های زمانی
۴۲	۲-۲-۷- گراف زمانی گستته
۴۳	۲-۲-۸- گراف زمانی پوسته
۴۴	۲-۲-۹- کاربرد GNN در علوم اعصاب
۴۶	فصل ۳: مقدمات پژوهش
۴۷	۳-۱- مقدمه
۴۷	۳-۲- جمع آوری داده‌ها
۴۸	۳-۲-۱- اطلاعات جمعیت شناختی
۴۸	۳-۲-۲- اندازه گیری fNIRS
۴۹	۳-۲-۳- پیش پردازش داده‌ها
۴۹	۳-۳-۱- پاکسازی اولیه داده‌ها
۵۱	۳-۳-۲- حذف مصنوعات حرکتی
۵۴	۳-۳-۳- فیلتر کردن
۵۶	۳-۳-۴- نرمال سازی
۵۸	۳-۳-۵- روش پیش پردازش مقاله پایه

۵۸	۴-۳- ویژگی های بررسی شده
۶۱	۴-۳-۱- انتخاب ویژگی ها
۶۵	۴-۳-۲- ساخت گراف
۶۸	۴-۳-۳- معیارهای ارزیابی سیگنال
۶۹	۴-۳-۴- معیارهای ارزیابی
۶۹	۴-۷-۱- دقت
۷۰	۴-۷-۲- فراخوانی
۷۰	۴-۷-۳- امتیاز F1
۷۰	۴-۷-۴- صحت
۷۱	۴-۷-۵- روش اعتبارسنجی متقابل

فصل ٤: مدل پیشنهادی

۷۴	۱-۴ مقدمه.....
۷۴	۲-۴ طراحی مدل: شبکه‌های عصبی گراف زمانی
۷۵	۱-۲-۴ معماری fNIRS برای داده‌های TGNN
۷۷	۲-۲-۴ جزئیات پیاده سازی
۸۱	۳-۴ مقایسه پیش پردازش داده ها
۸۱	۱-۳-۴ نتایج ارزبایی سیگنال
۸۳	۲-۳-۴ نتایج آزمون تجزیه و تحلیل آماری
۸۶	۴-۴ ارزبایی نتایج
۸۷	۱-۴-۴ مقایسه پیش پردازش پیشنهادی در شرایط یکسان
۸۸	۲-۴-۴ مقایسه با نتایج مقاله پایه
۹۱	۴-۵ تحلیل نتایج و جم بندی

فصل ۵: جمع‌بندی و پیشنهادها

۹۹	-۱- مقدمه
۱۰۰	-۲- نوآوری
۱۰۰	-۳- محدودیت‌ها
۱۰۱	-۴- شنیدادها

فصل ٦: مراجعة

مراجع

فہرست اشکاں

۲۶ شکل (۱-۲) ضریب جذب H ₂ O,Hb,HbO ₂ در طول موج های متفاوت
۲۸ شکل (۲-۲) مسیری که توسط فوتون های NIR از منبع نور به آشکارساز از طریق لایه های مختلف سر دنبال می شود [61].
۲۹ شکل (۳-۲) دستگاه های موج پیوسته تضعیف نور ناشی از پراکندگی و جذب را بر اساس اندازه گیری شدت نور ورودی (I _{in}) و خروجی (I _{out}) اندازه گیری می کنند [61].
۳۲ شکل (۴-۲) fNIRS در مقایسه با سایر روش ها [66].
۳۸ شکل (۵-۲) کانولوشن دوبعدی در مقابل کانولوشن گرافی.
۳۹ شکل (۶-۲) مثالی از جاسازی کردن گره [109].
۴۰ شکل (۷-۲) معماری یک مدل با استفاده از دو لایه GCN [111].
۴۲ شکل (۸-۲) سه تصویر لحظه ای از یک DTDG [119].
۴۸ شکل (۱-۳) نحوه چیش ساطع کنندها، آشکارسازها و کانالها
۵۳ شکل (۲-۳) اعمال TDDR روی داده های fNIRS

۵۷ شکل (۳-۳) مقایسه دو روش نرمال‌سازی.....
۶۴ شکل (۴-۳) وزن‌های داده شده به ویژگی‌های عملکردی با استفاده از XGBoost
۶۵ شکل (۵-۳) مقایسه و انتخاب ویژگی‌های سیگنال بر اساس آزمون من وینتی.....
۷۹ شکل (۱-۴) جزئیات شبکه پیشنهادی.....
۸۲ شکل (۲-۴) مقایسه کیفیت سیگنال فیلتر شده با استفاده از دو نوع فیلتر دو روش پیش‌پردازش
۸۳ شکل (۳-۴) مقایسه پاسخ فرکانسی دو نوع فیلتر استفاده شده در دو روش پیش‌پردازش
۸۵ شکل (۴-۴) مقایسه آماری تاثیر دو روش پیش‌پردازش
۸۷ شکل (۵-۴) مقایسه عملکرد دو روش پیش‌پردازش در XGBoost
۸۹ شکل (۶-۴) عملکرد مدل پیشنهادی در دو مجموعه داد و نواحی مختلف پیشانی
۹۰ شکل (۷-۴) مقایسه عملکرد مدل پیشنهادی با دو مدل برتر مقاله پایه (یادگیری انتقالی) و روش‌های یادگیری ماشین پایه
۹۲ شکل (۸-۴) مقایسه میانگین ویژگی‌ها و روابط کانال‌ها در دو گروه در قسمت راست پیشانی
۹۳ شکل (۹-۴) مقایسه میانگین ویژگی‌ها و روابط کانال‌ها در دو گروه در قسمت میانی پیشانی
۹۴ شکل (۱۰-۴) مقایسه میانگین ویژگی‌ها و روابط کانال‌ها در دو گروه در قسمت چپ پیشانی

فهرست جداول

۳۰	جدول (۱-۲) مزایا و معایب fNIRS [63]
۳۰	جدول (۲-۲) مقایسه fNIRS با سایر روش‌های تصویربرداری عصبی [61]
۵۵	جدول (۱-۳) مقایسه دو نوع فیلتر FIR Hamming Window Filter و Butterworth Filter
۹۳	جدول (۱-۴) مقایسه میانگین تمام ویژگی‌های گره‌های بین دو گروه در قسمت راست پیش پیشانی
۹۴	جدول (۲-۴) مقایسه میانگین تمام ویژگی‌های گره‌های بین دو گروه در قسمت میانی پیش پیشانی
۹۵	جدول (۳-۴) مقایسه میانگین تمام ویژگی‌های گره‌های بین دو گروه در قسمت چپ پیش پیشانی

فصل ۱:

کلیات پژوهش و مسأله

۱-۱- مقدمه

اختلال بیماری آلزایمر یک اختلال مغزی انحطاطی با علت ناشناخته است. یک شکل رایج از زوال عقل، که در افراد میانسال یا مسن تر شروع می‌شود [1]. طبق اعلام انجمن آلزایمر، ۲۰٪ از بزرگسالان بزرگتر از ۶۵ سال به این اختلال مبتلا هستند. آلزایمر همچنین شایع ترین نوع زوال عقل در افراد مسن است [2]. عملکرد شناختی معمولاً با پنج حوزه مشخص می‌شود: یادگیری و حافظه، زبان، دیداری-فضایی، اجرایی و روانی حرکتی. این حوزه‌ها تقریباً با موقعیت مغزی خود مطابقت دارند و با استفاده از آزمایش عصبی روان‌شناختی شناسایی و ارزیابی می‌شوند [3].

بیماری آلزایمر منجر به از دست دادن پیشرونده حافظه، اختلال در تفکر، تغییرات در شخصیت و خلق و خو می‌شود [4]. در مراحل پایانی آلزایمز، افراد توانایی برقراری ارتباط یا پاسخ به محیط خود را از دست می‌دهند. آنها در تمام فعالیت‌های زندگی روزمره خود به کمک نیاز دارند و حتی ممکن است توانایی بلع خود را نیز از دست بدهند. در سال ۲۰۱۷، بیش از ۱۶ میلیون نفر از اعضای خانواده و سایر مراقبین بدون مزد، مشارکتی به ارزش بیش از ۲۳۲ میلیارد دلار، برای مراقبت از بیماران آلزایمر اختصاص دادند. چنین یافته‌هایی نیاز به یافتن راه حل‌هایی برای جلوگیری از هزینه‌های بالا افراد مبتلا به بیماری‌های مرتبط با آلزایمر را برجسته می‌کند [5]. اختلال شناختی خفیف، علائم اولیه اختلال شناختی شدی یا بیماری آلزایمر را نشان می‌دهد و با افزایش سن مرتبط است. MCI و زوال عقل می‌تواند منجر به از دست دادن استقلال و عملکرد فرد بشود که فشار باورنکردنی را بر افراد، خانواده‌ها، مراقبان و سیستم‌های مراقبت‌های بهداشتی وارد می‌کند [6]. بسیاری از محققان اشاره می‌کنند که تاثیرگذارترین دوره برای کاهش یا جلوگیری از پیشرفت بیماری آلزایمر، دوره اختلال شناختی خفیف است. در همین حال، تشخیص زودهنگام اختلال شناختی خفیف می‌تواند مانع از پیشرفت بیماری آلزایمر شود [7].

۲-۱- اختلال شناختی خفیف (MCI)

بیماری آلزایمر (AD) به طور رسمی به عنوان پنجمین علت اصلی مرگ برای افراد بالای ۶۵ سال است [8]. مرگ هفتصد هزار نفر ۶۵ سال و بالاتر در ایالات متحده به دلیل بیماری آلزایمر در سال ۲۰۱۹ برآورد شد [9]. همانطور که اخیراً توسط انجمن آلزایمر گزارش شده است، تخمین زده است که ۱۸.۵ میلیارد ساعت کمک (به ارزش ۲۳۳.۹ میلیارد دلار) توسط مراقبان افراد مبتلا به بیماری آلزایمر یا سایر زوال عقل ارائه شده است [10]. تصور بر این است که بیماری آلزایمر حداقل ۲۰ سال قبل از بروز علائم با تغییرات کوچک غیرقابل توجه در مغز شروع می‌شود. علائم به دلیل سلول‌های عصبی آسیب‌دیده (نورون‌ها) مربوط به تفکر، یادگیری و حافظه ایجاد می‌شوند [11]. علائم به مرور زمان رشد می‌کنند و به

تدريج شروع به تداخل در توانايی فرد برای انجام فعالیت های روزمره تا زمان مرگ می کنند. بيماري آزایير يك اختلال عصبي مغزي پيشرونده و غيرقابل برگشت در نظر گرفته می شود. در حال حاضر، هيچ درمان دارويي وجود ندارد که بتواند علائم بيماري آزایير را کاهش داده يا از آن جلوگيري کند [10]. در سال ۲۰۱۸، تخمين زده شد که بيش از ۵۰ ميليون نفر در سراسر جهان با زوال عقل زندگی می کنند و پيش بيني می شود که اين تعداد تا سال ۲۰۵۰ به بيش از ۱۵۰ ميليون نفر افزایش يابد [12]. از آنجايي که در حال حاضر هيچ درمانی وجود ندارد، تمرکز به سمت پيشگيري و بهبود كيفيت زندگي افراد مبتلا به زوال عقل معطوف شده است [13]. بسياري از محققان باور دارند که مرحله اوليه در فرآيند بيماري آزایير ، چه مرحله اختلال شناختي خفيف (MCI) يا مرحله پيش باليني، موثرترین دوره برای درمان های آينده برای کند کردن يا جلوگيري از پيشرفت بيماري آزایير خواهد بود [14]. اختلال شناختي خفيف به زوال جزئي حافظه يا تفكير، بدون تاثير بر توانايي زندگي مستقل و انجام بيشتر وظايف اطلاق می شود. در اختلال شناختي خفيف، خود فرد يا نزديkan او متوجه ايجاد تغييراتي در نحوه تفكير يا به خاطر سپردن موارد می شوند. اختلال شناختي خفيف، علائم اوليه اختلال شناختي شديد يا بيماري آزایير را نشان می دهد و با افزایش سن مرتبط است. در همین حال، تشخيص زودهنگام اختلال شناختي خفيف می تواند مانع از پيشرفت بيماري آزایير شود. با اين حال، يك وضعیت نسبی خفيف اختلال شناختي قبل از شروع آزایير وجود دارد، که به عنوان اختلال شناختي خفيف شناخته می شود، مرحله اي که در آن درمان می تواند شانس ابتلا به آزایير را کاهش دهد [15].

با اين حال، MCI اغلب توسط بيماران و مراقبان ناديده گرفته می شود، زيرا علائم آن ممکن است به پيرى طبیعی نسبت داده شود [16]. تخمين زده می شود که ۱۵ تا ۲۰ درصد از بزرگسالان ۶۵ سال يا بيشتر داراي اختلال شناختي خفيف (MCI) هستند [17]. که تقريرياً در ۳۰ درصد موارد به آزایير پيشرفت می کند. در حال حاضر، گزارش شده است که شروع دارودرمانی در مرحله MCI موثرترین روش برای کند کردن پيشرفت بيماري به سمت آزایير است [18].

۱-۳- تغييرات نوروفيزiolوژيک در MCI

نتایج تصويربرداری عصبی، تودههای غیرطبیعی پلاکهای پروتئین بتا آمیلوبید^۱ و پروتئینهای تاو^۲ در MCI مشابه آنچه در آزایير مشاهده می شود، نشان داده اند. پلاکهای^۳ بتا آمیلوبید نشانگرهای زیستی رسوب پروتئین هستند که در اوائل دوره پيش درومال بيماري آزایير مشاهده می شوند يعني دوره بدون علامتی که سالها قبل از شروع زوال شناختي رخ می دهد [19]. اين پلاکها معمولاً در نواحي قشری بهم

¹ Beta-Amyloid

² Tau

³ Plaques

پیوسته یافت می شوند که به ساختارهای لوب گیجگاهی داخلی می رساند، که می تواند در حافظه نقش داشته باشد [19]. پروتئین های تاو پروتئین هایی هستند که به طور معمول میکروتوبول ها را تشییت می کنند. با این حال، در آسیب شناسی آلزایمر، آنها به صورت توده های نامحلول در هم می روند که مانع عملکرد نورون ها و سلامت سلولی می شوند [19]. پروتئین های تاو و پلاک های آمیلوئید نیز می توانند سال ها قبل از ظهر علائم آلزایمر در مایع مغزی نخاعی شناسایی شوند. هر دو پروتئین در رابطه با آسیب شناسی MCI نیز مشاهده می شوند [19]. توده های پروتئین تاو، در کاهش عملکرد اجرایی در دوره اولیه بیماری AD، از جمله مرحله MCI نقش دارند. این کاستی ها در عملکرد اجرایی شامل دستکاری اطلاعات، شکل گیری مفهوم، حل مسئله کلامی و رفتار هدایت شده خود را نشان می دهند. فرض بر این است که این مشکلات به طور پاتولوژیک به دلیل بار پیچیدگی نورو فیبریلاری در قشر جلوی مغز به طور خاص ایجاد می شوند [19]. علاوه بر این، علائم آسیب شناسی^۱ سکته های کوچک یا کاهش جریان خون از طریق عروق خونی مغز نیز مشاهده شده است. تصویربرداری ساختاری مغز، کوچک شدن قابل توجه هیپوکامپ^۲، بخشی از مغز که در حافظه نقش دارد، بزرگ شدن بطن های پر از مایع و کاهش استفاده از گلوکز را نشان می دهد [20].

۱-۴- روشهای تشخیص اختلال شناختی خفیف

قبل از پیشرفت های گوناگون چند سال اخیر در زمینه علم کامپیوتر و همچنین توسعه نرم افزارها و پردازشگرهای علم روانشناسی و عصب شناسی عمدها با جهت گیری ها و تشخیص های متخصصین این حوزه ها مسئول بوده است. اما در چند سال اخیر، با توجه به کارآمدی هوش مصنوعی در بسیاری از صنایع و حوزه ها، این روشهای تشخیص های پزشکی، عصبی و روان شناختی نیز وارد شده و اساساً در حال دگرگونی شیوه های سنتی تشخیص است. این روشهای با ارائه دقیق تر علائم باعث تشخیص سریع تر بیماری ها و اختلالات می شوند. در چند سال اخیر، استفاده از روشهای مبتنی بر هوش مصنوعی برای تشخیص اختلال شناختی خفیف بسیار موثر بوده است. ارزیابی عملکردهای مغز با استفاده از نشانگرهای زیستی دیجیتال، از فناوری های تصویربرداری، مایعات فیزیولوژیکی، ژنومیک و تجزیه و تحلیل داده های مبتنی بر هوش مصنوعی، توجه تحقیقاتی قابل توجهی را به خود جلب کرده است. این روشهای ابزارهای قدرتمندی را برای ارزیابی عملکردی درمان و حتی توانبخشی احتمالی در اختلالات عصبی ارائه می کند [21]. مطالعات اخیر در مورد تجزیه و تحلیل تصویربرداری مغز، نقش موثر تکنیک های یادگیری ماشین را در برای تشخیص بیماری های مغزی نشان داده است [22].

¹ Pathology

² Hippocampus

۱-۴-۱- روش‌های بالینی

یکی از روش‌های بالینی ارزیابی‌های شناختی سنتی مانند آزمون وضعیت ذهنی کوچک (MMSE) و ارزیابی شناختی مونترال (MoCA) است که برای ارزیابی عملکردهای شناختی مانند حافظه، توجه و زبان استفاده می‌شود [23]. این تست‌ها به طور گسترده در تنظیمات بالینی استفاده می‌شوند و یک راه سریع و مقوون به صرفه برای ارزیابی اختلالات شناختی ارائه می‌دهند. آزمون وضعیت ذهنی کوچک (MMSE) شامل ۶ مقیاس است: توانایی زبانی، توانایی حافظه، توانایی محاسباتی، توجه، حافظه، جهت‌گیری و ساختار بصری فضایی. در مجموع شامل ۳۰ سوال است که به هر سوال پاسخ صحیح ۱ امتیاز اختصاص می‌یابد. نمره کل برای عملکرد شناختی طبیعی ۲۵-۳۰، برای ۲۴-۲۱ MCI، برای اختلال شناختی متوسط ۱۴-۲۰، و برای اختلال شناختی شدید ۱۳ یا کمتر از آن است [24].

مقیاس ارزیابی شناختی مونترال (MoCA) شامل ۸ جنبه ارزیابی شناختی، از جمله فضای بصری، تولنایی اجرایی، نامگذاری، حافظه، توجه، حافظه تاخیری، جهت‌گیری، روانی زبان و تفکر انتزاعی است. مجموع امتیاز ممکن ۳۰ است، هر چه امتیاز بالاتر باشد، عملکرد شناختی بهتر است، نمره ۲۶ یا بیشتر به عنوان نرمال طبقه بندی می‌شود. در صورتی که تعداد مدت زمان تحصیلی شرکت کننده کمتر یا مساوی ۱۲ سال باشد، ۱ امتیاز به امتیاز کل اضافه می‌شود [24].

یکی دیگر از روش‌های بالینی مصاحبه‌های بالینی و سابقه پزشکی است. مصاحبه‌های ساختاریافته با بیماران و مراقبان، همراه با مرور تاریخچه پزشکی، می‌تواند به شناسایی تغییرات ظریف شناختی کمک کند. این روش دید جامعی از وضعیت شناختی بیمار در طول زمان ارائه می‌دهد و امکان در نظر گرفتن عواملی مانند سابقه خانوادگی و سبک زندگی را نیز فراهم می‌کند.

یکی دیگر از روش‌های بالینی معاینه فیزیکی و اعصاب است. این معاینات معمول فیزیکی و عصبی می‌تواند به رد سایر شرایطی که ممکن است باعث علائم شناختی شوند، مانند سکته مغزی، تومورها یا کمبود ویتامین کمک کند. این روش به شناسایی شرایط چند ابتلایی (Comorbid Conditions) که می‌توانند بر عملکرد شناختی تأثیر بگذارند، کمک می‌کند.

۱-۴-۲- روش‌های مبتنی بر یادگیری ماشین

هوش مصنوعی با توانایی خود در تجزیه و تحلیل هوشمند داده‌های پیچیده و استخراج الگوهای پنهان، به عنوان یک انتخاب عالی برای تجزیه و تحلیل داده‌های علوم اعصاب که بسیار پیچیده هستند، مناسب است. همچنین، شبیه سازی‌های مبتنی بر هوش مصنوعی در مقیاس بزرگ به دانشمندان علوم اعصاب کمک می‌کند تا فرضیه‌های خود را آزمایش کنند. هوش مصنوعی همچنین می‌تواند برای تجزیه و تحلیل داده‌های تصویربرداری عصبی و کاهش بار کاری رادیولوژیست‌ها استفاده شود. مطالعه علوم اعصاب به تشخیص و تشخیص زودهنگام اختلالات عصبی کمک می‌کند، به همین ترتیب، استفاده از

هوش مصنوعی می‌تواند به طور موثر برای پیش‌بینی و تشخیص اختلالات عصبی به کار رود [25]. یادگیری عمیق (DL) باعث پیشرفت قابل توجهی در شناسایی و طبقه‌بندی الگوها شده است و یک روش امیدوارکننده یادگیری ماشین در نظر گرفته می‌شود [26]. شبکه‌های عصبی کانولوشنال (CNN)، پرکاربردترین معماری DL، عملکرد بسیار خوبی در پیش‌بینی به کمک رایانه برای اختلالات عصبی ارائه کرده‌اند [27]. مدل‌های یادگیری عمیق به یک سیستم اجازه می‌دهند تا از داده‌های خام به عنوان ورودی استفاده کند، در نتیجه به آن‌ها اجازه می‌دهند تا به طور خودکار ویژگی‌های بسیار متمایز در مجموعه داده‌های آموزشی داده شده را کشف کنند [29]. این فلسفه طراحی یادگیری انتهای انتها، اساس اساسی یادگیری عمیق است. مزیت اصلی یادگیری انتهای انتها به این است که تمام مراحل در خط لوله پردازش به طور همزمان بهینه می‌شوند و به طور بالقوه منجر به عملکرد بهینه می‌شوند. شبکه‌های عصبی گراف (GNN) دسته‌ای از شبکه‌های عصبی هستند که برای مدیریت داده‌های ساختار یافته به صورت گراف طراحی شده‌اند و آن‌ها را برای تجزیه و تحلیل داده‌های اتصال مغز مناسب می‌سازند. GNN‌های زمانی این قابلیت را به داده‌های گراف زمانی گسترش می‌دهند و امکان مدل سازی تغییرات پویا در اتصال مغز را در طول زمان فراهم می‌کنند [30]. استفاده از GNN در داده‌های fNIRS برای تشخیص MCI می‌تواند از اطلاعات غنی موجود در الگوهای اتصال مغز استفاده کند و به طور بالقوه ابزارهای تشخیصی حساس‌تر و خاص‌تری را در مقایسه با روش‌های سنتی ارائه دهد.

۱-۵- چالش‌های تشخیص اختلال شناختی خفیف

متأسفانه، تمایز بین MCI و پیری شناختی طبیعی می‌تواند چالش برانگیز باشد، زیرا علائم مشابه در هر دو شرایط مشترک است، مانند کاهش‌های مورد انتظار در دقت حسی، کاهش سرعت پردازش، و کاهش در عملکرد اجرایی [31]. تشخیص زودهنگام MCI می‌تواند مفید باشد زیرا اگرچه افراد مبتلا به MCI اغلب می‌توانند به عملکرد شناختی معمولی بازگردند، تقریباً ۵۰٪ از افراد مبتلا به MCI طی پنج سال به زوال عقل آلزایمر پیشرفت می‌کنند [32]. تصور می‌شود بازگشت به عملکرد شناختی معمولی به عواملی مانند داشتن اختلال تک دامنه‌ای، عدم وجود افسردگی همزمان، استفاده از داروهای آنتی کولینرژیک، حجم بیشتر هیپوکامپ در تصویربرداری عصبی و نمرات بالاتر در تست شناختی مربوط می‌شود [33]. تشخیص زودهنگام MCI نیز به دلیل موانع مرتبط با خود بیماری، ذاتاً چالش برانگیز است. علائم مربوط به شروع اولیه MCI می‌تواند به طور قابل توجهی بین افراد متفاوت باشد، بسته به علت، ذخیره شناختی، و نیازهای متغیر زندگی روزمره، در میان عوامل دیگر. علاوه بر این، MCI می‌تواند نسبت به سایر بیماری‌های همراه پزشکی کمتر مرتبط باشد و به اولویت بندی پزشکی متفاوت قبل از نظرارت بر شناخت کمک می‌کند. علاوه بر این، مراقبان و بیماران احتمالاً در مقایسه با سایر نگرانی‌های سلامتی نسبت به عملکرد شناختی حساس هستند. نگرانی‌های بیمار ممکن است منجر به سناریویی شود که در

آن پزشک به دلیل نگرانی در مورد به خطر انداختن رابطه پزشک و بیمار، در مورد بررسی ارزیابی عملکرد شناختی یا پیامدهایی که این مهارت‌ها بر مهارت‌های دیگر (مانند رانندگی) دارند، مردد است. به طور مشابه، افراد ممکن است به دلیل نگرانی در مورد پیامدهای ارزیابی شناختی و/یا ننگ درک شده مرتبط با اختلال شناختی، فعالانه از بحث در مورد عملکرد شناختی با پزشک خود اجتناب کنند. همه این مسائل به دلیل عدم استفاده و انطباق، می‌تولند کاربرد آزمایش‌های مفید بالینی را محدود کند [34]. اختلال شناختی خفیف (MCI) یک وضعیت پیچیده و چندوجهی است که به عنوان یک مرحله میانی بین پیری شناختی طبیعی و اشکال شدیدتر زوال عقل، مانند بیماری آلزایمر عمل می‌کند. علیرغم اهمیت بالینی، تشخیص MCI به دلیل علائم ظریف، تنوع در ارائه شناختی و فقدان ابزارهای تشخیصی استاندارد، چالش‌های متعددی را ارائه می‌کند. این چالش‌ها با تکیه بر ارزیابی‌های بالینی ذهنی و عدم وجود نشانگرهای زیستی پذیرفته شده جهانی ترکیب می‌شوند، که تشخیص دقیق و ثابت را دشوار می‌کند. این بخش به بررسی موانع کلیدی در تشخیص بالینی MCI می‌پردازد و نیاز به روش‌های تشخیصی بهبود یافته و یادگیری ماشین را برجسته می‌کند.

۱-۵-۱- ماهیت ظریف و ناهمگون اختلال شناختی خفیف

ماهیت ظریف و ناهمگون اختلال شناختی خفیف اغلب شناسایی بالینی آن را پیچیده می‌کند. نقاط شناختی مرتبط با اختلال شناختی خفیف نه تنها به سختی از پیری طبیعی متمایز می‌شود، بلکه تنوع قابل توجهی در بین افراد نشان می‌دهد. به عنوان مثال، برخی از بیماران ممکن است نقص‌هایی در حافظه نشان دهند، در حالی که برخی دیگر اختلالاتی در توجه یا عملکرد اجرایی نشان می‌دهند. این تنوع بیشتر با تفاوت‌ها در زمینه تحصیلی، عوامل فرهنگی و تولناکی‌های شناختی اولیه بیماران، که می‌تواند بر نمایش بالینی و تفسیر ارزیابی‌های شناختی تأثیر بگذارد، ترکیب می‌شود. علاوه بر این، مطالعات اخیر نشان می‌دهد که مسیر MCI می‌تواند به طور قابل توجهی متفاوت باشد، به طوری که برخی افراد ثابت می‌مانند، برخی دیگر به شناخت طبیعی بازمی‌گردند، و برخی با سرعت‌های مختلف به سمت زوال عقل پیش می‌روند [35]. اختلاف شناختی خفیف اغلب به عنوان یک مرحله میانی بین پیری طبیعی و زوال عقل، به ویژه بیماری آلزایمر در نظر گرفته می‌شود. ناهمگونی در شرح حال، حوزه‌های شناختی متفاوت تحت تأثیر و نرخ‌های مختلف پیشرفت به زوال عقل، تشخیص را پیچیده‌تر می‌کند [36].

۱-۵-۲- تغییرپذیری در حساسیت آزمون شناختی

تنوع در حساسیت آزمون‌های شناختی یک چالش مهم در تشخیص اختلال شناختی خفیف است. ارزیابی‌های شناختی مانند آزمون وضعیت ذهنی کوچک (MMSE) و ارزیابی شناختی مونترال (MoCA) به طور گسترده مورد استفاده قرار می‌گیرند، اما محدودیت‌هایی در تشخیص تغییرات شناختی اولیه و ظریف دارند. این تست‌ها اغلب به دلیل اثرات سقفی و عدم حساسیت به تغییرات در عملکرد اجرایی و

توجه مورد انتقاد قرار می‌گیرند که در تشخیص اولیه اختلال شناختی خفیف بسیار مهم هستند. علاوه بر این، تفاوت‌های فرهنگی و زبانی می‌تواند بر نتایج این آزمایش‌ها تأثیر بگذارد و منجر به تشخیص نادرست یا تشخیص نادرست در جمعیت‌های مختلف شود [37] [38].

تست‌های شناختی که معمولاً در محیط‌های بالینی استفاده می‌شوند ممکن است قادر حساسیت لازم برای تشخیص اختلالات اولیه یا خفیف مشخصه اختلال شناختی خفیف باشند. در نتیجه، اختلال شناختی خفیف اغلب کمتر یا اشتباہ تشخیص داده می‌شود، به ویژه در مراحل اولیه که مداخله ممکن است سودمندتر باشد. تنوع در اثربخشی ارزیابی‌های شناختی مختلف به ناسازگاری در تشخیص کمک می‌کند [39].

۱-۵-۳- تکیه بر قضاوت بالینی و ارزیابی‌های ذهنی

تشخیص اختلال شناختی خفیف اغلب به شدت به قضاوت بالینی و ارزیابی‌های ذهنی متخصصان مراقبت‌های بهداشتی متکی است. این اتکا می‌تواند منجر به تنوع در تشخیص‌ها در میان پزشکان مختلف و تنظیمات بالینی شود، زیرا تفسیرهای فردی علائم شناختی و اهمیت آنها ممکن است متفاوت باشد. فقدان معیارهای استاندارد شده این موضوع را تشدید می‌کند و دستیابی به تشخیص‌های منسجم و دقیق را دشوار می‌کند [40]. مطالعات نشان داده‌اند که پزشکان مختلف ممکن است به دلیل تفاوت در تجربه، آشنایی با معیارهای اختلال شناختی خفیف و سوگیری‌های فردی، حتی در هنگام ارزیابی یک بیمار، اختلال شناختی خفیف را متفاوت تشخیص دهند. این تنوع می‌تواند به تشخیص بیش از حد منجر شود، که در آن پیری طبیعی با اختلال شناختی خفیف اشتباہ گرفته می‌شود، یا به تشخیص نادرست، که در آن علائم اولیه زوال شناختی نادیده گرفته می‌شود. برای رسیدگی به این چالش‌ها، فشاری به سوی استانداردسازی معیارهای تشخیصی و گنجاندن اقدامات عینی، مانند تصویربرداری عصبی و بیومارکرهای مایع، در فرآیند تشخیص وجود دارد. علاوه بر این، هوش مصنوعی (AI) و الگوریتم‌های یادگیری ماشین به طور فزاینده‌ای در حال بررسی هستند تا با تجزیه و تحلیل مجموعه داده‌های پیچیده و شناسایی الگوهایی که ممکن است از طریق روش‌های سنتی آشکار نباشند، به پزشکان در تشخیص‌های عینی‌تر و ثابت‌تر کمک می‌کنند [36] [41].

۱-۶- درمان اختلال شناختی خفیف

رویکردهایی که در ادامه این بخش توضیح داده شد، درمان نیستند، و هیچ کس باور ندارد که این اقدامات تأثیر مستقیمی بر تغییرات نوروپاتولوژیک رخ داده در MCI خواهد داشت، اما هنوز دلیلی وجود دارد که فکر کنیم ممکن است پیشرفت به زوال عقل را به تاخیر بیندازند [42].

۱-۶-۱- مداخله دارویی

مداخلات دارویی اغلب به عنوان وسیله‌ای برای کاهش علائم MCI و به طور بالقوه کاهش پیشرفت آن به سمت اختلالات شناختی شدیدتر مورد بررسی قرار می‌گیرند. مهارکننده‌های کولین استراز^۱ مانند دونپزیل^۲ و رایوستیگمین^۳، که معمولاً در بیماری آلزایمر استفاده می‌شوند، برای تأثیر آنها بر MCI مورد مطالعه قرار گرفته‌اند. مطالعه‌ای توسط بنت و همکاران [43] نشان داد که دونپزیل پیشرفت از MCI به بیماری آلزایمر را به تعویق می‌اندازد، اگرچه این مزیت بیش از سال اول حفظ نشد. مطالعه دیگری توسط Winblad و همکاران [44] دریافتند که گالانتامین، یکی دیگر از مهارکننده‌های کولین استراز، مزایای بالقوه‌ای را در عملکرد شناختی نشان می‌دهد، اگرچه تأثیر طولانی مدت آن نامشخص است.

۱-۶-۲- ایده حفظ

اگر بتوانیم سطح عملکرد شناختی یک فرد را بالا ببریم، آن فرد قبل از پیشرفت به سمت زوال عقل سرعت پیشرفت کمتری از کاهش شناختی را تجربه می‌کند، که اساساً زمان بیشتری را برای سلامت شناختی نسبتاً خوب برای او می‌خرد. تحقیقات چندین عامل مربوط به اوایل زندگی و میانسالی مانند پیشرفت تحصیلی و شغلی را شناسایی کرده‌اند که ذخیره^۴ را افزایش می‌دهند و به افراد اجازه می‌دهند سطوح بالاتر آسیب‌شناسی عصبی را تحمل کنند و در عین حال عملکرد شناختی خود را حفظ کنند. این ذخیره می‌تواند عصبی باشد، برای مثال با تقویت ارتباطات عصبی غنی‌تر، یا شناختی، که به افراد اجازه می‌دهد به روش‌های جدیدی به وظایف خود نزدیک شوند [45].

۱-۶-۳- ورزش بدنی

مداخلات ورزشی فواید عصبی و شناختی کوچک اما قابل توجهی را برای شناخت در افراد مبتلا به MCI نشان داده است [46]. به عنوان مثال، بیکر و همکاران [47]، ۳۳ نفر را به طور تصادفی به تمرین هوازی و گروه دیگر رابا تمارین کششی^۵ ۴ بار در هفته طی ۶ ماه انتخاب کردند. علاوه بر اثرات موردن انتظار بر آمادگی قلبی تنفسی، تمرینات هوازی با بهبود توجه و عملکرد اجرایی همراه بود. ارتباط بین بهبود عملکرد قلبی تنفسی و معیارهای شناختی برای زنان بیشتر از مردان بود. این بهبودها علیرغم اینکه هر دو گروه از بهبودهای قابل مقایسه در آمادگی قلبی تنفسی برخوردار بودند، رخ داد.

¹ Cholinesterase

² Donepezil

³ Rivastigmine

⁴ Reserve

۱-۶-۴- الگوهای غذایی

پیروی از الگوهای غذایی مدتیرنهای با کاهش خطر ابتلا به MCI و AD در مطالعات اپیدمیولوژیک مرتبط بوده است [48]. مطالعات بررسی تأثیر رژیم غذایی در جمعیت‌های MCI که تا به امروز منتشر شده تاکنون امیدوارکننده بوده است [49]. مطالعه بیر و همکاران [50]، ۴۹ فرد مسن سالم و ۲۹ بزرگسال مبتلا به MCI فراموشی را به مدت چهار هفته به رژیم غذایی با چربی اشباع بالا/شاخص گلیسمی بالا یا رژیم غذایی با چربی اشباع پایین/شاخص گلیسمی پایین اختصاص داد. در گروه MCI، در مقایسه با رژیم غذایی بالا، رژیم غذایی با چربی اشباع پایین/شاخص گلیسمی پایین منجر به افزایش سطح CSF A β (نشان دهنده بهبود پاکسازی مغز) شد. اثرات مفید رژیم غذایی با چربی اشباع پایین بر سطح CSF A β در افرادی که فعالیت بدنی با شدت بالا را انجام می‌دهند، تقویت می‌شود که به اثرات افزایشی یا هم افزایی احتمالی رویکردهای چند جزئی برای مداخلات سبک زندگی سالم برای افزایش ذخیره در افراد مبتلا به MCI اشاره دارد.

۱-۶-۵- آموزش روانی اجتماعی

رویکرد دیگر برای افزایش ذخیره و عملکرد روزمره در افراد مبتلا به MCI، آموزش روانی اجتماعی گروهی است. این مداخلات معمولاً به افراد استراتژی‌های حافظه کاربردی و روزمره مانند تصویرسازی ذهنی و پردازش معنایی برای بهبود رمزگذاری اطلاعات را آموزش می‌دهند [42]. این مداخلات معمولاً آموزش افراد در مورد تأثیر عوامل سبک زندگی مانند ورزش، رژیم غذایی و درگیری شناختی و اجتماعی بر حافظه و تسهیل در اتخاذ سبک زندگی سالم و استراتژی‌های مقابله‌ای مانند آرامش و آماده شدن برای آینده است [51]. تعدادی از مطالعات بهبودهایی را در تست‌های عینی حافظه و سایر توانایی‌های شناختی گزارش کرده اند [52] [53] [54].

۱-۷- بیان مسئله

اختلال شناختی خفیف (MCI) مرحله بحرانی زوال شناختی است که بین پیری طبیعی و شرایط زوال عقل شدیدتر مانند بیماری آلزایمر (AD) قرار دارد. با وجود اهمیت آن، روش‌های تشخیصی فعلی برای MCI اغلب تهاجمی، گران‌قیمت هستند و همیشه به اندازه کافی حساس نیستند تا تغییرات اولیه در عملکرد مغز را تشخیص دهند. طیف سنجی عملکردی مادون قرمز نزدیک (fNIRS) یک جایگزین غیرتهاجمی و مقرن به صرفه برای نظارت بر فعالیت مغز ارائه می‌دهد. استفاده از داده‌های fNIRS حالت استراحت بهویژه امیدوارکننده است زیرا می‌تواند الگوهای اتصال درونی مغز را بدون تأثیرات مخدوش‌کننده فعالیت مغز مرتبط با کار ثبت کند. با این حال، تجزیه و تحلیل این داده‌ها به دلیل

پیچیدگی و ابعاد بالای شبکه های اتصال مغز چالش برانگیز است.

شبکه های عصبی گرافی (GNN) و به طور خاص GNN های زمانی، ابزار قدرتمندی برای مدل سازی و تجزیه و تحلیل این شبکه های مغزی پیچیده در طول زمان ارائه می دهند. آنها می توانند پویایی مکانی و زمانی اتصال مغز را به تصویر بکشند و رویکرد جدیدی را برای تمایز بین افراد دارای MCI و افراد سالم ارائه دهند.

این مطالعه با هدف پاسخگویی به سوالات کلیدی زیر انجام می شود:

۱. آیا روش پیش پردازش داده توسعه یافته در مقایسه با روش پیش پردازش مقاله پایه برای تشخیص دادن اختلال شناختی خفیف موثرتر است؟
۲. آیا داده های fNIRS در حالت استراحت، که با استفاده از GNN های زمانی تجزیه و تحلیل می شوند، می توانند به طور موثر بین افراد دارای MCI و افراد سالم تمایز قائل شوند؟
۳. آیا الگوهای اتصال مغز بیماران MCI با افراد سالم در طول حالت استراحت، متفاوت است؟
۴. ویژگی های خاص GNN های زمانی چیست که آنها را برای این نوع تحلیل مناسب می کند و چگونه می توان آنها را برای دقت تشخیصی بهتر بهینه کرد؟

هدف توسعه یک ابزار تشخیصی قوی و غیرتهاجمی است که از تکنیک های پیشرفته یادگیری ماشین برای بهبود تشخیص و نظارت زودهنگام اختلال شناختی خفیف استفاده می کند و در نهایت به نتایج بهتر برای بیمار و درمان مؤثرتر کمک می کند.

۱-۸- ساختار پایان نامه

این پایان نامه در پنج فصل تنظیم شده است که هدف هر یک از این فصل ها، ارائه های در ک بهتری از روش های تشخیص اختلال خفیف شناختی (MCI) با استفاده از هوش مصنوعی و تصویربرداری عصبی غیرتهاجمی است. مرکز اصلی این تحقیق بر روی استفاده از طیف سنجی نزدیک به مادون قرمز عملکردی (fNIRS) و شبکه های عصبی گرافی (GNN)، به ویژه شبکه های عصبی گراف زمانی (TGNN)، می باشد. محتوای کلی هر یک از این پنج فصل به شرح زیر است:

❖ فصل اول: کلیات پژوهش و بیان مسأله

در فصل اول، به ارائه های پیش زمینه و انگیزه های انجام این پژوهش پرداخته می شود. این فصل، موضوع اختلال خفیف شناختی (MCI) را معرفی کرده و روش های مختلف تشخیص آن را بررسی می کند. سپس به چالش هایی که در تشخیص بالینی این اختلال وجود دارد، پرداخته می شود. در نهایت، مسأله پژوهش بیان شده، ساختار کلی پایان نامه توضیح داده می شود و اهداف و دستاوردهای کلیدی تحقیق به

- معرفی اختلال خفیف شناختی (MCI) و اهمیت تشخیص آن.
- بررسی روش‌های مختلف تشخیص MCI از جمله روش‌های بالینی و مبتنی بر یادگیری ماشین.
- بررسی چالش‌های موجود در تشخیص MCI، مانند پیچیدگی و ناهمگونی این اختلال.
- بیان مسأله‌ی پژوهش و تشریح اهداف و دستاوردهای تحقیق.
- ارائه‌ی ساختار کلی پایان‌نامه و مرور کلی محتوای آن.

❖ فصل دوم: پیشینه تحقیق

این فصل به بررسی مبانی نظری و مرور مطالعات و تحقیقات پیشین در زمینه‌ی تشخیص MCI می‌پردازد. در این فصل، اصول و کاربردهای طیف‌سنجدی نزدیک به مادون قرمز عملکردی (fNIRS) و شبکه‌های عصبی گرافی (GNN)، به ویژه شبکه‌های عصبی گراف زمانی (TGNN)، مورد بررسی قرار می‌گیرند. همچنین مطالعات قبلی در مورد طبقه‌بندی MCI با استفاده از این روش‌ها مرور می‌شوند و به نقد روش‌های پیش‌پردازش داده‌ها در این مطالعات پرداخته می‌شود تا محدودیت‌های آن‌ها مشخص شود.

- مرور اصول و کاربردهای طیف‌سنجدی نزدیک به مادون قرمز عملکردی (fNIRS) در علوم اعصاب شناختی.

- بررسی مزایای استفاده از fNIRS در حالت استراحت برای تحقیقات مربوط به MCI.
- معرفی و بررسی انواع شبکه‌های عصبی گرافی (GNN)، به ویژه شبکه‌های عصبی گراف زمانی (TGNN).
- مرور مطالعات پیشین در زمینه‌ی طبقه‌بندی MCI و تحلیل روش‌های استفاده شده در این مطالعات.
- نقد روش‌های پیش‌پردازش داده‌ها در مطالعات قبلی و بررسی محدودیت‌های آن.

❖ فصل سوم: مقدمات پژوهش

در فصل سوم، روش‌های جمع‌آوری داده‌ها و نحوه‌ی پیش‌پردازش آن‌ها به تفصیل توضیح داده می‌شود. این فصل به معرفی تکنیک‌های مختلف پیش‌پردازش داده‌ها می‌پردازد و روش پیشنهادی این تحقیق را با روش‌های استفاده شده در مطالعات قبلی مقایسه می‌کند. همچنین طراحی و جزئیات پیاده‌سازی مدل شبکه عصبی گراف زمانی (TGNN) تشریح می‌شود و معیارهای ارزیابی برای سنجش کیفیت سیگنال‌ها و عملکرد مدل بررسی می‌گردد.

- توضیح روش‌های جمع‌آوری داده‌های fNIRS
- بررسی تکنیک‌های مختلف پیش‌پردازش داده‌ها شامل پاکسازی اولیه، حذف نویزها، تکنیک‌های فیلتر کردن سیگنال و نرمال‌سازی.

- مقایسه روش پیشنهادی پیشپردازش داده‌ها با روش‌های استفاده شده در مطالعات قبلی.
- طراحی و پیاده‌سازی مدل شبکه عصبی گراف زمانی (TGNN) و توضیح جزئیات آن.
- معرفی و بررسی معیارهای ارزیابی کیفیت سیگنال و عملکرد مدل.

❖ فصل چهارم: روش پیشنهادی

در این فصل، روش پیشنهادی از جمله ساخت گراف‌های زمانی، توسعه مدل GNN و معیارهای ارزیابی مورد استفاده مورد بحث قرار می‌گیرد. بخش نتایج و تجزیه و تحلیل کیفیت داده‌های پیش‌پردازش شده و عملکرد مدل GNN را با تجزیه و تحلیل مقایسه‌ای بین افراد دارای اختلال شناختی خفیف با افراد سالم ارزیابی می‌کند.

- نحوه ساخت گراف‌های زمانی و استخراج ویژگی‌ها برای استفاده در مدل GNN شرح داده می‌شود.

- معماری مدل GNN پیشنهادی، فرآیند آموزش و اعتبارسنجی آن و معیارهای ارزیابی مورد استفاده برای سنجش عملکرد مدل توضیح داده می‌شود.
- به تحلیل نتایج به دست آمده از مدل GNN می‌پردازد. ارزیابی کیفیت داده‌های پیش‌پردازش شده، عملکرد مدل و تحلیل مقایسه‌ای بین گروه‌های دارای اختلال شناختی خفیف و افراد سالم مورد بحث قرار می‌گیرد. همچنین، تفسیر نتایج و ارتباط موفقیت مدل با تکنیک‌های پیش‌پردازش داده‌ها شرح داده می‌شود.

❖ فصل پنجم: جمع‌بندی و پیشنهادات

فصل آخر پایان‌نامه به خلاصه‌ای از یافته‌های اصلی تحقیق می‌پردازد. همچنین دستاوردهای پژوهش و کاربردهای عملی آن مورد بحث قرار می‌گیرد. محدودیت‌های پژوهش بیان می‌شود و پیشنهادهایی برای تحقیقات آینده و کاربردهای بالینی ارائه می‌گردد.

- خلاصه‌ای از یافته‌ها و دستاوردهای پژوهش.
- بحث در مورد کاربردهای عملی و تأثیرات تحقیق.
- بیان محدودیت‌های پژوهش.

فصل ۲:

بررسی پیشینه و ادبیات پژوهش

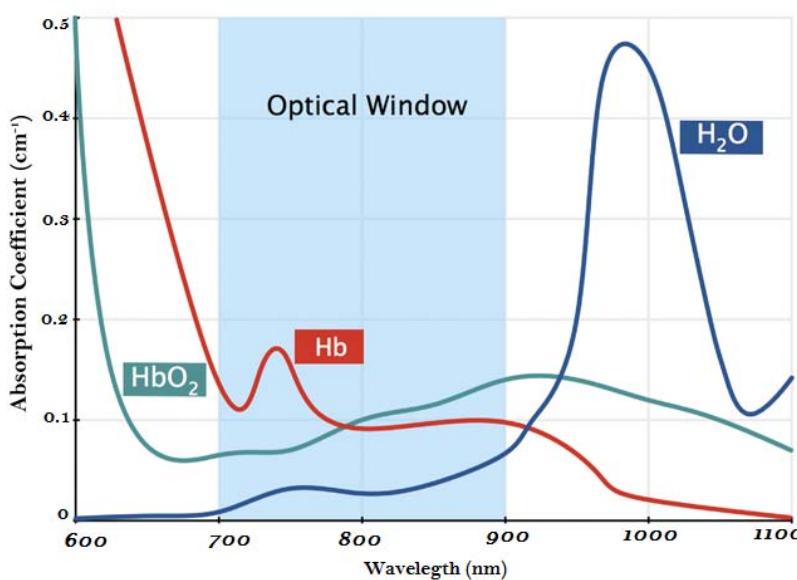
۱-۲- مقدمه

در این فصل، به بررسی پیشینه و ادبیات پژوهش‌های مرتبط با موضوع تشخیص اختلال خفیف شناختی (MCI) با استفاده از طیفنگاری کارکردی فروسرخ نزدیک (fNIRS) و شبکه‌های عصبی گرافی (GNN) پرداخته می‌شود. این فصل به منظور فراهم آوردن زمینه‌ای جامع برای فهم بهتر مطالعات پیشین و نقاط قوت و ضعف آن‌ها، طراحی شده است. همچنین، این بررسی ادبیات به طور ویژه به روش‌های پیشنهادی در این پژوهش اشاره دارد. در بخش‌های آتی، ابتدا اصول و کاربردهای fNIRS در علوم اعصاب شناختی و مزایای استفاده از این تکنیک در حالت استراحت بررسی می‌شود. سپس به مرور مطالعاتی که از fNIRS در تحقیقات مرتبط با MCI استفاده کرده‌اند، پرداخته خواهد شد. در ادامه، مقدمه‌ای بر شبکه‌های عصبی گرافی ارائه شده و سپس به معنی GNN های زمانی و کاربرد آن‌ها در علوم اعصاب خواهیم پرداخت. هدف این فصل، ایجاد یک پایه قوی برای تجزیه و تحلیل‌های بعدی است.

۲-۲- طیفنگاری کارکردی فروسرخ نزدیک fNIRS

پیشرفت‌ها در فناوری‌های تصویربرداری عصبی عملکردی و تحقیقات تأثیر عمدہ‌ای بر درک ما از طیف وسیعی از عملکردهای مغز، نه تنها در مورد مغز سالم، بلکه در شرایط عصبی و روان‌پزشکی داشته است. با این حال، درک اینکه چگونه عملکرد در وظایف شناختی کاملاً کنترل شده با زندگی روزمره ما مرتبط است و می‌تواند در تشخیص و درمان شرایط بالینی ارزشمند باشد، هنوز چالش برانگیز است. برخی از این چالش‌ها از محدودیت‌های خود فناوری‌های تصویربرداری عصبی ناشی می‌شوند. fNIRS یک تکنیک تصویربرداری عصبی نوری و غیر تهاجمی است که امکان اندازه‌گیری تغییرات غلظت هموگلوبین اکسیژن‌دار (HbO₂) و هموگلوبین بدون اکسیژن (HbR) در بافت مغز را به دنبال فعال‌سازی عصبی می‌دهد. این امر با تابش نور (۶۵۰-۹۵۰ نانومتر) به سر به دست می‌آید و با بهره گیری از شفافیت نسبی بافت بیولوژیکی در این پنجره نوری، نور به بافت مغز می‌رسد. نور در این محدوده توسط اکسی هموگلوبین و دی اکسی هموگلوبین بسیار قوی تر از بافت‌های اطراف جذب می‌شود. محدوده طول موج ۶۵۰-۹۵۰ نانومتر برای fNIRS انتخاب می‌شود، زیرا برای نفوذ به بافت‌های بیولوژیکی از جمله پوست سر، جمجمه و مغز بهینه است، در حالی که هنوز به طور متفاوت توسط هموگلوبین اکسیژن‌دار و بدون اکسیژن جذب می‌شود. نور در محدوده ۶۵۰-۹۵۰ نانومتر که به عنوان "پنجره نوری" یا "پنجره درمانی" شناخته می‌شود، می‌تواند تا عمق قلبی توجهی به بافت‌های بیولوژیکی نفوذ کند. طول موج های کوتاه تر (زیر ۷۰۰ نانومتر) به شدت توسط بافت‌های سطحی جذب می‌شوند، در حالی که طول موج های بلندتر (بالاتر از ۹۰۰ نانومتر) توسط محتوای آب در بافت جذب می‌شوند که عمق نفوذ را محدود می‌کند. در محدوده ۶۵۰-۹۵۰ نانومتر، هموگلوبین اکسیژن‌دار (HbO₂) و هموگلوبین بدون اکسیژن (HbR) دارای طیف‌های

جدبی متمایز هستند. این به fNIRS اجازه می‌دهد تا با تشخیص جذب نسبی نور در طول موج‌های مختلف در این محدوده، تغییرات در اکسیژن رسانی خون را لندازه گیری کند. پراکندگی نور در این محدوده طول موج کاهش می‌یابد، که به دستیابی به سیگنال واضح تراز مغز کمک می‌کند. پراکندگی در طول موج‌های کوتاه‌تر به طور قابل توجهی افزایش می‌یابد، که دقیق‌تر اندازه گیری fNIRS را کاهش می‌دهد. با استفاده از طول موج در ۹۵۰-۶۵۰ نانومتر، fNIRS می‌تواند به طور موثر اکسیژن رسانی خون مغز و پاسخ‌های همودینامیک مربوط به فعالیت عصبی را نظارت کند.



شکل (۱-۲) (ضریب جذب $\text{H}_2\text{O}, \text{Hb}, \text{HbO}_2$ در طول موج‌های متفاوت

کشف وجود پنجه نوری مادون قرمز نزدیک^۱ (NIR) در بدن ما به سال ۱۹۷۷ برمی‌گردد، زمانی که فرانسیس جوبسیس توانایی نور قرمز را برای نفوذ از یک استخوان ۴ میلی‌متری یک استیک گوشت گاو در حالی که آن را در مقابل نگه داشته بود مشاهده کرد. این نشان می‌دهد که نور قرمز و حتی نور NIR با طول موج‌های بلندتر، می‌تواند از پوست سر و جمجمه ما عبور کرده و به بافت‌های زیرین برسد. فناوری fNIRS از خاصیت شفافیت پوست و استخوان نسبت به نور NIR بهره می‌برد و در بسیاری از زمینه‌ها و کاربردهای مختلف، از جمله بررسی فیزیولوژی عضله و نظارت بالینی قشر مغز استفاده شده است. به طور خلاصه، در اوایل دهه ۱۹۹۰، ضبط‌های fNIRS ابتدا با استفاده از دستگاه‌های تک کاناله انجام شد و توانایی fNIRS را برای اندازه‌گیری اکسیژن و تغییرات همودینامیک در مغز در پاسخ به وظایف فعال‌سازی عملکردی در بزرگسالان را نشان داد. این روش، میزان جذب طیف مادون قرمز نزدیک در هموگلوبین موجود در خون با اکسیژن و بدون اکسیژن را اندازه گیری کرده و مشابه با تصویربرداری تشدید

¹ Near Infrared

مغناطیسی^۱) اطلاعات مهمی در مورد فعالیت مغزی کارکردی فراهم می‌نماید. در این روش، پرتو نور نزدیک به طیف مرئی، به سطح پوست سر تابانده می‌شود و بخشی از نور تابیده شده جذب و بخشی نیز بازتاب می‌شود. با اندازه گیری تغییرات در مشخصه‌های امواج نوری بازتاب شده از سطح سر می‌توان پاسخ همودینامیک را ارزیابی نمود. تکنولوژی fNIRS تغییرات نسبی در غلظت اکسی هموگلوبین، دی اکسی هموگلوبین و مجموع اکسی هموگلوبین + دی اکسی هموگلوبین را به طور پیوسته اندازه گیری می‌کند. برای بهره‌برداری کامل و گسترش پتانسیل fNIRS، اندازه گیری‌های چند کanalی مورد نیاز است. در ابتدا، دستگاه‌های تک کanalه ترکیب شدند و به طور همزمان در مکان‌های مختلف مورد استفاده قرار گرفتند [55]. اولین سیستم‌های چند کanalه توسعه یافته‌ند که امکان نظارت بر نواحی مختلف را فراهم می‌کردند. مطالعات اثباتی زیادی انجام شد و اعتبارسنجی fNIRS به عنوان یک ابزار تصویربرداری عصبی عملکردی قابل اعتماد تأیید شده است [56].

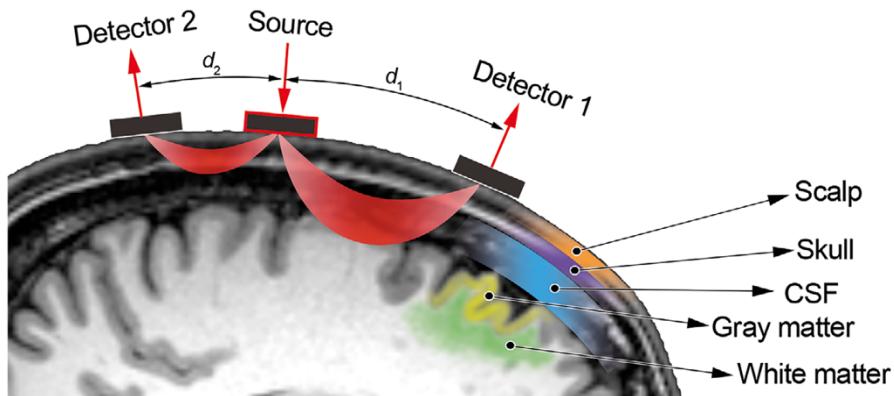
همانطور که ابزار پیچیده‌تر چند کanalه و پوشیدنی توسعه یافته و در آزمایش‌های شناختی مورد استفاده قرار گرفته است، fNIRS به پیشرفت‌های مهمی در درک فعالیت عملکردی مغز و عملکردهای شناختی بالاتر در بزرگسالان و نوزادان، هم در سلامت و هم در بیماری منجر شده است [57] [58] [59] [60]. اندازه گیری fNIRS با انتقال نور NIR بر روی پوست سر انجام می‌شود. قبل از رسیدن به مغز، نور NIR باید از چندین لایه مختلف (به عنوان مثال، پوست سر، جمجمه، مایع مغزی نخاعی) عبور کند که هر کدام دارای خواص نوری متفاوتی هستند. بنابراین برهمکنش نور NIR با بافت انسانی پیچیده است. هنگامی که یک ناحیه از مغز فعال و درگیر اجرای یک کار خاص است، نیاز متابولیکی مغز برای اکسیژن و گلوکز افزایش می‌یابد که منجر به عرضه بیشتر جریان خون مغزی منطقه‌ای^۲ (CBF) برای پاسخگویی به افزایش تقاضای متابولیک مغز می‌شود. افزایش CBF در پاسخ به افزایش فعالیت عصبی، پرخونی عملکردی نامیده می‌شود و توسط چندین مکانیسم جفت عصبی عروقی، مانند تغییر در قطر مویرگی و متابولیت‌های^۳ وازاکتیو^۴، واسطه می‌شود. از این رو، عرضه بیش از حد در CBF منطقه‌ای باعث افزایش HbO₂ و کاهش غلظت HbR می‌شود. این‌ها با تغییرات در تضعیف نور که می‌تواند توسط fNIRS اندازه گیری شود، تخمین زده می‌شود. علاوه بر جذب، نور NIR هنگام عبور از بافت بیولوژیکی پراکنده نیز می‌شود. پراکنده‌گی نور ۱۰۰ برابر بیشتر از جذب است و منجر به تضعیف نور می‌شود. هر چه یک فوتون بیشتر پراکنده شود، مسیر طی شده طولانی‌تر و احتمال جذب آن بیشتر می‌شود. نوری که به سر می‌تابد پراکنده، منتشر شده و می‌تواند چندین سانتی متر در بافت نفوذ کند. بنابراین، اگر یک آشکارساز نور را در فاصله معینی از منبع نور NIR قرار دهیم، می‌توانیم نور پس پراکنده را جمع‌آوری کنیم (شکل ۱-۲) و

¹ Magnetic Resonance Imaging

² Cerebral blood flow

³ Metabolite

⁴ Vasoactive



شکل ۲-۲) مسیری که توسط فوتون های NIR از منبع نور به آشکارساز از طریق لایه های مختلف سر دنیال می شود [61].

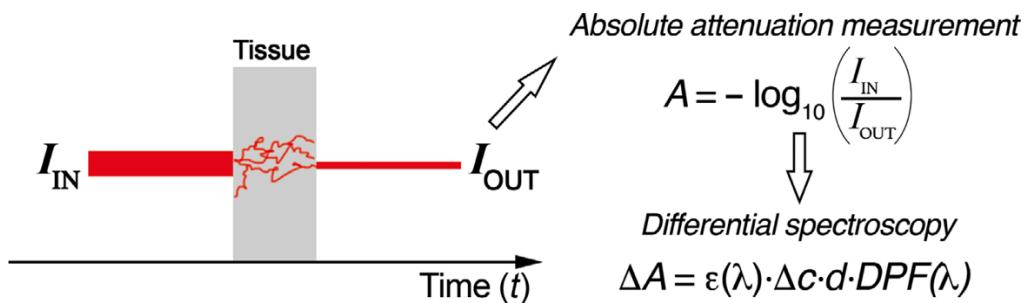
از آنجایی که جذب در پنجره نوری NIR عمدتاً به دلیل HbO₂ و HbR است، تغییرات در تضعیف نور در یک طول موج معین را می توان به صورت ترکیبی خطی از تغییرات غلظت HbO₂ و HbR بیان کرد. بیشتر سیستم های تجاری موجود، که به عنوان ابزارهای fNIRS موج پیوسته^۱ (CW) شناخته می شوند، از نور NIR منتشر شده پیوسته، معمولاً در دو یا سه طول موج، استفاده می کنند و میرایی نور (A) را همانطور که در شکل ۲-۲ نشان داده شده است از طریق نسبت نور تزریق شده (Iin) به نور خروجی (Iout) اندازه گیری می کنند. دستگاه های fNIRS موج پیوسته می توانند اطلاعاتی در مورد تغییرات غلظت HbO₂ و HbR ارائه دهند، اما نمی توانند غلظت های پایه مطلق را حل کنند، زیرا قادر به جداسازی و تعیین کمیت سهم جذب و پراکندگی نیستند. به همین دلیل است که اندازه گیری HbO₂ و HbR از صفر شروع می شود. با این حال، این سیستم ها به خوبی برای کاربرد در علوم اعصاب شناختی مناسب هستند، زیرا تمرکز مطلق ضروری نیست و فعالیت عملکردی معمولاً نسبت به یک خط پایه ارزیابی می شود [61]. علاوه بر سیستم های fNIRS مبتنی بر فناوری موج پیوسته، ابزارهای fNIRS را می توان به دو کلاس دیگر نیز تقسیم کرد: دستگاه های حوزه زمان^۲ (TD) و حوزه فرکانس^۳ (FD). این دو ردوش به جذب نور و مشارکت در پراکندگی اجازه می دهند تا از هم جدا شوند، بنابراین غلظت مطلق HbO₂ و HbR به دست می آید. دستگاه های FD با نور NIR تعدیل شده به مغز می تابانند و سیستم های TD نسبت به موج پیوسته پیچیده تر هستند. در این روش یک منبع نور NIR با پالس های چند پیکوثانیه و یک آشکارساز با زمان بندی سریع برای بازیابی زمان پرواز فوتون های بازپدید شده را اجرا می کند. یعنی هر چه مدت زمان صرف شده در داخل مغز توسط فوتون ها بیشتر باشد، فاصله آنها بیشتر می شود [62]. بنای تکنولوژی fNIRS اندازه گیری نوری است. هنگامی نور تابیده می شود و از محیطی عبور می کند

¹ Continuous Wave

² Time Domain

³ Frequency Domain

مقداری از فوتون‌ها توسط مولکول‌های آن محیط جذب می‌شوند و طول موج نور خروجی از آن محیط با طول موج نور تابیده شده متفاوت است و میزان جذب فوتون‌ها رابطه مستقیمی با میزان غلظت مولکول‌های محیط دارد. هنگامی که غلظت اکسی هموگلوبین در طول عروق زیاد باشد نور جذب فوتون نور بیشتر است. برای بررسی و کمی کردن این موضوع از قانون بیر-لامبرت اصلاح شده^۱ استفاده می‌کنیم. به طور کلی، فن‌آوری fNIRS را می‌توان به دو روش استفاده کرد، بر اساس تعداد کانال‌ها و پیکربندی آن‌ها. فیبرهای نوری ساطع کننده و آشکارساز fNIRS در ساده‌ترین، رایج‌ترین و در دسترس‌ترین شکل تجاری خود، به طور منحصر به فردی در مکان‌های مختلف رأس سر و در جداسازی آشکارساز منبع ثابت توزیع می‌شوند. هر جفت ساطع کننده - آشکارساز نشان دهنده یک کانال اندازه گیری است که بازنمایی تپوگرافیکی از توزیع تغییرات در غلظت HbO₂ و HbR بر روی سطح قشر مغز را ارائه می‌دهد. اخیراً ابزارهای پوشیدنی و یا بدون فیبر fNIRS توسعه یافته‌اند که این دستگاه‌ها مبتنی بر فناوری موج پیوسته هستند که با باتری کار می‌کنند و معمولاً از LED‌هایی که مستقیماً به کلاه متصل می‌شوند استفاده می‌کنند. عدم وجود بسته‌های فیبر نوری باعث می‌شود که آن‌ها سبک‌تر و مقاوم‌تر از مصنوعات حرکتی باشند. بنابراین شرکت‌کنندگان می‌توانند با محدودیت‌های کمتری به‌طور طبیعی حرکت کنند. معمولاً داده‌ها را می‌توان روی واحد ضبط پوشیدنی ضبط کرد یا به صورت بی‌سیم به کامپیوتر فرستاد.



شکل (۳-۲) دستگاه‌های موج پیوسته تضعیف نور ناشی از پراکندگی و جذب را بر اساس اندازه گیری شدت نور ورودی (I_{in}) و خروجی (I_{out}) اندازه گیری می‌کنند.^[61]

میرایی(A) با محاسبه لگاریتم نسبت بین I_{in} و I_{out} که به تغییرات غلظت هموگلوبین مربوط می‌شود، ارزیابی می‌شود. تغییرات در میرایی ΔA به تغییرات در غلظت کروموفور (Δc ، یا HbO₂ یا HbR) توسط قانون بیر-لامبرت اصلاح شده مربوط می‌شود. d نشان دهنده فاصله منبع-آشکارساز، ϵ ضریب خاموش شدن کروموفور در یک طول موج مشخص و فاکتور طول مسیر تفاضلی(DPF) طول مسیر تفاضلی است و نشان دهنده افزایش مسیر فوتون به دلیل پراکندگی است (شکل ۲-۲).

¹ Modified Beer-Lambert law

۲-۲-۲- مزایا و معایب fNIRS

کاربرد یک تکنیک تصویربرداری عصبی خاص را می‌توان به روش‌های مختلفی ارزیابی کرد، از جمله وضوح مکانی و زمانی، استحکام داده‌ها، منابع مصنوعات، پتانسیل برای تجزیه و تحلیل‌های پیشرفت، و دسترسی شرکت کنندگان.

جدول ۱-۲) مزایا و معایب fNIRS [63]

مزایا	معایب
امن	وضوح زمانی کمتر از EEG/MEG
وضوح فضایی بهتر از EEG	وضوح فضایی کمتر از fMRI
وضوح زمانی بهتر نسبت به fMRI	عمق نفوذ (۱-۲ سانتی متر)
امکان نظارت همزمان بر HbR و HbO ₂	عدم امکان جمع آوری تصاویر ساختاری و اطلاعات آناتومیک
تحمل مصنوعات حرکتی	قرار دادن حسگرهای نوری در مناطق پر مو و همچنین تعداد زیاد منابع و آشکارسازها می‌تواند زمان بر باشد.
قابل حمل	حساسیت بیشتر به خطاهای حرکتی و راحتی کمتر در صورت اندازه گیری‌های با پوشش بالا (مناطق بیشتر سر) با فیبر نوری متصل به سر
هزینه کم	عدم استانداردسازی در تجزیه و تحلیل داده‌ها
بی صدا	
قابل استفاده در سیستم‌های پوشیدنی	
مناسب بودن برای استفاده مدت طولانی	
امکان تصویربرداری چندوجهی (ترکیب با دیگر روش‌ها)	
راحتی بیشتر شرکت کنندگان در مقایسه با fMRI	
همه شرکت کنندگان واجد شرایط هستند (همه سنین)	

در اینجا، قبل از ارائه مقایسه متمرکزتر بین fNIRS و سایر روش‌های تصویربرداری عصبی موجود، مزایا و معایب fNIRS را برای تحقیقات تصویربرداری عصبی بررسی می‌کنیم (جدول ۱-۲) و شکل (۳-۲).

جدول ۱-۲) مقایسه fNIRS با سایر روش‌های تصویربرداری عصبی [61]

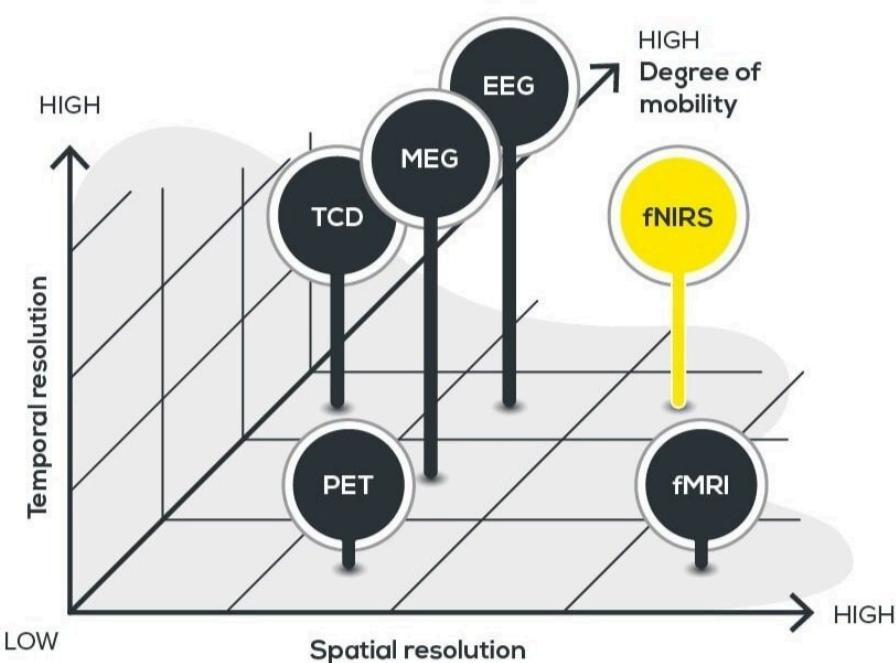
	fNIRS	fMRI	EEG/MEG	PET
--	-------	------	---------	-----

سیگنال	HbO ₂ , HbR	BOLD ^۱ (HbR)	الکترومغناطیسی	حریان خون مغزی متابولیسم گلوکز
وضوح فضایی	۲ تا ۳ سانتی متر	وکسل های ۰.۳ میلی متری	۵ تا ۹ سانتی متر	۴ میلی متر
عمق نفوذ	قشر مغز	کل سر	قشر مغز برای ساختارهای EEG/MEG عمیق برای	کل سر
نرخ نمونه برداری	تا ۱۰ هرتز	۱ تا ۳ هرتز	بیش از ۱۰۰۰ هرتز	کمتر از ۰.۱ هرتز
طیف وظایف ممکن	زیاد	محدود	محدود	محدود
پایداری در بار حرکت	خیلی خوب	محدود	محدود	محدود
طیف شرکت کنندگان احتمالی	هر شخص	محدود، مخصوصاً برای کودکان	هر شخص	محدود
صدا	بدون صدا	صدا زیاد	بدون صدا	بدون صدا
قابل حمل بودن	بله، برای سیستم های قابل حمل	خیر	بله، برای سیستم های EEG قابل حمل	خیر
هزینه	کم	بالا	پایین برای EEG بالا برای MEG	بالا

سیستم‌های fNIRS اندازه‌گیری‌هایی را از سطح قشر مغز متشکل از دو سیگنال همودینامیک HbO₂ و HbR، با وضوح فضایی ۲ تا ۳ سانتی متر فراهم می‌کنند. بررسی رابطه متقابل بین این دو سیگنال به ما امکان می‌دهد تا نتایج دقیق تری در مورد فعالیت عملکردی مغز بگیریم [64]. مانند fMRI، fNIRS پاسخ همودینامیک را ثبت می‌کند که معمولاً پس از حدود ۶ ثانیه به اوج خود می‌رسد. با این حال، سیستم‌های fNIRS دارای نرخ‌های نمونه‌برداری زمانی هستند که معمولاً تا ۱۰ هرتز می‌رسد، که به طور گسترده‌ای از پاسخ همودینامیک^۲ (HRF) نمونه‌برداری می‌کند. این امکان ردیابی بهتر شکل HRF را فراهم می‌کند. یکی از عوامل اصلی افزایش تحقیقات fNIRS این است که این روش تحمل خوبی

^۱ Blood oxygen level dependent^۲ Hemodynamic response function

نسبت به مصنوعات حرکتی دارد. یک کلاه fNIRS با موقعیت مناسب همچنان سیگنال‌های خوبی را هنگام راه رفتن یک شرکت کننده ارائه می‌دهد [65]. در طول زمان دستگاه‌های پوشیدنی کوچک‌تر، سبک‌تر و در نتیجه برای حرکات بدن مقاوم‌تر شده‌اند. این باعث می‌شود که fNIRS برای طیف وسیع‌تری از وظایف شناختی، مانند کارهایی که نیاز به پیاده روی دارند، به عنوان مثال برای اهداف توانبخشی عصبی، مناسب باشد. در صورت جابجایی سنسور نوری به دلیل حرکات سریع سر، مصنوعات حرکتی می‌توانند به صورت سریع و باریک یا جابجایی از مقادیر پایه در سیگنال‌های fNIRS ظاهر شوند.



شکل ۴-۲۰) fNIRS در مقایسه با سایر روش‌ها [66]

سیستم‌های fNIRS در مواردی که ایمنی و راحتی شرکت کنندگان در اولویت هستند، مزایای زیادی دارند. ضبط fNIRS بی‌صدا، نسبتاً راحت است و محدودیت‌های فیزیکی را بر شرکت کننده تحمیل نمی‌کند، به این معنی که روش انتخابی برای بسیاری از مطالعات نوزادان و کودکان و برای جلسات ضبط طولانی مناسب است. برخلاف fMRI، هیچ نگرانی ایمنی وجود ندارد و fNIRS می‌تواند برای همه شرکت کنندگان از نوزادان [67] تا جمعیت بیماران بزرگسال استفاده شود [68]. به طور خلاصه، می‌تواند سیگنال‌های همودینامیک را با نمونه برداری زمانی بالا در طیف وسیعی از زمینه‌ها و جمعیت‌ها ارائه دهد. سایر فناوری‌های موجود برای مطالعه شناختی انسان عبارتند از fMRI و توموگرافی گسیل پوزیترون (PET) که بر اتصال عصبی عروقی متکی است و الکتروانسفالوگرافی (EEG) و مغناطیسی مغزی (یا MEG) که فعالیت الکترومغناطیسی مغز را تشخیص می‌دهد. این روش‌ها معمولاً بر اساس تفکیک زمانی و مکانی هر کدام مقایسه می‌شوند، اما عوامل مهم دیگری نیز وجود دارد. به طور خاص، مقاوم بودن در برابر حرکت، گستردگی و تنوع نمونه شرکت کننده که می‌توان مطالعه کرد، عوامل مهمی در بسیاری از

زمینه‌ها هستند. جدول ۲-۲ نقاط قوت و ضعف فناوری‌های تصویربرداری عصبی را خلاصه می‌کند.

۳-۲-۲ fNIRS در علوم اعصاب شناختی

فعالیت عصبی با افزایش گشادشده‌گی عروق موضعی و به دنبال آن افزایش جریان خون مغزی (CBF) و افزایش حجم خون مغزی (CBV) یعنی پر خونی^۱ عملکردی، مرتبط است که به منظور پشتیبانی از افزایش تقاضای مغز برای مواد مغذی (یعنی گلوکز و اکسیژن) رخ می‌دهد. میزان اکسیژنی که به ناحیه فعال مغز می‌رسد بیشتر از نرخی است که مصرف می‌شود، که منجر به افزایش هموگلوبین اکسیژنه (HbO₂) و کاهش هموگلوبین بدون اکسیژن (HbR) می‌شود. این پدیده به عنوان پاسخ همودینامیک شناخته می‌شود و می‌توان آن را با استفاده از fNIRS در نقاط مختلفی از قشر مغز اندازه‌گیری کرد. مغز یک اندام با تقاضای انرژی بالا است و فعال‌سازی نورون‌ها با افزایش جریان خون و حجم خون مغزی مرتبط است. در واقع، fNIRS به ابزاری برای مراقبت استاندارد در بخش‌های مراقبت ویژه کودکان تبدیل شده است تا اکسیژن‌سازیون منطقه‌ای، مانند اکسیژن‌سازیون بدنی^۲ [69] و اکسیژن‌سازیون مغزی [70]، را در لحظه ارزیابی کند. fNIRS همچنین به طور گسترده برای ارزیابی عملکرد قشری مغز استفاده می‌شود. با استفاده از طراحی بلوکی، سیگنال‌های جریان خون مغزی منطقه‌ای می‌توانند تقویت شوند تا عملکرد قشری مبتنی بر وظیفه را مشخص کنند [71].

یکی از مزایای اصلی fNIRS در علوم اعصاب شناختی، قابلیت آن در اندازه‌گیری فعالیت مغزی در شرایط طبیعی و بدون نیاز به بی‌حرکتی کامل بیمار است. این ویژگی به ویژه در مطالعاتی که با کودکان یا افراد مبتلا به اختلالات حرکتی انجام می‌شود، بسیار حائز اهمیت است [61]. علاوه بر این، fNIRS امکان بررسی تعاملات اجتماعی و وظایف چندنفره را در شرایط طبیعی و غیر آزمایشگاهی فراهم می‌کند، که این امر موجب افزایش اعتبار خارجی یافته‌های پژوهشی می‌شود [72]. از fNIRS در طیف وسیعی از تحقیقات علوم اعصاب شناختی استفاده شده است. به عنوان مثال، این روش برای مطالعه پردازش زبانی، توجه، حافظه کاری، و تصمیم‌گیری استفاده شده است [63]. مطالعات نشان داده‌اند که fNIRS می‌تواند تغییرات در فعالیت قشری را در پاسخ به محرك‌های مختلف و در طول وظایف شناختی پیچیده شناسایی کند [73]. اخیراً، تحقیقات fNIRS به بررسی شبکه‌های مغزی و ارتباطات عملکردی نیز گسترش یافته است. این روش به محققان امکان می‌دهد تا تغییرات پویا در ارتباطات شبکه‌ای مغز را در طول وظایف شناختی و همچنین در حالت استراحت بررسی کنند [74]. زبان پیشرفته‌ترین عملکرد قشری در مغز و مهم‌ترین حوزه عملکردی است که در طی جراحی‌های مغز برای برداشتن تومور و درمان صرع باید مشخص و محلی‌سازی شود [75]. صرع شناسان، جراحان مغز و اعصاب و روانشناسان اعصاب به دنبال

¹ Hyperaemia

² Somatic

یک جایگزین غیرتهاجمی بوده لند و fNIRS برای این منظور مورد مطالعه قرار گرفته است [76] [77]. [78] وضوح زمانی محدود و تفکیک عمقی fNIRS موانع اصلی برای نگاشت زبان است. علاوه بر این، fNIRS فاقد دقت بالای مکانی است، که برای برنامه ریزی جراحی بسیار مهم است. افزایش تراکم حسگرهای نوری و ثبت مشترک با سایر روش‌های تصویربرداری (مانند MRI) می‌تواند دقت مکانی را بهبود بخشد[79]. دقت بالای مکانی در محیط مراقبت‌های عصبی که در آن لندازه گیری به موقع اکسیژن رسانی مغزی هدف اصلی است، کمتر به یک موضوع تبدیل می‌شود. fNIRS با توجه به غیرتهاجمی بودن و وضوح زمانی خوب برای تغییرات همودینامیک به طور گستردۀ برای این منظور استفاده شده است. مطالعات نشان داده‌لند که fNIRS پتانسیل نظارت بر تغییرات همودینامیک مغزی و خودتنظیمی مغزی^۱ (CA) در مرحله‌ای که بعد از مرحله حاد اولیه سکته مغزی اما قبل از فاز مزمن رخ می‌دهد را دارد [80]. fNIRS حوزه فرکانس یکی دیگر از ابزارهای نوظهور برای ارزیابی خودتنظیمی مغزی در بیماران سکته مغزی است. مشخص شده است که نوسانات کم^۲ (LFO) اکسی هموگلوبین پارامترهای قوی برای ارزیابی خودتنظیمی مغزی هستند [81]. به غیر از ارزیابی تغییرات فیزیولوژیکی مغزی شناخته شده، fNIRS همچنین می‌تواند یک ابزار تحقیقاتی مفید برای آن دسته از بیماری‌هایی باشد که مکانیسم‌های آنها به طور کامل کشف نشده است. اختلال عملکرد اتونومیک یک مثال است. مطالعات نشان داده‌لند که fNIRS می‌تواند به عنوان ابزاری برای ارزیابی اختلالات اتونومیک (مسئول تنظیم عملکردهای غیر ارادی بدن) مورد استفاده قرار گیرد [82] [83] [84]. تشخیص دپرشن گستردۀ قشر مغز به عنوان ویژگی اصلی الکتروفیزیولوژیکی هاله میگرنی فرض می‌شود [85]. NIRS عملکردی می‌تواند یک نشانگر زیستی بالقوه برای ارزیابی پاسخ درمانی به دارو در بیماران مبتلا به میگرن باشد [86]. چند گروه راجع به کاربرد fNIRS برای تشخیص افسردگی دپرشن گستردۀ قشر مغز^۳ (CSD) در میگرن تمرکز کرده‌اند [87] [88]. در ادامه، پتانسیل fNIRS به عنوان یک نشانگر زیستی تشخیصی در اختلال شناختی خفیف نشان داده شده است.

با پیشرفت تکنولوژی و توسعه حسگرهای پیشرفته‌تر، انتظار می‌رود که کاربردهای fNIRS در علوم اعصاب شناختی افزایش یابد. ترکیب fNIRS با سایر تکنیک‌های تصویربرداری مانند EEG می‌تواند اطلاعات جامع‌تری در مورد فعالیت‌های مغزی فراهم کند. همچنین، بهبود روش‌های پردازش داده و کاهش حساسیت به حرکات می‌تواند محدودیت‌های فعلی fNIRS را کاهش دهد و با نگاهی به تصویر بزرگتر، fNIRS احتمالاً به گسترش در سایر زمینه‌های تحقیقاتی ادامه خواهد داد و شاید در محیط‌های بالینی برجسته تر شود. همانطور که توسط پینتی و همکاران بحث شده است [89]. از آنجایی که این

¹ Cerebral Autoregulation

² Low Frequency Oscillation

³ Cortical Spreading Depression

سیستم‌ها و روش‌ها گستردہ‌تر و در دسترس‌تر می‌شوند، fNIRS ممکن است شاهد انفجاری در توجه و علاقه باشد، مانند آنچه در fMRI دھه‌های قبل رخ داده است، که تقریباً بر تمام حوزه‌های علوم اعصاب تأثیر می‌گذارد [90].

۴-۲-۲- استفاده از fNIRS در تحقیقات MCI

اختلال خفیف شناختی (MCI) با کاهش شناختی مشخص می‌شود که بین پیری طبیعی و کاهش جدی‌تر مرتبط با زوال عقل قرار دارد. این اختلال حداقل یکی از حوزه‌های شناختی، مانند حافظه یا تفکر پیچیده را تحت تأثیر قرار می‌دهد، اما فعالیت‌های روزمره زندگی را مختل نمی‌کند. حدود ۱۵-۲۰ درصد از بیماران مبتلا به MCI به بیماری آلزایمر (AD) مبتلا می‌شوند [91]. تست‌های عصب‌روان‌شناختی به عنوان اصلی‌ترین نشانگر زیستی برای تشخیص بیماران مبتلا به MCI که در نهایت به آلزایمر مبتلا می‌شوند از کسانی که به آلزایمر مبتلا نمی‌شوند استفاده شده است [92] [93]. مانند سایر روش‌های تصویربرداری عصبی غیرتھاجمی، fNIRS نیز به عنوان یک نشانگر زیستی بالقوه برای تمایز MCI و AD مورد بررسی قرار گرفته است [94]. مطالعات اخیر fNIRS در مورد MCI نشان داده‌لند که قشر خلفی‌جانبی پیش‌پیشانی^۱ در طول حافظه کاری [95] [96] و قشر پشتی‌جانبی پیش‌پیشانی^۲ مغز در طول بازیابی حافظه افزایش کمتری در اکسی‌هموگلوبین وجود دارد [97]. اخیراً تمرکز بر نشانگر زیستی تصویربرداری عصبی غیرتھاجمی برای MCI و AD به سمت اتصال عملکردی تغییر کرده است. اتصال چپ و بین‌نیمکره‌ای در طول یک تست روان‌کلامی در بیماران مبتلا به MCI در مقایسه با گروه کنترل سالم کمتر بوده است [98]. این موضوع می‌تواند نشان‌دهنده استفاده از مکانیسم‌های جبرانی در قشر پیش‌پیشانی به عنوان نتیجه‌ای از اتصال پیش‌فرض مختل در بیماران مبتلا به MCI باشد. در مطالعه دیگری [99] ، نتایج نشان می‌دهد که می‌توان از اندازه‌گیری ۳۰ ثانیه حالت استراحت با fNIRS برای تشخیص MCI استفاده کرد. اخیراً، مطالعات fNIRS تلاش کرده‌اند بین ضعف شناختی مرتبط با MCI و AD تمایز قائل شوند. زیرا این بیماری‌ها فعالیت متابولیکی نورون‌های قشری را تغییر می‌دهند که این به نوبه خود می‌تواند ویژگی‌های نوری تغذیه نورو‌عروقی بافت‌های قشری مغز را تغییر دهد در نتیجه این امر ممکن است. در مطالعه‌ای فعالیت غیرعادی در قشرهای پیش‌پیشانی بیماران MCI و AD در طول وظایف شناختی مختلف مشاهده شده است [100].

در مطالعه [101] به وضوح نوید استفاده بالینی را نشان می‌دهد و می‌تواند یک ابزار تشخیصی مفید در آینده باشد. مزایای اضافی انعطاف‌پذیر، سریع، غیرتھاجمی و متحرک بودن fNIRS را

¹ Bilateral Prefrontal Lobes

² Dorsolateral Prefrontal Cortex

به چیزی تبدیل می‌کند که می‌توان از آن در محیط‌های عادی استفاده کرد. سهولت استفاده و کاربرد fNIRS، آن را به یک گزینه ممکن برای بازدیدهای مطب بالینی نیز تبدیل می‌کند [102]. در نهایت همچنان تحقیقات بیشتری برای اعتبارسنجی fMRI در مقابل fNIRS به عنوان ابزاری برای توصیف اتصال عملکردی در بیماران مبتلا به MCI مورد نیاز است [103].

۳-۲- ضبط در حالت استراحت

ضبط در حالت استراحت^۱ یکی از روش‌های پرکاربرد در تصویربرداری عصبی است که به بررسی فعالیت‌های مغزی بدون نیاز به انجام وظایف خاصی توسط فرد می‌پردازد. این تکنیک به دلایل مختلفی، از جمله فراهم آوردن اطلاعات غنی از شبکه‌های عصبی مغز و سهولت اجرا، مورد توجه ویژه محققان و متخصصین بالینی قرار گرفته است. ضبط در حالت استراحت به بررسی فعالیت‌های مغزی در حالت غیر فعال (بدون انجام وظایف خاص) می‌پردازد. اتصال عملکردی در حالت استراحت یک زیر حوزه مطالعه است که به محققان اجازه می‌دهد تا فعالیت مغز را در غیاب یک کار یا محرک بررسی کنند. این می‌تواند بینشی در مورد معماری عملکردی ذاتی مغز ارائه دهد و به شناسایی شبکه‌های عصبی که در هنگام استراحت فعال هستند کمک کند. در زیر به چند مورد از مزایای آن می‌پردازیم:

- ارائه دیدگاه جامعی از فعالیت‌های عصبی مغز: حالت استراحت به محققان امکان می‌دهد که بدون نیاز به تحریکات خارجی، الگوهای فعالیت مغز را مورد بررسی قرار دهند. این روش امکان مشاهده شبکه‌های عصبی مغز، مانند شبکه حالت پیش‌فرض^۲، را فراهم می‌آورد که در بسیاری از تحقیقات مربوط به اختلالات عصبی، مانند بیماری آلزایمر، نقش مهمی دارد [104].
- سهولت در اجرا: برخلاف روش‌های وظیفه‌محور که نیاز به طراحی و اجرای وظایف پیچیده دارند، ضبط در حالت استراحت بسیار ساده‌تر است و نیازی به تعامل فعالانه فرد با محیط ندارد. این مسئله باعث می‌شود تا این روش در جمعیت‌های مختلف از جمله کودکان، سالمندان، و بیماران با مشکلات شناختی به راحتی قابل اجرا باشد [105]. یکی از مزایای اصلی پتانسیل کاهش عوامل مخدوش کننده مانند تنوع بین فردی در انطباق با وظایف و یا عملکرد در طول ضبط داده است [106]. این ویژگی به ویژه در محیط‌های بالینی و تحقیقاتی که نیاز به تصویربرداری سریع و ساده دارند، بسیار مفید است.
- پایداری و مقاومت در برابر نویزهای حرکتی: یکی دیگر از مزایای مهم ضبط در حالت استراحت، مقاومت آن در برابر نویزهای حرکتی است، زیرا نیاز نیست بیمار حرکت کند یا

¹ Resting state

² Default Mode Network

کاری انجام دهد که این باعث کم شدن نویزهای حرکتی می‌شود.

- راحتی بیشتر برای بیمار: حالت استراحت همچنین برای بکارگیری در افراد مبتلا به نقص‌های شناختی آسان تر است [107].

fNIRS تجزیه و تحلیل اتصال عملکردی در حالت استراحت بر اساس داده‌های حالت استراحت برای مطالعه عملکرد مغز در جمعیت‌های سالم و بیمار معتبر و قبل از اعتماد است، بنابراین یک ابزار تصویربرداری امیدوارکننده برای علوم شناختی و کلینیک‌ها ارائه می‌کند [108].

۴-۲- شبکه‌های عصبی گرافی^۱

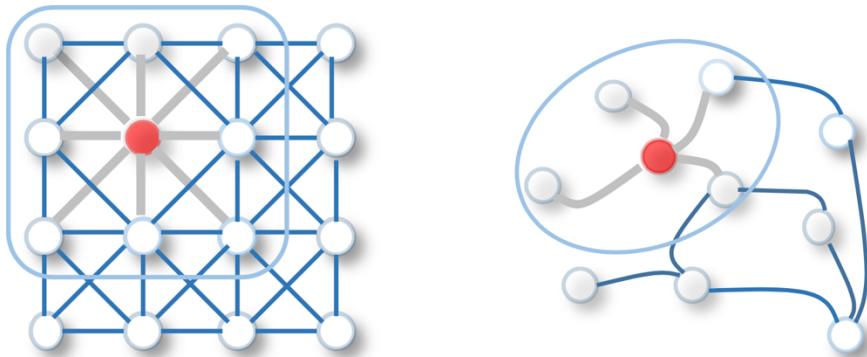
دنباله اطراف ما از اجزایی تشکیل شده است که در تعامل و ایجاد روابط با یکدیگر هستند. این امر باعث می‌شود که گراف‌ها یک نمایش داده ضروری و یک بلوک مهم برای برنامه‌های کاربردی یادگیری ماشین باشند. گره‌های گراف با موجودیت‌ها و یال‌ها مربوط به تعاملات و روابط هستند. یادگیری عمیق در سال‌های اخیر بسیاری از وظایف یادگیری ماشین را متحول کرده است، از طبقه بندی تصویر و پردازش ویدیو گرفته تا تشخیص گفتار و درک زبان طبیعی. داده‌های این وظایف معمولاً در فضای اقلیدسی نشان داده می‌شوند. با این حال، تعداد فزاینده‌ای از برنامه‌ها وجود دارد که در آن داده‌ها از حوزه‌های غیر اقلیدسی تولید می‌شوند و به صورت گراف‌هایی با روابط پیچیده و وابستگی متقابل بین اشیاء نشان داده می‌شوند. به طور سنتی، مدل‌های یادگیری ماشین برای پیش‌بینی موجودیت‌ها (یا اشیا یا نمونه‌ها) تنها با توجه به ویژگی‌های آن‌ها و صرف نظر از ارتباط آن‌ها با موجودیت‌های دیگر در داده‌ها، توسعه داده می‌شوند. پیچیدگی داده‌های گرافی چالش‌های قابل توجهی را بر الگوریتم‌های یادگیری ماشینی موجود تحمیل کرده است. اخیراً، مطالعات زیادی در مورد گسترش رویکردهای یادگیری عمیق برای داده‌های گرافی پیدید آمده است. در این بخش از پایان‌نامه، ما یک نمای کلی از شبکه‌های عصبی گراف (GNN) در زمینه‌های داده کاوی و یادگیری ماشین ارائه می‌دهیم. در حالی که یادگیری عمیق به طور موثر الگوهای پنهان داده‌های اقلیدسی را استخراج می‌کنند، تعداد فزاینده‌ای از زمینه‌ها وجود دارد که در آنها داده‌ها به شکل گراف نمایش داده می‌شوند. به عنوان مثال، در شیمی، مولکول‌ها به صورت گراف مدل‌سازی می‌شوند و فعالیت زیستی^۲ آن‌ها برای کشف دارو باید شناسایی شود. در یک شبکه استنادی، مقالات از طریق استناد به یکدیگر مرتبط می‌شوند و باید در گروه‌های مختلف دسته بندی شوند. از آنجایی که گراف‌ها می‌توانند نامنظم باشند، ممکن است یک گراف دارای تعداد متغیری از گره‌های نامرتب باشد، و گره‌های یک گراف ممکن است تعداد همسایه‌های متفاوتی داشته باشند گراف‌ها به طور طبیعی در بسیاری از کاربردهای دنیای واقعی از جمله سیستم‌های توصیه‌کننده، زیست‌شناسی، شبکه‌های اجتماعی، هستی‌شناسی، گراف‌های دانش و امور مالی محاسباتی به وجود می‌آیند. در برخی

¹ Graph Neural Network (GNN)

² Bio-activity

حوزه‌ها، گراف ثابت است، یعنی ساختار گراف و ویژگی‌های گره در طول زمان ثابت می‌ماند. در سایر حوزه‌ها، گراف در طول زمان تغییر می‌کند. برای مثال، در یک شبکه اجتماعی، هنگامی که افراد دوستان جدیدی پیدا می‌کنند، لبه‌های جدید اضافه می‌شوند، زمانی که افراد دیگر دوستی ندارند، لبه‌های موجود حذف می‌شوند، و با تغییر ویژگی‌های افراد، ویژگی‌های گره تغییر می‌کنند، به عنوان مثال، زمانی که آنها حرفه خود را تغییر می‌دهند با این فرض که شغل یکی است.

محاسبه برخی از عملیات‌های مهم (مثلًاً کانولوشن^۱‌ها) در حوزه تصویر آسان است، اما اعمال در حوزه گراف دشوار است. علاوه بر این، یک فرض اصلی الگوریتم‌های یادگیری ماشینی موجود این است که نمونه‌ها مستقل از یکدیگر هستند. این فرض دیگر برای داده‌های گراف صدق نمی‌کند، زیرا هر نمونه (گره) با پیوندهایی از انواع مختلف، مانند نقل قول‌ها، دوستی‌ها و تعاملات، به دیگران مرتبط است. اخیراً، توجه فرایندهای به گسترش رویکردهای یادگیری عمیق برای داده‌های گراف بوجود آمده است. با انگیزه شبکه‌های عصبی کانولوشنال^۲ (CNN)، شبکه‌های عصبی بازگشتی^۳ (RNN) و رمزگذارهای خودکار^۴ از یادگیری عمیق، تعمیم‌ها و تعاریف جدیدی از عملیات مهم در چند سال گذشته برای رسیدگی به کانولوشن داده‌های گرافی توسعه یافته‌اند. به عنوان مثال، کانولوشن گرافی را می‌توان از یک کانولوشن دو بعدی تعمیم داد.



شکل ۲-۵) کانولوشن دو بعدی در مقابل کانولوشن گرافی

همانطور که در شکل (۵-۲) نشان داده شده است، یک تصویر را می‌توان به عنوان یک مورد خاص از گراف‌ها در نظر گرفت که در آن پیکسل‌ها توسط پیکسل‌های مجاور به هم متصل می‌شوند. مشابه کانولوشن دو بعدی، می‌توان با گرفتن میانگین وزنی اطلاعات همسایگی یک گره، کانولوشن گرافی را انجام داد.

در اینجا، ما شرح مختصری از GNN‌ها را ارائه می‌دهیم. فرض کنید $G = (V, A, X)$ یک گراف ثابت

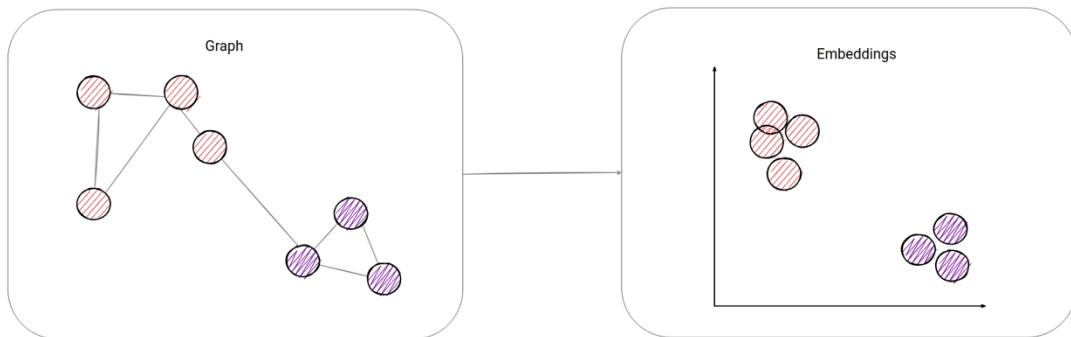
¹ Convolution

² Convolutional Neural Network

³ Recurrent Neural Network

⁴ Auto Encoder

باشد. یک GNN یک تابع است $f: \mathbb{R}^{n \times n} \times \mathbb{R}^{n \times d} \rightarrow \mathbb{R}^{n \times d'}$ (یا به طور خاص A و X) را به عنوان ورودی می‌گیرد و به عنوان خروجی یک ماتریس $Z \in \mathbb{R}^{n \times d'}$ ارائه می‌دهد که در آن $Z_i \in \mathbb{R}^{d'}$ مربوط به یک نمایش پنهان برای v_i است. این نمایش را جانمایی^۱ گره می‌نامند. ارائه یک گره جانمایی شده برای هر گره v_i را می‌توان به عنوان کاهش ابعاد نیز در نظر گرفت که در آن اطلاعات از ویژگی‌های اولیه v_i و همچنین اطلاعات مربوط به اتصال آن به سایر گره‌ها و ویژگی‌های این گره‌ها در یک بردار Z_i (جانمایی شده) ثبت می‌شود. از این بردار می‌توان برای پیش‌بینی‌های آگاهانه در مورد v_i استفاده کرد. در ادامه، یک نمونه GNN یعنی شبکه کانولوشن گراف^۲ گراف‌های بدون جهت توضیح می‌دهیم.



شکل ۶-۲) (مثالی از جاسازی کردن گره [109]

شبکه‌های کانولوشن گراف [110] چندین لایه کانولوشن گراف را پشته می‌کنند. لایه ۱ از GCN برای یک گراف بدون جهت ($G = (V, A, X)$) را می‌توان به صورت زیر فرموله کرد:

$$(2-1) Z^l = \sigma(D^{-\frac{1}{2}} \tilde{A} D^{-\frac{1}{2}} Z^{(l-1)} W^{(l)})$$

- که در آن \tilde{A} مربوط به ماتریس مجاورت همراه با حلقه^۳ هر گره است، ماتریس درجه^۴ D یک ماتریس قطری است که $D_{i,i} = \tilde{A}_i$ (۱ نشان دهنده بردار ستونی از یک ها است).
- $D^{-\frac{1}{2}} \tilde{A} D^{-\frac{1}{2}}$ مربوط به نرمال‌سازی سطر و ستون \tilde{A} است.
- $Z^{(0)} \in X \in \mathbb{R}^{n \times d^{(0)}}$ که نشان دهنده جانمایی در لایه ۱ و به ترتیب $Z^{(l)} \in \mathbb{R}^{n \times d^{(l)}}$
- $W^{(l)} \in \mathbb{R}^{n^{(l-1)} \times d^{(l)}}$ ماتریس وزن را در لایه ۱ نشان می‌دهد و σ یک تابع فعال سازی است.

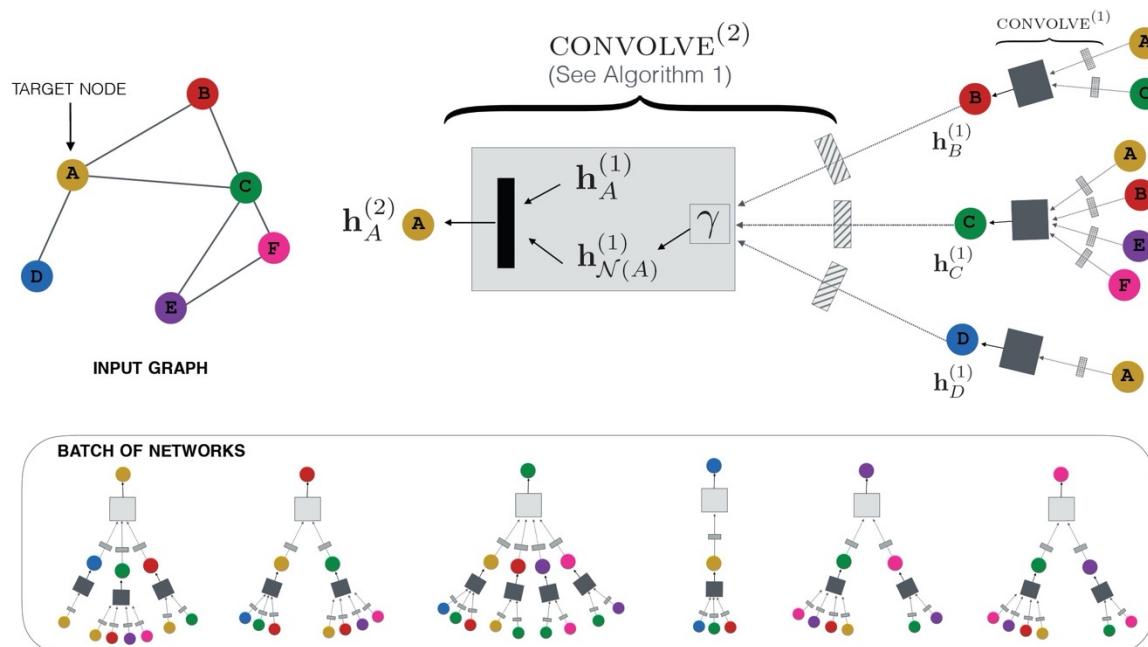
¹ Embedding

² Graph Convolutional Network (GCN)

³ Self Loop

⁴ Degree Matrix

لایه ۱ یک مدل GCN را می‌توان به صورت زیر توصیف کرد. ابتدا، با استفاده از ماتریس وزن $W^{(l)}$ یکتابع خطی را به جانمایی‌های گره $Z^{(l-1)}$ اعمال می‌کند، سپس، برای هر گره v_i یک مجموع وزنی از جانمایی‌های که تابع خطی بروی آن‌ها اعمال شده v_i و همسایگانش محاسبه می‌شود، که وزن‌ها برای این مجموع وزنی بر اساس $D^{-\frac{1}{2}}\tilde{A}D^{-\frac{1}{2}}$ تعیین می‌شوند. در نهایت، یک غیرخطی‌سازی به مجموع‌های وزنی اعمال می‌شود و جاسازی‌های گره‌ها به روزرسانی می‌شوند. توجه داشته باشید که در یک GCN با L لایه، جانمایی‌ها برای هر گره بر اساس همسایگی L پوش^۱ آن (یعنی بر اساس گره‌هایی که در نهایت L پوش از آن فاصله دارند) محاسبه می‌شود. اصطلاح "1-hop" در تئوری گراف به فرآیندی اشاره دارد که در آن شما از یک گره خاص شروع به حرکت و به تعداد "1" یال در گراف پیش روی می‌کنید. در طراحی شبکه‌های گرافی، تعداد لایه‌های شبکه عصبی گرافی تعداد پرش‌هارا برای هر گره مشخص می‌کند. برای مثال، در شکل ۷-۲ هنگامی که از دو لایه شبکه عصبی گراف (GNN) استفاده شده است، حداقل فاصله پوش که اطلاعات هر گره می‌تواند تأثیر بگذارد حداقل دو پرش است. با این حال، این بدان معنا نیست که هر گره تضمین شده است که به گره‌هایی دقیقاً دو پرش فاصله دارد. بلکه به این معنی است که اطلاعات می‌توانند تا دو پرش فاصله انتشار یابد.



شکل ۷-۲) معماری یک مدل با استفاده از دو لایه GCN [111]

کانولوشن گراف اساساً بر اساس مکانیسم ارسال پیام^۲ است. ارسال پیام یک مکانیسم اصلی است که در شبکه‌های عصبی گراف (GNN) برای پردازش و تجزیه و تحلیل داده‌های ساختار یافته گراف استفاده

¹ Hop

² Message Passing

می‌شود. ایده اساسی در ارسال پیام این است که گره‌ها در یک گراف با همسایگان خود برای تبادل اطلاعات ارتباط برقرار می‌کنند. در اینجا نحوه کار آن را بررسی می‌کنیم:

- مقداردهی اولیه: هر گره در گراف با یک نمایش اولیه دارد که اغلب بر اساس ویژگی‌ها یا ویژگی‌های آن است.
- ارسال پیام: در طی این مرحله، هر گره پیام‌هایی را به گره‌های مجاور خود ارسال و دریافت می‌کند. این پیام‌ها معمولاً شامل وضعیت یا ویژگی‌های فعلی گره می‌شوند که سپس به نحوی جمع می‌شوند (به عنوان مثال، جمع‌بندی، میانگین‌گیری یا العاق).
- تجمع: پس از جمع آوری پیام‌ها از همسایگان خود، هر گره نمایش خود را بر اساس اطلاعات جمع آوری شده به روز می‌کند. این به روز رسانی معمولاً با استفاده از یک شبکه عصبی یا سایر عملکردهای قابل یادگیری انجام می‌شود.
- تکرار: فرآیند ارسال پیام و تجمعی برای تعداد ثابتی از مراحل یا تا زمان همگرایی تکرار می‌شود. این کار این اجازه را می‌دهد تا اطلاعات در سراسر گراف منتشر شود و گره‌ها را قادر می‌سازد تا دانش را از گره‌های دورتر ترکیب کنند.
- نمایش نهایی: پس از چندین بار تکرار، نمایش گره نهایی اطلاعات مربوط به خود گره و همچنین ساختار و ویژگی‌های اطراف خود را جانمایی می‌کند. سپس می‌توان از این نمایش‌ها برای کارهای مختلفی مانند طبقه‌بندی گره، طبقه‌بندی گراف یا پیش‌بینی یال استفاده کرد.

ارسال پیام به GNN‌ها اجازه می‌دهد تا الگوها و وابستگی‌های پیچیده در داده‌های گراف را بیاموزند، و آن‌ها را به ابزارهای قدرتمندی برای طیف گسترده‌ای از مسائل، از جمله تجزیه و تحلیل شبکه‌های اجتماعی، شیمی مولکولی، سیستم‌های توصیه‌گر و غیره تبدیل می‌کند.

۲-۴-۲ GNN‌های زمانی

گراف‌های زمانی نشان دهنده روابط پویا بین موجودیت‌ها هستند و در بسیاری از مسئله‌های زندگی واقعی مانند شبکه‌های اجتماعی، تجارت الکترونیک، ارتباطات، شبکه‌های جاده‌ای، سیستم‌های بیولوژیکی و بسیاری موارد دیگر وجود دارند. گراف‌های ثابت^۱ به طور سنتی ساختارهای داده واقعی در بسیاری از مسائل دنیای واقعی مانند شبکه‌های اجتماعی، شبکه‌های بیولوژیکی، شبکه‌های کامپیوتی، شبکه‌های مسیریابی، شبکه‌های آب و هوای جغرافیایی، شبکه‌های تعاملی، شبکه‌های استنادی، شبکه‌های ترافیک و

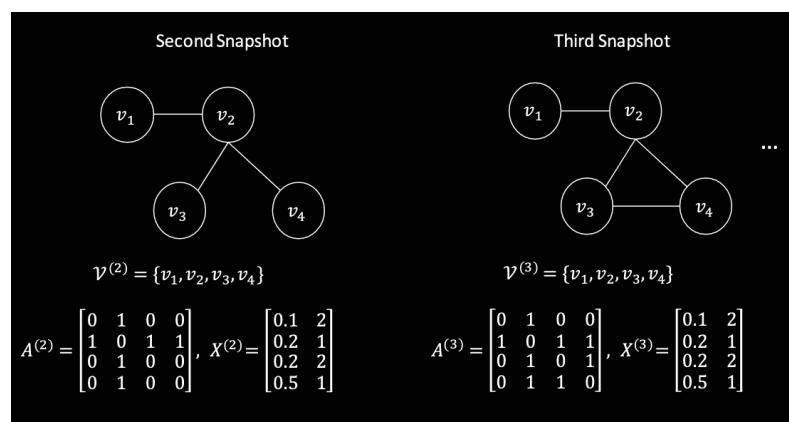
¹ Static

گراف‌های دانش^۱ بوده‌اند. این گراف‌ها برای نشان دادن روابط بین موجودیت‌های مختلف استفاده می‌شوند. مسائل اصلی مانند تشخیص جامعه، طبقه‌بندی^۲ گراف، طبقه‌بندی موجودیت، پیش‌بینی یال و بهینه‌سازی ترکیبی، حوزه‌های تحقیقاتی در این حوزه هستند. این وظایف در سیستم‌های توصیه‌گر [112]، تشخیص ناهنجاری [113]، بازیابی اطلاعات با استفاده از گراف دانش [114]، کشف دارو [115]، پیش‌بینی ترافیک [116]، پیش‌بینی رابط پروتئین [117] کاربرد دارند. علاوه بر این، موقوفیت‌های زیادی از نظر کیفیت و مقیاس پذیری توسط روش‌های مولد گراف به دست آمده است [118].

گراف‌های زمانی یک ساختار داده موثر برای نشان دادن روابط در حال تکامل بین موجودیت‌های مختلف در ابعاد زمانی هستند. با این حال، گراف‌های زمانی نه تنها برای توصیف پدیده‌ای که پیوندهای در حال تکامل را شبیه‌سازی می‌کند، بلکه فرآیند زیربنایی را که باعث اضافه یا حذف موجودیت از روابط می‌شود، استفاده می‌شود. علاوه بر این، گراف‌های زمانی همچنین نشان دهنده تکامل ویژگی‌های گره‌ها و یال‌ها در طول زمان هستند. یک گراف زمانی یا در فضای پیوسته یا فضای گستته نمایش داده می‌شود. در زیر بخش‌های زیر، تمایز بین این دو را شرح می‌دهیم.

۳-۴-۲- گراف زمانی گستته^۳

یک گراف زمانی زمان گستته (DTDG) یک دنباله $[G(t), G(1), \dots, G(2), G(0)]$ از تصاویر لحظه‌ای^۴ گراف است که هر کدام دارای رؤس V ، ماتریس مجاورت $A(t)$ و ماتریس ویژگی $X(t)$ هستند. گراف‌های زمانی زمان گستته عمدها در مسائلی ظاهر می‌شوند که در آن داده‌ها در فواصل زمانی منظم گرفته می‌شوند.



شکل ۳-۲-۱۰ سه تصویر لحظه‌ای از یک DTDG [119]

¹ Knowledge Graph

² Classification

³ Discrete Time Temporal Graph (DTDG)

⁴ Snapshot

شکل ۸-۲ دو تصویر لحظه‌ای از یک نمونه DTDG را نشان می‌دهد. در دومین تصویر لحظه‌ای، چهار گره وجود دارد. در تصویر لحظه‌ای بعدی، یک یال جدید بین گره ۳ و ۴ اضافه شده است. نوع خاصی از DTDG ها گراف‌های مکانی-زمانی هستند که در آن مجموعه‌ای از موجودیت‌ها به صورت مکانی (از نظر نزدیکی در فضا) و از نظر زمانی همبستگی دارند و داده‌ها در فواصل زمانی منظم گرفته می‌شوند. نمونه‌ای از چنین گراف‌های مکانی-زمانی، داده‌های ترافیکی در یک شهر یا منطقه‌ای است که در آن آمار ترافیک در هر جاده در فواصل زمانی منظم محاسبه می‌شود. ترافیک در یک جاده خاص در زمان t با ترافیک جاده‌های متصل به آن در زمان t (همبستگی مکانی) و همچنین ترافیک در این جاده‌ها و جاده‌های متصل به آن در تکه‌های زمانی قبلی (همبستگی زمانی) مرتبط است. در این مثال، گره‌های هر $G(t)$ نشان دهنده جاده‌ها (یا بخش‌های جاده)، ماتریس مجاورت ($A(t)$) نحوه اتصال جاده‌ها و ماتریس ویژگی $X(t)$ نشان دهنده آمار ترافیک در هر جاده در زمان t است.

۴-۴-۲- گراف زمانی پیوسته^۱

یک گراف زمانی پیوسته (CTDG) یک جفت $(G^{(t_0)}, O)$ است که در آن $= G^{(t_0)}$ یک گراف ایستا^۲ است که حالت اولیه را در زمان t_0 نشان می‌دهد و O دنباله‌ای از مشاهدات یا رویدادهای زمانی است. هر مشاهده یک تاپلی از شکل (نوع رویداد، رویداد، برچسب زمانی^۳) است که در آن نوع رویداد می‌تواند اضافه کردن یک گره یا لبه، حذف گره یا لبه، بهروز رسانی ویژگی گره وغیره باشد، رویداد نشان دهنده هدف نوع رویداد است که می‌تواند اسم دو گره انتخابی یا ویژگی برای یک یال یا گره باشد، و برچسب زمانی که رویداد در آن زمان رخ داده است. به عنوان مثال:

$O = [(add\ node,\ v4,\ 20-05-2020), (add\ edge,\ (v2,\ v4),\ 21-05-2020), (Featureupdate,\ (v1,\ [0.1,\ 2]),\ 28-05-2020), (add\ edge,\ (v3,\ v4),\ 04-06-2020)]$

یک DTDG را می‌توان به عنوان یک مورد خاص از یک CTDG مشاهده کرد که در آن فقط برخی از تصاویر لحظه‌ای با فاصله منظم از CTDG در دسترس هستند. چهار نوع مسئله برای گراف‌های زمانی وجود دارد: طبقه‌بندی یا رگرسیون گره، طبقه‌بندی گراف، پیش‌بینی یال و پیش‌بینی زمان. تعاریف مسئله‌های فوق برای دسته‌بندی یا رگرسیون گره، پیش‌بینی یال، و پیش‌بینی زمان مربوط به یک محیط انتقالی^۴ هستند که در زمان تست، باید پیش‌بینی‌ها برای

¹ Continuous Time Dynamic Graph (CTDG)

² Static

³ Timestamp

⁴ Transductive

موجودیت‌هایی که در طول آموزش مشاهده شده‌اند، انجام شود. در محیط استقرایی^۱، اطلاعات مربوط به موجودیت‌های جدید که قبلاً دیده نشده‌اند (یا گراف‌های کاملاً جدید) در زمان تست ارائه می‌شود و باید پیش‌بینی‌ها برای این موجودیت‌ها انجام شود [120]. طبقه‌بندی گراف به‌طور طبیعی استقرایی است زیرا نیاز به انجام پیش‌بینی برای گراف‌هایی که قبلاً در زمان تست دیده نشده‌اند، دارد.

۵-۴-۲- کاربرد GNN در علوم اعصاب

مغز یک شبکه است. مغز مجموعه‌ای از نورون‌های به هم پیوسته است که تعاملات آنها باعث شناخت می‌شود. بنابراین، استفاده از تکنیک‌های یادگیری ماشین مجهر به داده‌های شبکه‌ای یا گراف‌مانند، به عصب‌شناسان کمک می‌کند. ما می‌توانیم از GNN برای استخراج اطلاعات غنی از کانکتوم‌های^۲ آناتومیکی و عملکردی، استفاده کنیم. کاربردهای شبکه‌های عصبی گراف (GNN) در علوم اعصاب به دلیل توانایی آن‌ها در مدل‌سازی روابط و ساختارهای پیچیده در داده‌های عصبی توجه زیادی را به خود جلب کرده است. در اینجا مروری بر مسائل کاربردی و استفاده‌های GNN در آن مسائل می‌کنیم. درک رابطه ساختار و عملکرد مغز، به عنوان مثال، روابط بین اتصال ساختاری مغز^۳ (SC) و اتصال عملکردی^۴ (FC)، برای آشکار کردن اصول کارکرد مغز انسان حیاتی است. با این حال، حالت ساختار عملکرد چند به یک مغز، یعنی الگوهای عملکردی متنوع ممکن است با همان روابط بین اتصال ساختاری مغز مرتبط باشد، و تعاملات مستقیم و یا غیر مستقیم پیچیده در هر دو اتصال ساختاری و عملکردی، استنباط یک رابطه قابل اعتماد بین اتصال ساختاری مغز و اتصال عملکردی را به چالش می‌کشد. این نتیجه نشان می‌دهد که ممکن است یک قاعده مشترک بین ساختارهای ساختاری و عملکردی مغز در افراد مختلف وجود داشته باشد [121].

تحلیل اتصال عملکردی:

۱. مدل سازی شبکه مغز: GNN‌ها برای مدل سازی شبکه‌های اتصال عملکردی استفاده می‌شوند، جایی که نواحی مغز به عنوان گره و اتصالات عملکردی آن‌ها (به عنوان مثال، بر اساس داده‌های fMRI) به عنوان یال در نظر گرفته می‌شوند. این مدل‌ها می‌توانند تعاملات پویا بین مناطق مختلف مغز را در طول زمان به تصویر بکشند و بینشی در مورد عملکرد و سازماندهی مغز ارائه دهند [122].

۲. طبقه‌بندی و پیش‌بینی بیماری: با تجزیه و تحلیل تغییرات در اتصال به شبکه مغز،

¹ Inductive

² Connectome

³ Structural Connectivity

⁴ Functional Connectivity

می‌توان از GNN ها برای طبقه بندی و پیش‌بینی اختلالات عصبی و روانپزشکی، مانند بیماری آلزایمر، اسکیزوفرنی و اختلالات طیف اوتیسم استفاده کرد. توانایی شناسایی الگوهای اتصال غیرعادی می‌تواند به تشخیص زودهنگام و برنامه ریزی درمان کمک کند [123].

تجزیه و تحلیل شبکه ساختاری مغز:

۱. مطالعات توسعه عصبی: می‌توان از GNN ها برای مطالعه توسعه شبکه‌های ساختاری مغز در طول زمان استفاده کرد و به ترسیم مسیر طبیعی رشد مغز یا شناسایی انحرافات مرتبط با اختلالات رشد عصبی کمک کرد [124].

تجزیه و تحلیل تصاویر عصبی:

۱. طبقه بندی سیگنال‌های مغزی: در اینجا، گره‌ها حسگرها را نشان می‌دهند و یال‌ها را می‌توان بر اساس معیارهای عملکردی یا تشریحی تعریف کرد. GNN ها می‌توانند حالت‌های شناختی را طبقه بندی کنند، اختلال‌ها را تشخیص دهند یا الگوهای فعالیت مغز مرتبط با وظایف خاص را تجزیه و تحلیل کنند [125].

۲. مدل‌سازی پویا فضایی-زمانی: GNN ها به ویژه برای ثبت پویا مکانی-زمانی سیگنال‌های عصبی مفید هستند و به محققان این امکان را می‌دهند تا نحوه انتشار فعالیت مغز در مناطق مختلف در طول زمان را مدل کنند [125].

شبکه‌های عصبی گرافی ابزارهای قدرتمندی را برای کاوش و مدل‌سازی شبکه‌های پیچیده زیربنایی عملکرد و ساختار مغز ارائه می‌کنند. توانایی آن‌ها در مدیریت داده‌های به هم پیوسته و با ابعاد بالا، آن‌ها را به ویژه برای کاربردهای مختلف در علوم اعصاب، از درک مکانیسم‌های بیماری گرفته تا پیشرفت پژوهشی شخصی، مناسب می‌سازد. GNN ها در تحقیقات علوم اعصاب، فرصت‌های جدیدی را برای کشف اسرار مغز و بهبود نتایج بالینی باز می‌کند.

فصل ۳: مقدمات پژوهش

۱-۳- مقدمه

در این فصل، به مراحل مختلف جمع‌آوری و پیش‌پردازش داده‌ها، طراحی مدل و معیارهای ارزیابی پرداخته می‌شود. هدف اصلی از این فصل، ارائه روشی جامع برای آماده‌سازی داده‌های fNIRS جهت استفاده در مدل‌های یادگیری ماشین و شبکه‌های عصبی گراف زمانی (TGNN) است. در ابتدا، به نحوه جمع‌آوری داده‌های fNIRS اشاره خواهد شد و سپس فرآیندهای مختلف پیش‌پردازش مانند پاکسازی اولیه، حذف مصنوعات، و تکنیک‌های فیلترسازی سیگنال به تفصیل مورد بررسی قرار خواهد گرفت. روش‌های پیش‌پردازش پیشنهادی و روش مقاله‌پایه، مقایسه خواهد شد تا نقاط قوت و ضعف هر یک مشخص شود. همچنین، نرمال‌سازی داده‌ها به عنوان یکی از مراحل مهم در آماده‌سازی داده‌ها برای مدل‌سازی معرفی می‌شود. معیارهای مختلفی برای ارزیابی کیفیت سیگنال و تحلیل آماری استفاده شده که به صورت جزئیات بیشتری بررسی خواهد شد. در ادامه، به طراحی مدل شبکه‌های عصبی گراف زمانی (TGNN) پرداخته و معماری و جزئیات پیاده‌سازی آن ارائه می‌شود. در بخش پایانی، روش‌های ارزیابی عملکرد مدل‌ها مانند اعتبارسنجی متقابل و معیارهای سنجش دقت و کارایی مدل مورد بحث قرار خواهد گرفت. این فصل به عنوان یکی از بخش‌های کلیدی در پایان‌نامه، زیربنای اصلی برای تحلیل نتایج و توصیه‌های نهایی پژوهش فراهم می‌آورد.

۲-۳- جمع‌آوری داده‌ها

بیست و شش نفر برای آزمایش انتخاب شدند. همه شرکت کنندگان توسط بیمارستان دانشگاه ملی پوسان (بوسان، کره جنوبی) انتخاب شدند. افراد انتخاب شده شرایط زیر را داشتند: راست دست، قادر به برقراری ارتباط به زبان کره‌ای، سن مشابه، و سوابق تحصیلی مشابه. قبل از اندازه‌گیری‌های fNIRS، سلامت روان افراد با استفاده از معاینه وضعیت ذهنی کوچک کره‌ای^۱ (K-MMSE) [126]، انباره غربالگری عصبی روان‌شناختی سئول^۲ [۵۲] و تصویربرداری تشدید مغناطیسی (MRI) ارزیابی شد. هیئت بازبینی نهادی دانشگاه ملی پوسان پروتکل آزمایشی را تأیید کرد. قبل از انجام آزمایش، کل محتوای آزمایش برای همه افراد انتخاب شده توضیح داده شد و افراد انتخاب شده رضایت آگاهانه خود ارائه کردند.

¹ Korean mini-mental state examination

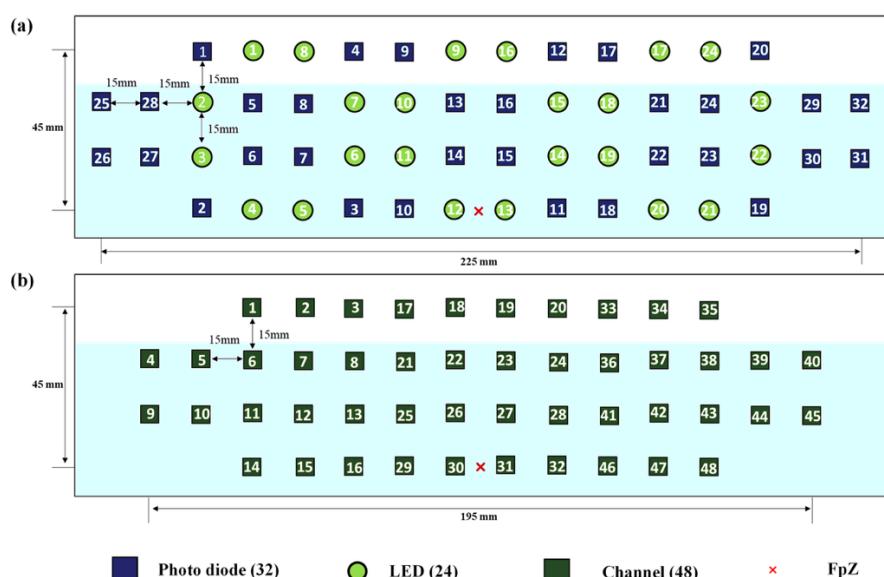
² Seoul Neuropsychological Screening Battery

۱-۲-۳- اطلاعات جمعیت‌شناختی

۱۵ بیمار MCI (یک مرد و چهارده زن) و یازده شرکت‌کننده HC همسان (سه مرد و هشت زن) انتخاب شدند. میانگین سن بیماران MCI (69.27 ± 7.09) و میانگین سن شرکت‌کننگان HC (68.33 ± 4.69) است. میانگین امتیاز تست K-MMSE بیماران MCI (25.13 ± 2.33) و شرکت‌کننگان HC (27.22 ± 1.98) است.

۲-۲-۳- اندازه گیری fNIRS

یک سیستم موج پیوسته NIRSIT چند کanalی (OBELAB Inc، کره جنوبی) با ۲۴ ساعط کننده و ۳۲ آشکارساز (شکل ۱-۳ a) برای اندازه گیری سیگنال‌های fNIRS با نرخ نمونه برداری 8.138 هرتز استفاده شد. طول موج مورد استفاده برای تشخیص ΔHbO و ΔHbR به ترتیب 780 و 850 نانومتر بود. فاصله بین سنسورهای نوری 15 میلی متر تعیین شد. در مجموع، 48 کanal به طور مساوی روی قشر جلوی مغز توزیع شدند. پیکربندی کanal در شکل نشان داده شده است، که مطابق با سیستم بین المللی EEG ۱۰-۲۰ با محل الکترود مرجع FpZ تنظیم شده است. هر کanal به عنوان یک جفت ساعط کننده - آشکارساز با فاصله 30 میلی متر تعریف شد (شکل ۱-۳ b). آزمایش در یک اتاق بسته برای جلوگیری از مزاحمت انجام شد. شرکت کننگان روی یک صندلی راحت نشسته بودند و از آن‌ها خواسته شد بدون حرکت غیر ضروری استراحت کنند. مدت زمان اندازه گیری حالت استراحت fNIRS برای هر شرکت‌کننده تقریباً 5 دقیقه بود.



شکل ۱-۳(۱) نحوه چینش ساعط کنندها، آشکارسازها و کanalها

۳-۳-۲- پیش پردازش داده ها

پیش پردازش داده ها یک مرحله مهم در تجزیه و تحلیل داده های fNIRS است که به طور قبلی توجهی بر کیفیت و قابلیت اطمینان نتایج تأثیر می گذارد. پیش پردازش مناسب نسبت سیگنال به نویز را افزایش می دهد، مصنوعات را حذف می کند و تضمین می کند که داده ها در فرمت بهینه برای تجزیه و تحلیل بیشتر با استفاده از مدل های یادگیری ماشینی مانند شبکه های عصبی گراف زمانی (TGNN) هستند. در این بخش، روش های به کار رفته در تمیز کردن اولیه، حذف مصنوعات، تکنیک های فیلتر سیگنال، نرمال سازی و معیار های ارزیابی سیگنال را مورد بحث قرار خواهیم داد.

۱-۳-۳- پاکسازی اولیه داده ها

در این مطالعه، تغییرات HbO و تغییرات HbR از چگالی نوری خام با استفاده از قانون بیر-لمبرت اصلاح شده به دست آمد. پس از اعمال قانون بیر-لمبرت اصلاح شده پاکسازی اولیه داده ها اعمال شد. پاکسازی اولیه داده ها یک بخش حیاتی از پیش پردازش است که برای اطمینان از دقت و اعتبار سیگنال های fNIRS انجام می شود. این مرحله شامل شناسایی و اصلاح نویزها و ناهنجاری ها در داده ها است تا تحلیل های بعدی به درستی انجام شود. دلایل و روش های انجام این مرحله عبارتند از:

۱. حذف داده های پرت ($\text{spike} > 1.8 * \text{var}$): در این مرحله، داده هایی که مقادیر آن ها به طور ناگهانی و غیرمعمول از محدوده نرمال فراتر رفته اند (یعنی مقادیر "لبه^۱" شناسایی و حذف می شوند. معیار حذف این داده ها این است که اگر مقدار داده ای بیش از ۱.۸ برابر انحراف معیار^۲ باشد، به عنوان نویز تلقی شده و حذف می شود. جهش های شدید یا لبه ها می توانند ناشی از حرکات ناگهانی سر، خطای دستگاه، یا تداخلات محیطی باشند. این نوسانات غیرمعمول می توانند باعث شوند نتایج تحلیل به سمت اشتباه بروند، زیرا این داده ها نمایانگر فعالیت واقعی مغز نیستند. حذف آن ها به بهبود نسبت سیگنال به نویز^۳ کمک می کند و داده ها را به واقعیت نزدیک تر می سازد.

۲. جایگزین کردن مقادیر پاک شده با میانگین ۵ ثانیه قبل و بعد: پس از شناسایی و حذف داده های نویزدار، به منظور پر کردن خلاه های ایجاد شده و حفظ پیوستگی سیگنال، مقادیر حذف شده با میانگین مقادیر پنج ثانیه قبل و بعد جایگزین می شوند. جایگزینی مقادیر به این روش باعث می شود که ساختار زمانی داده ها حفظ شود و از ایجاد گسستگی یا جهش های ناگهانی دیگر در سیگنال جلوگیری شود. این روش به حفظ یکپارچگی سیگنال کمک می کند و از انحرافات ناشی از داده های مفقود شده جلوگیری

¹ Spike

² Variance

³ Signal to Noise Ratio

می‌کند.

۳. حذف روندهای چندجمله‌ای^۱: داده‌های fNIRS و EEG اغلب حاوی روندها یا رانش‌هایی با فرکانس پایین به دلیل فرآیندهای فیزیولوژیکی (مانند تغییرات همودینامیک آهسته، تنفس) یا عوامل مرتبط با ابزار (مانند رانش خط پایه^۲ حسگر) هستند. Detrending این دریفت‌های آهسته را حذف می‌کند و به فیلتر گذر بلند اجازه می‌دهد تا بدون تداخل اجزای فرکانس پایین ناخواسته، روی بلندهای فرکانسی مربوطه تمرکز کند. در این مرحله، روندهای چندجمله‌ای^۳ از داده‌ها حذف می‌شوند. این روندها می‌توانند شامل تغییرات آهسته و طولانی‌مدت در سیگنال باشند که ارتباطی با فعالیت عصبی واقعی ندارند، مانند تغییرات دمای محیط، تغییرات در فشار پروب، یا اثرات فیزیولوژیکی کند. وجود این روندها می‌تواند باعث تغییر در سیگنال پایه شده و ارزیابی فعالیت‌های عصبی را دشوار کند. حذف روندهای طولانی‌مدت به تمرکز بر روی تغییرات کوتاه‌مدت و سریع‌تر که نشان‌دهنده فعالیت‌های مغزی هستند، کمک می‌کند. این کار باعث بهبود قابلیت تحلیل داده‌ها می‌شود و نتایج بهتری را در مدل‌های یادگیری ماشین به ارمغان می‌آورد.

پاک کردن داده‌ها با حذف داده‌های پرت (لبه‌ها) و کاهش روند قبل از اعمال فیلتر چندین مزیت مهم دارد که کیفیت و تفسیرپذیری تجزیه و تحلیل را بهبود می‌بخشد. پردازش و تمیز کردن داده‌ها از اعمال فیلتر دقت فیلتر را بهبود می‌بخشد. داده‌های پرت و روندها می‌توانند فرآیند فیلتر را مخدوش کنند و باعث می‌شوند فیلتر بیشتر به این ناهنجاری‌ها پاسخ دهد تا سیگنال واقعی. با حذف آنها، فیلتر می‌تواند اجزای فرکانس مورد نظر داده‌ها را با دقت بیشتری هدف قرار دهد. نقاط پرت می‌توانند باعث ایجاد مصنوعات یا نوسانات ناخواسته در داده‌های فیلتر شده شوند. تمیز کردن داده‌ها قبل از فیلتر کردن، عملکرد بهتر فیلتر را تضمین می‌کند. روندهای با فرکانس پایین می‌توانند باعث ایجاد مصنوعات فیلتر ناخواسته مانند موج دار شدن^۴ یا اثرات لبه شوند، به خصوص هنگام استفاده از فیلترهای حوزه زمان مانند IIR یا FIR. عدم تمايل قبل از فیلتر کردن به کاهش این مصنوعات کمک می‌کند و در نتیجه سیگنال فیلتر شده تمیزتری ایجاد می‌کند.

به طور کلی، تمیز کردن داده‌ها با حذف لبه‌ها و کاهش روند به دستیابی به سیگنال فیلتر شده دقیق تر و قابل تفسیرتر کمک می‌کند و در نتیجه کیفیت کلی فرآیند تجزیه و تحلیل داده‌ها را بهبود می‌بخشد. این مراحل پاکسازی اولیه به‌طور مؤثر ناهنجاری‌ها و نویزها را از داده‌های fNIRS حذف کرده و یک داده تمیز و یکپارچه را برای مراحل بعدی پیش‌پردازش فراهم می‌کنند.

¹ Poly detrend

² Baseline Drift

³ Poly

⁴ Ripple

۳-۲-۳- حذف مصنوعات حرکتی^۱

طیفسنجی مادون قرمز نزدیک عملکردی حالت استراحت (fNIRS) یک ابزار ارزشمند برای بررسی فعالیت خود به خودی مغز بدون تأثیرات مرتبط با کار است. یکی از مزایای کلیدی استفاده از داده‌های حالت استراحت این است که معمولاً در مقایسه با پارادایم‌های مبتنی بر وظیفه، مصنوعات حرکتی کمتری را شامل می‌شود، زیرا آزمودنی‌ها نیازی به انجام حرکات یا پاسخ به محرک‌ها ندارند. با این حال، حتی در شرایط استراحت، به دلیل حرکات جزئی سر، فعالیت ماهیچه‌ای، حرکات ظریف سر، حالات صورت، یا انقباضات غیرارادی عضلات می‌تواند باعث ایجاد مصنوعات حرکتی شود که سیگنال fNIRS را مخدوش می‌کند. این مصنوعات می‌توانند بر کیفیت داده‌ها تأثیر بگذارند و اگر به درستی مورد توجه قرار نگیرند منجر به نتیجه گیری‌های اشتباه می‌شوند.

برای حذف موثر این مصنوعات حرکتی باقیملنده، از روش تعمیر توزیع مشتق زمانی^۲ (TDDR) استفاده شد [127]. یک تکنیک قوی که به طور خاص برای شناسایی و تصحیح مصنوعات حرکتی در داده‌های fNIRS طراحی شده است و اطمینان حاصل می‌کند که سیگنال حاصل با دقت بیشتری فعالیت عصبی را منعکس کند. TDDR با شناسایی تغییرات سریع و گذرا در سیگنال fNIRS که مشخصه مصنوعات حرکتی است عمل می‌کند. طیفسنجی نزدیک به فروسرخ عملکردی (f) یک تکنیک تصویربرداری عصبی نوری است که برای اندازه‌گیری فعالیت قشر مغز استفاده می‌شود. در حالی که نسبت به fMRI حساسیت کمتری به مصنوعات حرکتی دارد، مصنوعات حرکتی همچنان چالش‌هایی را ایجاد می‌کنند، به ویژه در جمعیت‌هایی که مستعد حرکات سر هستند (مانند کودکان، افراد مبتلا به بیماری‌های عصبی). روش‌های موجود برای تصحیح حرکت در داده‌های fNIRS، مانند روش‌های مبتنی بر موجک^۳ و تجزیه و تحلیل مؤلفه‌های اصلی^۴ (PCA)، محدودیت‌هایی دارند، از جمله نیاز به پارامترها و مفروضات تعریف شده توسط کاربر که ممکن است در همه انواع داده‌ها وجود نداشته باشد.

یک روش اصلاح حرکت جدید برای fNIRS است که از یک رویکرد رگرسیون قوی برای شناسایی و تصحیح مصنوعات حرکتی بدون نیاز به پارامترهای ارائه شده توسط کاربر استفاده می‌کند. این روش با محاسبه مشتق زمانی سیگنال fNIRS برای برجسته کردن تغییرات سریع (نشان دهنده مصنوعات) کار می‌کند. این روش نقاط پرت را شناسایی می‌کند که به طور قابل توجهی از نوسانات فیزیولوژیکی طبیعی منحرف می‌شوند و به طور انتخابی این مصنوعات را با استفاده از توابع وزن دهی آماری قوی کاهش می‌دهد. در مقایسه با سایر تکنیک‌های تصحیح مانند tPCA، MARA، CBSI و

¹ Motion Artifact

² Temporal Derivative Distribution Repair

³ Wavelet

⁴ Principal component analysis (PCA)

TDDR نقشه‌های فعال سازی قابل اعتمادتر و گستردگر تری تولید می‌کند. TDDR به طور موثر هم تغییرات پایه^۱ و هم مصنوعات لبه را بدون معرفی پارامترها یا مفروضات اضافی حذف می‌کند، بر خلاف روش‌های دیگر که نیاز به تنظیم دستی پارامتر دارند یا در شرایط خاص شکست ناکارآمد می‌شوند. یکی از محدودیت‌های TDDR وابستگی آن به مشتق زمانی است که به اجزای فرکانس بالا حساس است. با این حال، این مشکل را می‌توان با فیلتر پایین گذر قبل از اعمال TDDR کاهش داد.

بنابراین الگوریتم TDDR را می‌توان به پنج مرحله تقسیم کرد:

مرحله ۱: برای زمان n ، تغییر در سیگنال fNIRS را می‌توان به صورت زیر محاسبه کرد:

$$(3-1) Dz(n) = z(n) - z(n-1)$$

که در آن D قبل از $z(n)$ مشتق زمانی سیگنال اندازه گیری شده در زمان n را نشان می‌دهد.

مرحله ۲: وزن مشاهده $w(n)$ ، مربوط به $Dz(n)$ ، با مقدار یک مقداردهی اولیه می‌شود.

مرحله ۳: وزن مشاهده به طور تطبیقی با استفاده از یک تخمین‌گر قوی، برآوردگر M وتابع دو وزنی

به روز می‌شود:^۲

$$(3-2) w(n) = \begin{cases} (1 - \sigma_s(n)^2)^2, & \sigma_s(n) < 1 \\ 0, & \text{otherwise} \end{cases}$$

$\sigma_s(n)$ نشان دهنده انحراف مقیاس شده در زمان n است. تخمین $\sigma_s(n)$ را می‌توان از میانگین وزنی نوسانات، باقیمانده مطلق مشتق زمانی، و مقیاس باقیمانده مطلق میانه برای توزیع نرمال به دست آورد. μ نشانگر میانگین وزنی نوسانات باشد، $res(n)$ نشانگر باقیمانده مطلق مشتقهای زمانی باشد، $\sigma(n)$ نشان دهنده مقیاس میانگین باقیمانده مطلق باشد. پس از آن می‌توانیم موارد زیر را بدست آوریم:

$$(3-3) \mu = \frac{1}{\sum_{i=1}^n w(i)} \sum_{i=1}^n w(i) Dz(i)$$

$$(3-4) res(n) = |Dz(n) - \mu|$$

$$(3-5) \sigma = 1.4826 \cdot \text{median}(res)$$

مراحل قبل تکرار شده و $\sigma_s(n) = \sigma(n)$ را تا زمانی که μ همگرا شود در نظر می‌گیریم.

مرحله ۴: مشتق زمانی فیلتر شده را می‌توان با استفاده از μ و $w(n)$ به دست آمده در مرحله ۳ به دست آورد.

$$(3-6) Dx(n) = w(n)(Dz(n) - \mu)$$

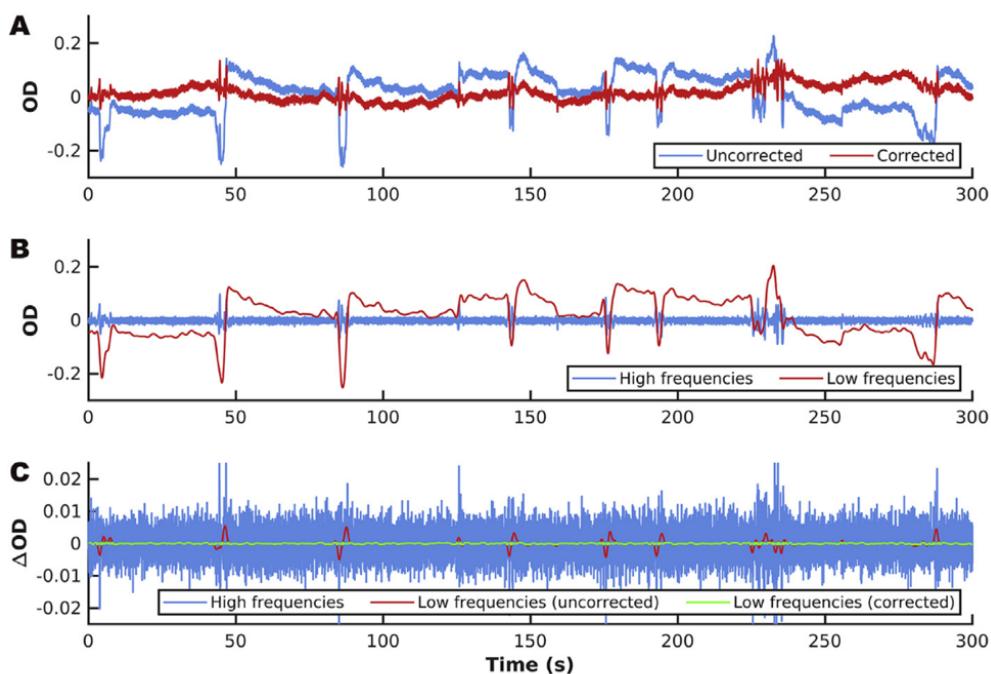
¹ Baseline Shift

² Tukey's biweight function

مرحله ۵: سیگنال نهایی فیلتر شده ادغام مشتقات زمانی تصحیح شده است.

$$(3-7)x(n) = \sum_{i=1}^n Dx(n)$$

۱. محاسبه مشتق زمانی: TDDR با محاسبه مشتق زمانی سری زمانی fNIRS آغاز می‌شود. این مرحله تشخیص تغییرات ناگهانی در سیگنال را افزایش می‌دهد که نشان‌دهنده مصنوعات حرکتی است.
۲. تحلیل توزیع: این روش سپس توزیع این مشتقات زمانی را برای شناسایی نقاط پرت که به طور قابل توجهی از محدوده مورد انتظار نوسانات فیزیولوژیکی انحراف دارند، تجزیه و تحلیل می‌کند. این نقاط پرت مربوط به بخش‌هایی از سیگنال هستند که احتمالاً تحت تأثیر حرکت قرار می‌گیرند.
۳. تشخیص و تعمیر مصنوعات: مصنوعات شناسایی شده با استفاده از رویکرد داده محور که سیگنال را در بخش‌های شناسایی شده تنظیم می‌کند، تصحیح می‌شوند. این فرآیند تعمیر شامل صاف کردن و کالیبراسیون مجدد سیگنال برای به حداقل رساندن تأثیر مصنوعات بدون به خطر اندختن یکپارچگی داده‌های عصبی زیرین است.
۴. بازسازی: مشتقات تمیز شده مجدداً در سیگنال اصلی ادغام می‌شوند، که منجر به یک سری زمانی اصلاح شده fNIRS می‌شود که فعالیت عصبی واقعی را حفظ می‌کند و در عین حال نویز ناشی از مصنوعات حرکتی را به حداقل می‌رساند.



شکل ۳-۲(a) اعمال TDDR روی داده‌های fNIRS

نمایش اثر TDDR بر سیگنال fNIRS جمع آوری شده از قشر جلوی مغز کودک را نشان داده می‌دهد. اجزای فرکانس بالا و پایین سیگنال تصحیح نشده در (B) نشان داده شده است. مشتق زمانی برای اجزای فرکانس بالا و پایین سیگنال تصحیح نشده و همچنین مشتق فرکانس پایین تصحیح شده در

(C) نشان داده شده است.

TDDR به طور خاص بخش‌هایی از داده را هدف قرار می‌دهد که توسط مصنوعات حرکتی تحت تأثیر قرار می‌گیرند (فرکانس‌های زیر ۰.۵ هرتز)، اطمینان حاصل می‌کند که فرآیند تعمیر داده‌های بدون مصنوع را تغییر نمی‌دهد (همانطور که در شکل (۲-۳) نشان داده شده است). این روش ساختار طبیعی سیگنال عصبی را حفظ می‌کند و آن را نسبت به تکنیک‌هایی که ممکن است داده‌ها را بیش از حد صاف یا مخدوش کند برتری می‌دهد. TDDR کاملاً خودکار است، نیاز به تنظیمات دستی را کاهش می‌دهد. استفاده از TDDR به طور موثری آثار حرکت باقیمانده را از داده‌های fNIRS در حالت استراحت حذف کرد و کیفیت کلی سیگنال را بهبود بخشدید. این بهبود امکان تجزیه و تحلیل قابل اعتمادتر و دقیق‌تر عملکرد مغز در حالت استراحت را فراهم کرد.

۳-۲-۱-۲- فیلتر کردن

طیف‌سنجی عملکردی مادون قرمز نزدیک (fNIRS) یک تکنیک تصویربرداری نوری غیر تهاجمی است که برای اندازه‌گیری فعالیت مغز با تشخیص تغییرات در اکسیژن‌رسانی خون و حجم خون استفاده می‌شود. به دلیل حساسیت آن به نویز فیزیولوژیکی، فیلتر کردن نقش مهمی در پیش پردازش داده‌های fNIRS برای افزایش کیفیت سیگنال و جداسازی فعالیت عصبی دارد. سیگنال‌های fNIRS اغلب توسط منابع مختلف نویز آلوده می‌شوند، از جمله:

- نویزهای فرکانس پایین: مانند رانش خط پایه، تنفس و نوسانات همودینامیک آهسته.
- نویزهای فرکانس بالا: از منابع خارجی، تجهیزات یا مصنوعات حرکت ناگهانی.
- تپش‌های قلبی: سیگنال‌های دوره‌ای که می‌توانند در تفسیر فعالیت عصبی اختلال ایجاد کنند.

برای استخراج سیگنال‌های عصبی معنادار، استفاده از فیلترهایی که بازه فرکانسی خاصی را هدف قرار می‌دهند، ضروری است. در این پایان‌نامه فیلتر کردن در بازه ۰.۱ تا ۰.۰۱ هرتز بر حذف نویز با فرکانس بالاتر و رانش‌های فرکانس بسیار پایین تمرکز دارد و پاسخ همودینامیک مرتبط با فعالیت مغز را جدا می‌کند. بازه ۰.۰۱ تا ۰.۱ هرتز مخصوصاً برای fNIRS مناسب است، زیرا محدوده فرکانسی را که در آن پاسخ همودینامیک برجسته‌تر است را ضبط می‌کند، پالس‌های قلبی (حدود ۱ هرتز) و آرتیفیکت‌های تنفسی (۰.۱ - ۰.۵ هرتز) را فیلتر می‌کند. برای فیلتر کردن داده‌ها در این مطالعه از نوع فیلتر FIR استفاده شده است.

فیلتر FIR نوعی فیلتر دیجیتالی است که در پردازش سیگنال استفاده می‌شود که با تعداد محدودی ضرایب کار می‌کند، به این معنی که پاسخ آن پس از تعداد معینی از نمونه‌های ورودی ثابت می‌شود. برخلاف فیلترهای دیگر، فیلترهای FIR از بازخورد خروجی‌های قبلی استفاده نمی‌کنند و ذاتاً پایدار

هستند. یکی از مزیت‌های کلیدی فیلترهای FIR توانایی آن‌ها در داشتن پاسخ فاز^۱ خطی است. این مشخصه باعث می‌شود که تمام اجزای سیگنال ورودی به یک میزان تاخیر داشته باشند. این ویژگی شکل و زمان سیگنال اصلی را حفظ می‌کند، که در مسائلی که یکپارچگی شکل موج مهم است، بسیار مهم است. فیلترهای FIR به دلیل عملکرد و پایداری قابل پیش‌بینی آن‌ها به طور گسترده مورد استفاده قرار می‌گیرند.

جدول ۱۳-۳) مقایسه دو نوع فیلتر FIR Hamming Window Filter و Butterworth Filter

ویژگی	FIR Hamming Window Filter	Butterworth Filter
نوع	Finite Impulse Response	Infinite Impulse Response
ثبات	به دلیل ضرایب محدود پایدار است.	به طراحی فیلتر بستگی دارد و می‌تواند ناپایدار شود.
فاز پاسخ	فاز خطی (تاخیر ثابت در تمام فرکانس‌ها).	فاز غیر خطی
پاسخ تکانه	متناهی؛ پاسخ فیلتر به سرعت حل می‌شود.	بی نهایت؛ پاسخ از نظر تئوری برای همیشه طول می‌کشد.
بار محاسباتی	به طور کلی زیاد	به طور معمول پایین تر
پارامترهای طراحی فیلتر	بر اساس مرتبه فیلتر، فرکانس‌های قطع و نوع پنجره تعریف می‌شود.	بر اساس مرتبه فیلتر، فرکانس‌های قطع و نوع فیلتر (پایین‌گذر، بالاگذر و غیره) تعریف می‌شود.
مورد استفاده	در کاربردهایی که نیاز به فاز خطی و پایداری دارند، مانند سیگنال‌های صوتی و زیست‌پزشکی، ترجیح داده می‌شود.	ترجیحاً هنگامی که فیلتر تیز با حداقل بار محاسباتی مورد نیاز است.

استفاده از پنجره Hamming به ایجاد فیلتری با ویژگی‌های فرکانس صاف تر، کاهش لوب‌های جانبی و به حداقل رساندن اعوجاج سیگنال فیلتر شده کمک می‌کند. این رویکرد به ویژه زمانی ارزشمند است که تعادل بین عملکرد و کارایی محاسباتی مورد نیاز باشد، و باعث می‌شود که فیلترهای FIR با پنجره‌های Hamming به طور گسترده در زمینه‌های مختلف از جمله پردازش سیگنال زیست‌پزشکی، ارتباطات و مهندسی صدا مورد استفاده قرار گیرند. در فیلتر کردن داده fNIRS، انتخاب فیلتر مناسب برای متعادل کردن یکپارچگی سیگنال و کاهش نویز ضروری است. فیلتر پنجره FIR Hamming به ویژه

¹ Phase Response

در کاربردهایی مانند fNIRS به دلیل پاسخ فاز خطی آن سودمند است و تضمین می‌کند که زمان و شکل سیگنال همودینامیک حفظ می‌شود. اگرچه از نظر محاسباتی سنگین‌تر است، اما توانایی فیلتر FIR برای حفظ پایداری و جلوگیری از اعوجاج فاز، آن را به انتخابی عالی برای تجزیه و تحلیل سیگنال‌های حوزه زمان در داده‌های fNIRS تبدیل می‌کند. از سوی دیگر، فیلتر Butterworth یک جایگزین محاسباتی کارآمد را ارائه می‌دهد.

۳-۳-۳- نرمال سازی

پس از اعمال TDDR و فیلتر میان‌گذر روی مجموعه داده، نرمال‌سازی برای استانداردسازی داده‌ها در همه کanal‌ها انجام شد. نرمال‌سازی یک مرحله پیش‌پردازش حیاتی در آموزش شبکه‌های عصبی است زیرا اطمینان حاصل می‌کند که داده‌های ورودی در محدوده‌ی ثابتی قرار می‌گیرند، که در نتیجه ثبات و عملکرد شبکه بهبود می‌یابد. در این مطالعه، هر کanal داده به صورت جداگانه بر اساس حداکثر مقدار مطلق آن نرمال‌سازی شده و با افزودن یک حاشیه برای در نظر گرفتن تغییرات احتمالی در داده‌های آینده، انجام شد. به‌طور خاص، نرمال‌سازی با استفاده از فرمول زیر صورت گرفت:

$$\frac{X_i}{\max(|X_i|) + 0.1 \times \max(|X_i|)} = X'_i \quad (8-3)$$

که در آن:

X'_i نشان‌دهنده مقادیر نرمال شده داده برای کanal (i) است.

$|X_i|$ نشان‌دهنده مقادیر داده برای کanal (i) است.

$\max(|X_i|)$ حداکثر مقدار مطلق داده در کanal (i) است.

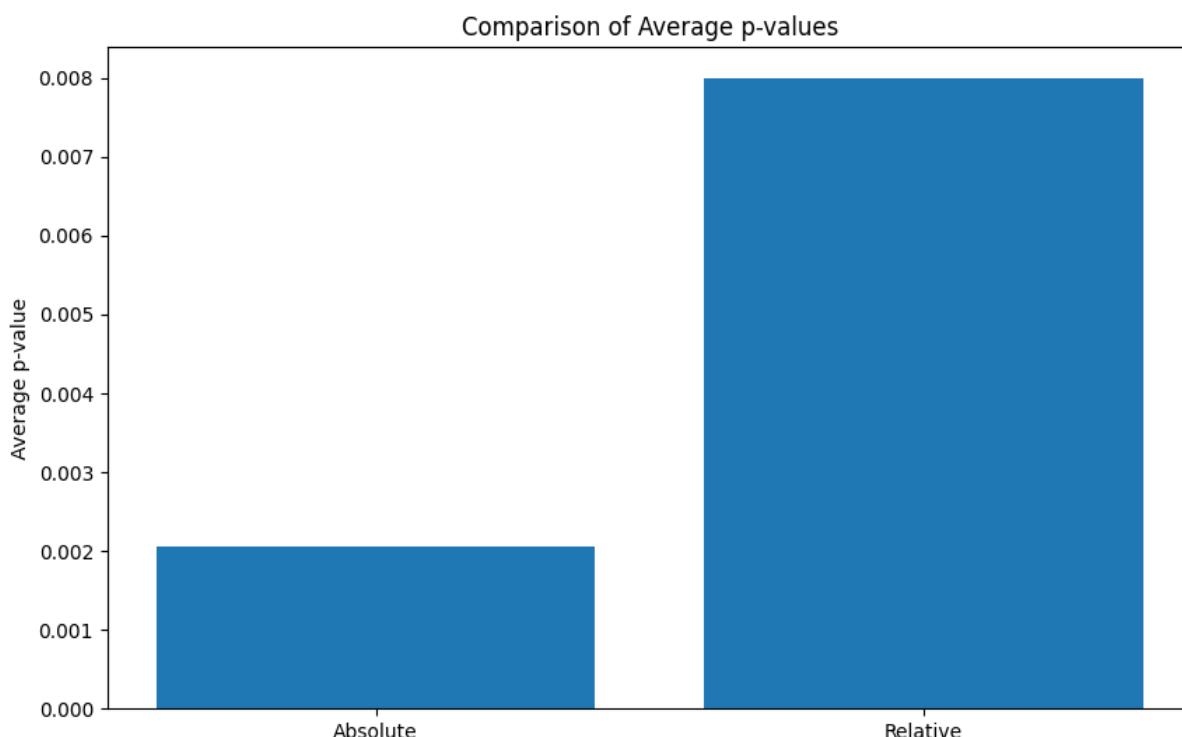
عبارت $(|X_i| + 0.1 \times \max(|X_i|))$ معادل ۱۰٪ از حداکثر مقدار مطلق به عنوان یک حاشیه اضافی اضافه می‌کند.

این روش برای اطمینان از مقاومت شبکه در برابر داده‌های جدیدی که ممکن است حاوی مقادیر کمی بالاتر باشند، انتخاب شده است. تصمیم به افزودن ۱۰٪ از حداکثر مقدار مطلق با هدف افزایش مقاومت شبکه در برابر داده‌های ورودی جدید اتخاذ شد. این استراتژی به حفظ توانایی تعمیم‌دهی شبکه کمک می‌کند و عملکرد پایدار آن را در برابر داده‌های موجود و تازه معرفی‌شده تضمین می‌کند. با نرمال‌سازی بر اساس این مقدار حداکثری اصلاح شده، مجموعه داده در محدوده‌ای امن باقی می‌ماند و خطرات ناشی از داده‌های غیرمعمول یا توزیع‌های دیده‌نشده که ممکن است اثربخشی مدل را مختل کنند، به حداقل می‌رسد. بنابراین، این روش نرمال‌سازی نه تنها داده‌ها را برای آموزش بهینه شبکه استاندارد می‌کند، بلکه مدل را در برابر اضافه کردن داده‌های جدید تا حدودی مقاوم می‌سازد.

برای ارزیابی تأثیر تکنیک‌های مختلف عادی سازی بر استحکام مدل و اهمیت آماری، دو روش مورد

بررسی قرار گرفت:

۱. نرمال‌سازی مطلق: با تقسیم داده‌ها با حداکثر مقدار مطلق هر کنال خاص $+ 10\%$ از حداکثر مقدار مطلق هر کانال با هدف افزایش مقاومت شبکه در برابر داده‌های ورودی جدید، هر کانال را به طور مستقل نرمال‌سازی کردیم.
۲. نرمال‌سازی نسبی: تمام داده‌ها را با حداکثر مقدار مطلق محاسبه شده در تمام کانال‌ها و کلیه بیماران نرمال‌سازی کردیم.



شکل (۳-۳) مقایسه دو روش نرمال‌سازی

مقایسه بین این دو روش، که در شکل (۳-۳) نشان داده شده است، تفاوت قابل توجهی در تأثیر آن‌ها بر خصوصیات آماری داده‌ها نشان می‌دهد. برای ارزیابی تأثیر تکنیک‌های مختلف نرمال‌سازی در تمایز بیماران مبتلا به اختلال شناختی خفیف (MCI) از کنترل سالم (HC)، دو روش با استفاده از آزمون من ویتنی^۱ ارزیابی شدند. این آزمون به میانگین حداکثر و حداقل مقادیر داده‌ها اعمال شد تا تعیین کند که کدام روش نرمال‌سازی بین دو گروه تفاوت بیشتری ایجاد می‌کند. نتایج نشان می‌دهد که نرمال‌سازی "مطلق" به طور قابل توجهی تمایز بیشتری را بین دو گروه بوجود آورده است.

این یافته‌ها بر اهمیت انتخاب یک استراتژی نرمال‌سازی مناسب تأکید می‌کند که نه تنها داده‌ها را در یک بازه مشخص قرار می‌دهد، بلکه توانایی مدل را در شناسایی تفاوت‌های مهم بین گروه‌های بالینی افزایش می‌دهد.

¹ Mann–Whitney U test

۳-۴-۳- روش پیش پردازش مقاله پایه

در مقاله پایه [128]، ΔHbO و ΔHbR از چگالی نوری خام با استفاده از قانون Bear-Lambert اصلاح شده به دست آمد. یک فیلتر مرتبه چهارم Butterworth با فرکانس قطع ۰.۱۵-۰.۱۸ هرتز برای حذف ضربان قلب (~ ۰.۱۱ هرتز)، تنفس (~ ۰.۲۵ هرتز) و سایر نویزهای فیزیولوژیکی اعمال شد. علاوه بر این، از یک الگوریتم کاهش روند برای حذف تغییرات در خط مبنا استفاده شد. پس از عبور سیگنال از فیلتر، کانال‌های نویز دار را نیز با نوسان غیر طبیعی آشکار، به صورت دستی بررسی و حذف شد.

۳-۴-۴- ویژگی‌های بررسی شده

در این مطالعه، ما از مجموعه‌ای جامع از ویژگی‌ها که برای تجزیه و تحلیل داده‌های طیف سنجی مادون قرمز نزدیک (fNIRS) با هدف شناسایی تفاوت‌های قابل توجه بین گروه‌های اختلال شناختی خفیف (MCI) و کنترل سالم (HC) در حالت استراحت استفاده کردیم. مجموعه ویژگی‌های ما هم معیارهای اتصال عملکردی و هم ویژگی‌های سیگنال را در بر می‌گیرد و یک رویکرد چندوجهی برای توصیف الگوهای فعالیت مغز ارائه می‌کند.

ما از چندین معیار اتصال عملکردی برای تعیین کمیت روابط بین مناطق مختلف مغز استفاده کردیم:

- کوواریانس^۱: تغییرپذیری مشترک دو کانال را لندازه گیری می‌کند و نشان می‌دهد که چگونه تغییرات در یک کانال با تغییرات در کانال دیگر ارتباط دارد.
- همبستگی پیرسون^۲: همبستگی خطی بین دو کانال را از ۱-تا ۱ تعیین می‌کند. قدرت و جهت رابطه خطی بین دو متغیر را لندازه گیری می‌کند. میزان ارتباط خطی بین نواحی مغز را تعیین می‌کند.
- همبستگی اسپیرمن^۳: روابط یکنواخت بین دو متغیر را ارزیابی می‌کند. زمانی مفید است که رابطه بین سیگنال‌ها غیر خطی باشد اما همچنان یکنواخت باشد. ممکن است روابط ظرفیتی را به تصویر بکشد که همبستگی پیرسون قادر به تشخیص آن‌ها نیست.
- ضریب همبستگی کندال^۴: یکی دیگر از معیارهای همبستگی مبتنی بر رتبه، که نسبت به همبستگی پیرسون حساسیت کمتری نسبت به موارد پرت دارد. نسبت به پیرسون

¹ Covariance

² Pearson Correlation

³ Spearman Correlation

⁴ Kendall's Tau

حساسیت کمتری نسبت به موارد دورافتاده دارد. می‌تواند الگوهای ثابتی از ترتیب فعال سازی را در سراسر مناطق مغز نشان دهد.

- همبستگی فاصله^۱: ارتباط خطی و غیرخطی بین کانال‌ها را اندازه‌گیری می‌کند و می‌تواند طیف وسیع‌تری از واپستگی‌ها را تشخیص دهد. ارتباط خطی و غیرخطی بین متغیرها را اندازه‌گیری می‌کند. طیف وسیع‌تری از واپستگی‌ها را بین مناطق مغز ثبت می‌کند. ممکن است فعل و انفعالات پیچیده‌ای را که معیارهای ساده‌تر از دست می‌دهند، آشکار کند.
- شاخص تأخیر فاز^۲ (PLI): عدم تقارن توزیع اختلاف فاز بین دو سیگنال را تعیین می‌کند که اثرات رسانایی قوی نسبت به حجم دارد. عدم تقارن توزیع اختلاف فاز بین دو سیگنال را کمی می‌کند. می‌تواند تفاوت‌هایی را در زمان بندی و هماهنگی فعالیت مغز نشان دهد.
- همدوسی^۳: همبستگی طیفی بین دو سیگنال را اندازه‌گیری می‌کند و اطلاعاتی در مورد روابط فرکانس خاص ارائه می‌دهد. اطلاعاتی در مورد روابط فرکانس خاص ارائه می‌دهد. ممکن است تفاوت‌هایی را در گروههای فرکانسی خاص فعالیت مغز نشان دهد.
- همبستگی متقابل^۴: شباهت دو سری زمانی را به عنوان تابعی از جابجایی یکی نسبت به دیگری ارزیابی می‌کند. می‌تواند روابط زمانی و تأخیر بین نواحی مغز را آشکار کند. می‌تواند تفاوت‌هایی را در زمان و ترتیب فعالیت‌های مغز نشان دهد.
- مقدار قفل فاز^۵ (PLV): ثبات اختلاف فاز بین دو سیگنال را در طول زمان تعیین می‌کند. میزان هماهنگی فازهای دو سیگنال را اندازه‌گیری می‌کند. ممکن است تفاوت‌هایی را در پایداری روابط فاز بین مناطق مغز نشان دهد.
- پیچش زمانی پویا^۶ (DTW): تکنیک محاسباتی قدرتمند است که برای اندازه‌گیری شباهت بین دو سری زمانی که ممکن است از نظر سرعت یا زمان متفاوت باشند، استفاده می‌شود. در زمینه داده‌های طیف‌سنجی مادون قرمز نزدیک به‌ویژه ارزشمند است زیرا نقاط داده سری زمانی را به‌طور غیرخطی همتراز می‌کند و به آن اجزا می‌دهد سیگنال‌هایی را که ممکن است در زمان کاملاً مطابقت نداشته باشند به طور مؤثر مقایسه کند.
- در حالی که معیارهای اتصال بر روابط بین کانال‌ها تمرکز می‌کنند، ویژگی‌های سیگنال اطلاعات ارزشمندی در مورد ویژگی‌های سیگنال‌های fNIRS فردی ارائه می‌دهند. این ویژگی‌ها می‌توانند

¹ Distance Correlation

² Phase Lag Index

³ Coherence

⁴ Cross-correlation

⁵ Phase Locking Value

⁶ Dynamic Time Warping (DTW)

- ویژگی‌های زمانی و طیفی فعالیت مغز را به تصویر بکشند:
- حداقل^۱ و حداکثر^۲: کمترین و بالاترین مقدار در سیگنال را نشان می‌دهد. محدوده تغییرات همودینامیک را نشان می‌دهد. می‌تواند تفاوت‌هایی را در میزان فعال یا غیرفعال شدن مغز آشکار کند.
 - کشیدگی^۳: توصیف کننده میزان قله‌ای بودن و مسطح بودن یک توزیع احتمالی است. هرچقدر شکل تابع چگالی احتمال قله‌ای تر و دارای دم پهن‌تر یا دنباله پهن‌تر باشد میزان شاخص کشیدگی برای آن بیشتر است. نشان دهنده وجود مقادیر شدید در سیگنال است. ممکن است تفاوت‌هایی را در وقوع رویدادهای فعال سازی شدید نشان دهد.
 - چولگی^۴: عدم تقارن توزیع احتمال سیگنال را کمی می‌کند. نشان دهنده میزان عدم تقارن توزیع احتمالی است. اگر داده‌ها نسبت به میانگین متقارن باشند، چولگی برابر صفر خواهد بود. چولگی می‌تواند سوگیری نسبت به فعال سازی یا غیرفعال سازی را در گروه‌های مختلف نشان دهد.
 - میانگین^۵: نشان دهنده مقدار متوسط سیگنال است. نشان دهنده سطح کلی فعال سازی است. ممکن است تفاوت‌هایی را در سطوح فعال سازی نشان دهد.
 - انحراف استاندارد^۶: میزان تغییرات یا پراکندگی سیگنال را اندازه گیری می‌کند. نشان دهنده تنوع فعالیت مغز است. می‌تواند تفاوت‌هایی را در ثبات یا تنوع فعال سازی مغز نشان دهد.
 - شب^۷: روند کلی سیگنال را در طول زمان ثبت می‌کند. نشان می‌دهد که آیا تمایلی برای افزایش یا کاهش فعال سازی در طول دوره اندازه گیری وجود دارد. ممکن است تفاوت‌هایی را در نحوه فعالیت مغز در طول زمان آشکار کند.
 - ضرایب موجک^۸: نمایش فرکانس زمانی سیگنال را ارائه می‌کند و اطلاعات زمانی و طیفی را در مقیاس‌های چندگانه می‌گیرد. می‌تواند تفاوت‌هایی را در الگوهای فرکانس زمانی خاص فعالیت مغز نشان دهد.

¹ Min² Max³ Kurtosis⁴ Skewness⁵ Mean⁶ Standard Deviation⁷ Slope⁸ Wavelet Coefficients

با ترکیب این معیارهای اتصال عملکردی و ویژگی‌های سیگنال، هدف ما توصیف جامع داده‌های fNIRS و شناسایی ویژگی‌هایی است که تفاوت‌های قابل توجهی را بین گروه‌های MCI و HC در حالت استراحت نشان می‌دهند. این رویکرد به ما اجازه می‌دهد تا جنبه‌های مختلف فعالیت و اتصال مغز را بررسی کنیم، که به طور بالقوه تغییرات ظریف در عملکرد مغز مرتبط با اختلال شناختی خفیف را آشکار می‌کند.

در ادامه ما قدرت تمایز این ویژگی‌ها را ارزیابی خواهیم کرد تا مشخص کنیم کدام یک در تمایز بین گروه‌های MCI و HC مؤثر هستند. این اطلاعات نه تنها به درک ما از همبستگی‌های عصبی MCI کمک می‌کند، بلکه به طور بالقوه توسعه نشانگرهای زیستی را برای تشخیص زودهنگام و نظارت بر زوال شناختی نشان می‌دهد.

۳-۱-۴- انتخاب ویژگی‌ها

انتخاب ویژگی گامی حیاتی در تجزیه و تحلیل داده‌های fNIRS است، به ویژه هنگام تمایز بین گروه‌های MCI (اختلال شناختی خفیف) و HC (کنترل سالم). برای افزایش دقت طبقه بندی و کارایی مدل، از هر دو ویژگی گره و لبه در نمایش گرافی داده‌ها استفاده کردیم. این بخش روش بکار گرفته شده برای انتخاب ویژگی، تمرکز بر ساخت گراف‌های ایستا، استخراج ویژگی، و کاربرد XGBoost و آزمون‌های آماری برای شناسایی مهم ترین ویژگی‌ها را توضیح می‌دهد. در ابتدا، گراف‌های ایستا برای هر بیمار بر اساس فواصل پنج دقیقه‌ای ضبط fNIRS ساخته شد. هر گراف نشان دهنده ارتباط کلی عصبی در این بازه زمانی است و الگوهای اتصال عملکردی منحصر به فرد افراد MCI و HC را در بر می‌گیرد. ساختار گراف شامل تعریف گره‌ها و یال‌ها است، جایی که گره‌ها کانال‌های fNIRS را نشان می‌دهند و یال‌ها اتصال عملکردی بین این گره‌ها را نشان می‌دهند. ویژگی‌های گره‌ها و یال‌ها استفاده شده برای ساخت گراف که برای انتخاب ویژگی ساخته شدند به شکل زیر است:

- ویژگی‌های گره (ویژگی‌های سیگنال): به هر گره در گراف، ویژگی‌های سیگنالی که مستقیماً

از داده‌های سری زمانی fNIRS مشتق شده بودند، اختصاص داده شد. این ویژگی‌ها شامل معیارهایی مانند حداکثر، حداقل، کشیدگی، چولگی، میانگین، شیب، ضرایب موجک و انحراف استاندارد سیگنال که در بازه زمانی مشخص شده محاسبه شده‌اند، است. این ویژگی‌ها نمایشی از سطح فعالیت و تنوع در هر گره را ارائه می‌دهند و به عنوان شاخص‌های عملکرد مغز در مناطقی که کانال‌های دستگاه قرار گرفته‌اند، عمل می‌کنند.

- ویژگی‌های یال (ویژگی‌های اتصال عملکردی): یال‌های گراف بر اساس معیارهای اتصال

عملکردی که تعاملات بین مناطق مختلف مغز را نشان می‌دهد وزن‌گذاری شدند. چندین معیار اتصال برای تعیین کمیت این تعاملات مورد استفاده قرار گرفت، از جمله کوواریانس، همبستگی پیرسون، همبستگی متقابل، شاخص تاخیر فاز (PLI) و

پیچش زمانی پویا (DTW). این ویژگی‌ها در مجموع انسجام زمانی و مکانی بین کانال‌های fNIRS را توصیف می‌کنند، بنابراین ساختار کلی شبکه مغز را در طول دوره ضبط منعکس می‌کنند.

هنگامی که گراف‌های ثابت ساخته شدند، گام بعدی شناسایی ویژگی‌هایی بود که به طور موثر بین گروه‌های MCI و HC متمايز است. برای این منظور از XGBoost، یک الگوریتم یادگیری ماشینی قدرتمند و کارآمد، استفاده شد. XGBoost به دلیل توانایی در مدیریت تعاملات پیچیده بین ویژگی‌ها از طریق درخت‌های تصمیم‌گیری افزایش گرددیان، به طور گسترده به دلیل عملکرد بالای خود در وظایف طبقه‌بندی، به ویژه با داده‌های ساختاریافته، شناخته شده است.

ما از XGBoost برای طبقه‌بندی گروه‌های MCI و HC بر اساس گراف‌های ساخته شده استفاده کردیم. این مدل با استفاده از ویژگی‌های گره (سیگنال) و ویژگی‌های یال (اتصال عملکردی) آموزش داده شد. فرآیند آموزش شامل یادگیری الگوها و روابط ذاتی در داده‌ها است که MCI را از HC متمايز می‌کند، بنابراین کار طبقه‌بندی را بهینه می‌کند. یک مزیت مهم XGBoost توانایی آن در ارائه بینش در مورد اهمیت ویژگی است که از وزن‌های اختصاص داده شده به ویژگی‌ها در طول فرآیند آموزش مدل مشتق شده است. امتیازهای اهمیت نشان می‌دهد که هر ویژگی چقدر به فرآیند تصمیم‌گیری مدل کمک می‌کند و امکان شناسایی متمايزترین ویژگی‌ها را فراهم می‌کند. این ویژگی‌ها به دلیل سهم بالایی که در کار طبقه‌بندی داشتنند، به عنوان ویژگی‌های یال کلیدی انتخاب شدند.

برای تقویت طبقه‌بندی بین MCI و افراد سالم، ما برای انتخاب ویژگی‌های عملکردی از XGBoost و برای ویژگی‌های سیگنال از آزمون من ویتنی استفاده کردیم. این رویکرد ما را قادر می‌سازد تا به طور سیستماتیک ویژگی‌های کلیدی را که سیگنال‌های fNIRS را مشخص می‌کنند، شناسایی کنیم، و بین ویژگی‌های عملکردی و مبتنی بر سیگنال تمایز قائل شویم. ویژگی‌های استخراج شده به دو نوع اصلی طبقه‌بندی می‌شوند:

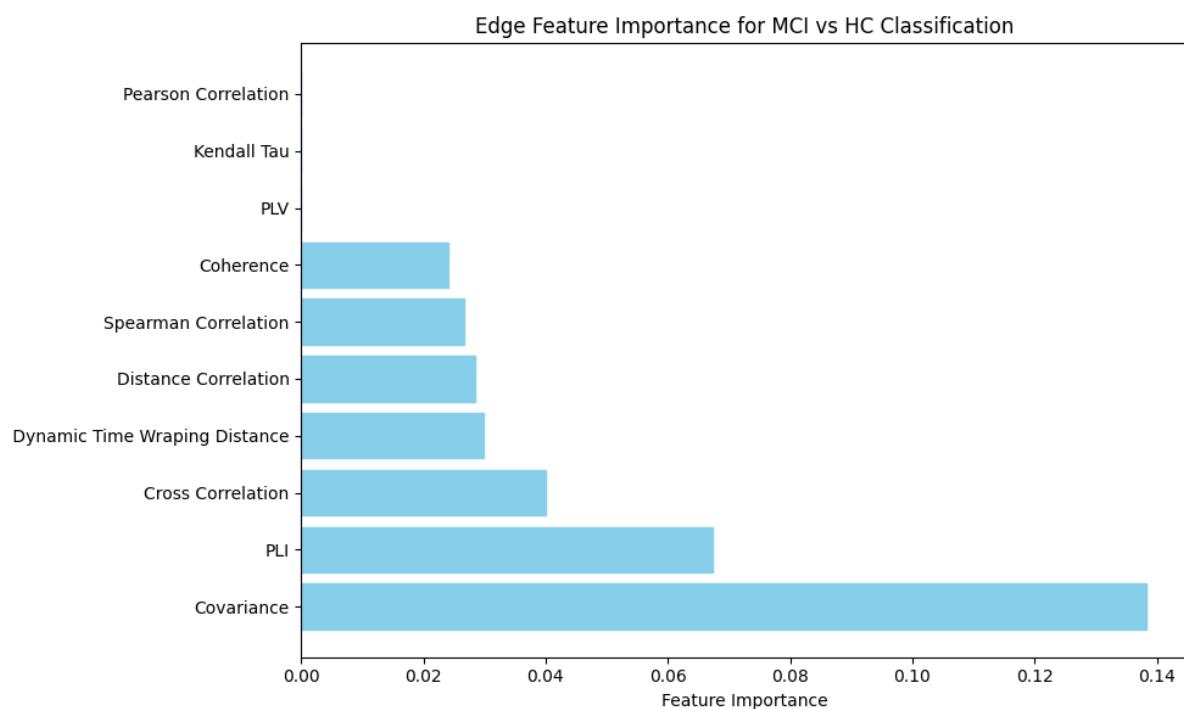
۱. ویژگی‌های عملکردی: این ویژگی‌ها روابط زیربنایی بین اجزای سیگنال مختلف را به تصویر می‌کشد که منعکس کننده اتصال عصبی و الگوهای تعامل است. ویژگی‌های عملکردی انتخاب شده با استفاده از وزن‌دهی XGBoost که در شکل ۳-۴ مشخص شده‌اند شامل موارد زیر هستند:

- کوواریانس: تغییرپذیری مشترک بین دو کانال را کمی می‌کند، نشان می‌دهد که چگونه

تغییرات سیگنال در یک منطقه با تغییرات در منطقه دیگر مرتبط است، و قدرت اتصال را به تصویر می‌کشد.

- شاخص تاخیر فاز (PLI): سازگاری تفاوت‌های فاز بین سیگنال‌ها را اندازه‌گیری می‌کند، برهمکنش‌های جهتی را برجسته می‌کند و همگام‌سازی نوسان‌های عصبی، که به ویژه برای تشخیص الگوهای ارتباطی تغییر یافته در MCI مرتبط است.

- همبستگی متقابل: روابط تاخیر زمانی بین سیگنال‌ها را ارزیابی می‌کند، شناسایی می‌کند که چگونه تغییرات در یک سیگنال، تغییرات در سیگنال دیگر را در طول زمان‌های مختلف پیش‌بینی می‌کند، بنابراین وابستگی‌های جهتی بین مناطق را آشکار می‌کند.
 - فاصله زمانی پویا (DTW): شباهت بین داده‌های سری زمانی را با اندازه‌گیری همترازی بهینه بین سیگنال‌ها، ثبت تغییرات زمانی غیرخطی و تغییرات زمان‌بندی سیگنال، که در انعکاس حالات عملکردی پویایی مغز حیاتی هستند، ارزیابی می‌کند.
 - ویژگی‌های اتصال عملکردی انتخاب شده نه تنها عملکرد مدل طبقه‌بندی را افزایش می‌دهد، بلکه بینش ارزشمندی را در مورد مکانیسم‌های عصبی زیربنا MCI ارائه می‌دهد. با انتخاب این ویژگی‌ها، ما اطمینان حاصل کردیم که مدل بر مرتبطترین جنبه‌های اتصال مغزی تمرکز دارد که MCI را از HC متمایز می‌کند. این رویکرد هدفمند نه تنها دقت طبقه‌بندی را بهبود می‌بخشد، بلکه در ک عمیق تری از تغییرات در پویایی شبکه مغز مرتبط با زوال شناختی را نیز ارائه می‌دهد.
۲. ویژگی‌های سیگنال: این ویژگی‌ها از ویژگی‌های سیگنال فردی مشتق شده‌اند که منعکس کننده ویژگی‌های آماری پاسخ‌های همودینامیک هستند.
- ویژگی‌های سیگنال انتخاب شده شامل:
- حداکثر: نشان دهنده دامنه پیک سیگنال، نشان دهنده بالاترین سطح فعال سازی است.
 - حداقل: منعکس کننده کمترین دامنه سیگنال، ارائه یک معیار پایه فعال سازی.
 - انحراف استاندارد: اندازه گیری تغییرپذیری سیگنال‌ها، برای درک ثبات فعالیت عصبی بسیار مهم است.

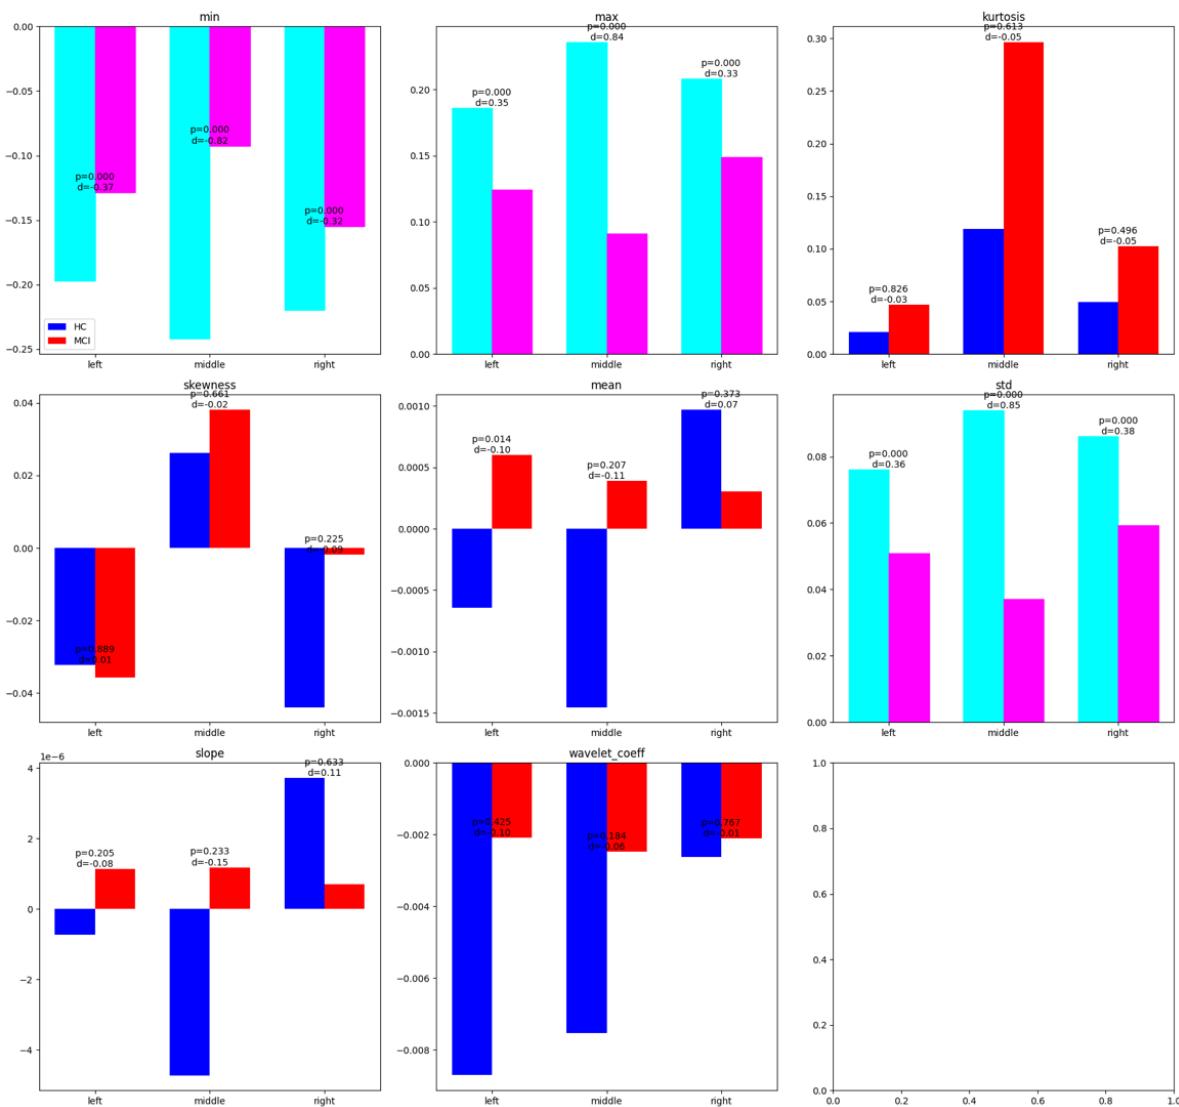


شکل (۴-۳) وزن‌های داده شده به ویژگی‌های عملکردی باستفاده از XGBoost

همانطور که در شکل (۳-۵) نشان داده شده است، آزمون من ویتنی برای اعتبار آماری اهمیت ویژگی‌های سیگنال، برای اطمینان از اینکه فقط متمایزترین ویژگی‌ها انتخاب شوند، انجام شد. در شکل (۳-۵) ویژگی‌هایی که دارای p -value کمتر از $1 \cdot 10^{-5}$ سطح با معنایی^۱ هستند به عنوان ویژگی‌های متمایز کننده دو گروه (در شکل رنگ روشن به خود گرفته اند) انتخاب شدند. همانطور که در شکل (۳-۴) نشان داده شده است با توجه به وزن‌های داده شده به ویژگی‌های عملکردی توسط XGBoost کوواریانس، شاخص تأخیر فاز، فاصله زمانی پویا و همبستگی متقابل را به عنوان ویژگی‌های عملکردی اولیه برجسته کرد، در حالی که حداقل، حداقل و انحراف استاندارد به عنوان ویژگی‌های کلیدی سیگنال شناسایی شدند. تجزیه و تحلیل نشان داد که ویژگی‌های خاص مربوط به HbR، تفاوت معنی‌داری را بین گروه‌ها نشان داد. این یافته بر اهمیت گنجاندن سیگنال‌های HbO و HbR برای گرفتن تصویری جامع از الگوهای فعالیت عصبی مرتبط با MCI تاکید می‌کند. این رویکرد سیستماتیک برای انتخاب ویژگی به ما اجازه داد تا اطلاعات مفیدترین ویژگی‌های سیگنال fNIRS را حفظ کنیم.

¹ Significant Level

Attributes Comparison for Left, Middle, and Right PFC Channels (Rest task, 5-300 seconds)



شکل ۵-۳) مقایسه و انتخاب ویژگی‌های سیگنال بر اساس آزمون من-ویتنی

به طور خلاصه، استفاده از XGBoost و آزمون من-ویتنی برای انتخاب ویژگی‌های سیگنال و عملکردی، امکان شناسایی کارآمد و مبتنی بر داده‌های حیاتی‌ترین معیارهای اتصال را فراهم می‌آورد، در نتیجه نمایش مبتنی بر گراف‌های زمانی داده‌های fNIRS را بهینه می‌کند و قابلیت تشخیصی مدل را افزایش می‌دهد

۵-۴- ساخت گراف

ساخت گراف‌های زمانی یک گام مهم در استفاده از شبکه‌های عصبی گراف زمانی (TGNN) برای طبقه‌بندی اختلال شناختی خفیف (MCI) است. پس از پیش پردازش داده‌های fNIRS و انتخاب ویژگی‌های مرتبط با استفاده از آزمون XGBoost و Mann-Whitney U-Test گراف‌های زمانی ایجاد

می‌شوند تا الگوهای در حال تکامل فعالیت عصبی را به تصویر بکشند. این گراف‌ها هم ویژگی‌های سیگنال و هم اتصال عملکردی را در بر می‌گیرند و به TGNN اجازه می‌دهند تا پویایی زمانی عملکرد مغز را در گروه‌های MCI و افراد سالم مدل کند.

هر گره در گراف مربوط به یک کانال خاص از دستگاه fNIRS است که نشان دهنده مناطق مختلف مغز است. این گره‌ها فقط نمایش‌های ثابت نیستند. آنها با ویژگی‌های سیگنال انتخابی غنی شده اند که ویژگی‌های کلیدی فعالیت عصبی در هر کانال را منعکس می‌کنند. ویژگی‌های یال‌ها و گره‌های گراف‌های زمانی به شکل زیر است :

- ویژگی‌های سیگنال انتخاب شده: ویژگی‌های انتخاب شده موجود در هر گره حداکثر، حداقل و انحراف استاندارد برای Hbo و HbR است که بر اساس اهمیت آماری آن‌ها در تمایز MCI از گروه‌های HC انتخاب شده‌اند. این ویژگی‌ها دامنه و تنوع سیگنال‌های عصبی را ثبت می‌کنند و خلاصه‌ای کمی از فعالیت مغز در هر گره ارائه می‌دهند.

این رویکرد مبتنی بر گره به TGNN اجازه می‌دهد تا مستقیماً داده‌های فیزیولوژیکی را در ساختار گراف بگنجاند، و گره‌ها را آموزنده‌تر کرده و توانایی مدل را برای یادگیری از داده‌ها افزایش می‌دهد. یال‌های بین گره‌ها بر اساس معیارهای اتصال عملکردی تعریف می‌شوند و تعامل بین سیگنال‌های عصبی از مناطق مختلف مغز را منعکس می‌کنند. ویژگی‌های اتصال انتخاب شده - کوواریانس، شاخص تاخیر فاز (PLI)، همبستگی متقابل و پیچش زمانی پویا (DTW) جنبه‌های متعددی از همگامی عصبی و هم ترازی زمانی را به تصویر می‌کشد و نمایش جامعی از پویایی شبکه مغز ارائه می‌دهد.

- ویژگی‌های انتخاب شده اتصال عملکردی: کوواریانس، شاخص تاخیر فاز (PLI)، همبستگی متقابل و پیچش زمانی پویا (DTW) هستند. اتصال عملکردی سیگنال‌های مغزی، تعامل بین نواحی مختلف مغز را نشان می‌دهد، که نشان دهنده همبستگی‌های زمانی بین فعالیت‌های عصبی بین کانال‌ها است [129]. ضرایب همبستگی پیرسون (r) برای تجزیه و تحلیل همبستگی بین سیگنال‌های زمانی هر کانال استفاده شد. آستانه برای حذف اتصالات کاذب اعمال شد، زمانی که ضریب همبستگی پیرسون بین دو کانال کمتر از آستانه باشد یالی بین دو کانال تشکیل نمی‌شود. براساس تجربه این آستانه مقدار ۰.۶۵. درنظر گرفته شد. این ویژگی‌های اتصال که به عنوان یال‌ها تعبیه شده‌اند، ساختار گراف را غنی‌تر می‌کنند، و TGNN را قادر می‌سازند تا قدرت و ماهیت زمانی تعاملات مغزی را تجزیه و تحلیل کند، در نتیجه بینش عمیق‌تری در مورد الگوهای اتصال مرتبط برای طبقه‌بندی افراد دارای MCI از افراد سالم ارائه دهد. برای آنکه ویژگی‌های سیگنال HbR در ویژگی‌های یال هم استفاده شود ولی تأثیر آن کمتر از سیگنال HbO باشد، حلقه^۱ هر گره ویژگی‌های

¹ Self Loop

انتخاب شده یال را بین سیگنال HbO و HbR (برای مثال: کanal ۳ در سیگنال HbO و HbR) در خود جای داده است. بقیه یال‌های گراف به غیر از حلقه‌ها، روابط بین کanal‌های HbO را نشان می‌دهند.

گراف‌های زمانی وزن‌دار بدون جهت با استفاده از یک پنجره کشویی^۱ ۱۵ و ۳۰ و ۵ ثانیه‌ای تولید شدند که جنبه‌های پویا تعاملات عصبی را در بازه‌های زمانی متوالی نشان می‌دهند. در این میان پنجره‌های ۱۵ ثانیه‌ای به دلیل هزینه محاسباتی کمتر از پنجره‌های کوچک‌تر و دقیق‌تر (با استفاده از XGBoost) برای آموزش شبکه استفاده شد. رویکرد ساخت گراف‌های زمانی دنباله‌ای از گراف‌ها را ایجاد می‌کند که منعکس کننده تکامل زمانی اتصال مغز است و به TGNN اجازه می‌دهد تا نحوه تغییر الگوهای اتصال را در طول زمان مدل کند. اندازه پنجره^۲ انتخابی نیاز به گرفتن الگوهای فعالیت عصبی معنی دار است. این طول پنجره برای مشاهده نوسانات در اتصال کافی است و در عین حال به اندازه کافی فشرده است تا پویایی‌های متغیر زمان مرتبط با حالت‌های شناختی را تشخیص دهد. رویکرد پنجره کشویی تضمین می‌کند که هر گراف یک عکس فوری زمانی مجزا را در بر می‌گیرد و TGNN را قادر می‌سازد از الگوهای متوالی بیاموزد و وابستگی‌های زمانی حیاتی برای تشخیص MCI از پیری سالم را بهتر درک کند.

گراف‌های زمانی به عنوان ورودی به TGNN عمل می‌کنند، جایی که مدل از هر دو ویژگی سیگنال خاص گره و اتصال عملکردی تعریف شده از یال‌ها یاد می‌گیرد. این نمایش مبتنی بر گراف به TGNN اجازه می‌دهد تا به طور موثر ویژگی‌های مکانی-زمانی عملکرد مغز را ثبت کند و آن را برای مدل‌سازی پویایی عصبی پیچیده مشاهده شده در MCI بسیار مناسب می‌کند.

معماری TGNN برای مدیریت ماهیت متوالی گراف‌های تولید شده توسط پنجره کشویی طراحی شده است و به آن اجازه می‌دهد تا تغییرات عصبی کوتاه مدت و روندهای اتصال طولانی مدت را ثبت کند، که برای مدل سازی دقیق شبکه‌های مغزی که در آن‌ها مشاهده می‌شود بسیار مهم هستند. با ادغام داده‌های زمانی و مکانی، TGNN توانایی مدل را برای شناسایی تغییرات ظریف اتصال افزایش می‌دهد. این قابلیت به ویژه در تشخیص MCI مهم است، جایی که اختلالات در اتصال اغلب پیچیده هستند و در طول زمان تکامل می‌یابند.

این رویکرد نشان دهنده پیشرفت قابل توجهی در تجزیه و تحلیل تصویربرداری عصبی است که از مدل‌سازی مبتنی بر گراف پیشرفت به برای به تصویر کشیدن ماهیت پیچیده و پویا شبکه‌های مغزی استفاده می‌کند. گراف‌های زمانی و TGNN با هم چارچوبی قدرتمند برای تجزیه و تحلیل اختلالات شناختی ارائه می‌دهند و دیدگاه جامع‌تری از عملکرد عصبی ارائه می‌دهند که فراتر از تکنیک‌های تحلیل

¹ Sliding Window

² Window Size

سنتی است. گراف زمانی ساخته شده به عنوان ورودی TGNN استفاده می‌شوند. TGNN از ویژگی‌های گره (ویژگی‌های سیگنال) و ویژگی‌های یال (اتصال عملکردی) برای تجزیه و تحلیل الگوهای زمانی عملکرد مغز استفاده می‌کند. با پردازش این گرافها در طول زمان، TGNN می‌تواند ماهیت در حال تکامل شبکه‌های مغزی را ثبت کند، اختلالات در الگوهای اتصال عادی را شناسایی کند و بین MCI و پیری سالم تمایز قائل شود.

۶-۳- معیارهای ارزیابی سیگنال

در این مطالعه، ما از چندین روش ارزیابی سیگنال برای ارزیابی کیفیت و مقایسه دو نوع فیلتری که روش پیشنهادی پیش‌پردازش ما و مقاله پایه استفاده کرده‌اند استفاده، کردہ‌ایم. این روش‌ها عبارتند از میانگین مربعات خطأ^۱ (MSE)، خطای میانگین مربعات ریشه^۲ (RMSE)، نسبت سیگنال به نویز^۳ (SNR)، همبستگی^۴ و اعوجاج طیفی^۵. هر یک از این معیارها بینش منحصر به فردی را در مورد کیفیت سیگنال و اثربخشی نوع فیلتر انتخابی ما ارائه می‌دهند که در زیر به آن‌ها پرداخته‌ایم:

- میانگین مربعات خطأ (MSE): میانگین مربعات خطأ یک متريک پرکاربرد برای تعیين کميت میانگین محدود اختلاف بين مقادير براورد شده و مقادير واقعي است. مقادير كمتر MSE نشان دهنده كييفيت بهتر سیگنال است، زيرا انحرافات کوچکتر از سیگنال واقعي را نشان مي‌دهد. MSE به ما كمك مي‌کند تا دقت كلی تکنيک‌های پردازش سیگنال، از جمله اثربخشی نوع فیلتر انتخابی را ارزیابی کنیم.
- ریشه میانگین مربعات خطأ (RMSE): RMSE جذر MSE است که معیاری از انحراف استاندارد باقیماندها را ارائه می‌دهد. مانند MSE، مقادير RMSE نشان دهنده كييفيت بهتر سیگنال است. RMSE در همان واحد سیگنال اصلی است و آن را قابل تفسیرتر می‌کند. RMSE به ما اين امكان را مي‌دهد که مقدار خطای معمولی در سیگنال‌های پردازش شده خود را کمی کنیم و نشانه‌ای واضح از دقت پیش‌پردازش ارائه کنیم.
- نسبت سیگنال به نویز (SNR): SNR نسبت سطح سیگنال مورد نظر را با سطح نویز پس زمینه مقایسه می‌کند. مقادير SNR بالاتر نشان دهنده سیگنال تمیزتر با آلودگی نویز کمتر

¹ Mean Square Error

² Root Mean Squared Error

³ Signal to Noise Ratio

⁴ Correlation

⁵ Spectral Distortion

است. SNR در ارزیابی اثربخشی روش‌های فیلتر و کیفیت کلی سیگنال بسیار مهم است.

- همبستگی: همبستگی قدرت و جهت رابطه خطی بین دو سیگنال را اندازه گیری می‌کند.

مقادیر از ۱-تا ۱ است که ۱ نشان دهنده همبستگی مثبت کامل، ۰-۱ همبستگی منفی کامل و ۰ بدون همبستگی خطی است. با محاسبه همبستگی بین سیگنال خام و سیگنال پیش پردازش شده، می‌توانیم بررسی کنیم که مراحل پیش پردازش چقدر داده‌های اصلی را تغییر داده است. همبستگی تاثیر فیلترهای مختلف بر ساختار بنیادی سیگنال را نشان می‌دهد.

- اعوجاج طیفی: اعوجاج طیفی تفاوت بین نمایش طیفی دو سیگنال را اندازه گیری می‌کند.

اعوجاج طیفی کمتر نشان می‌دهد که محتوای فرکانس سیگنال در طول پیش پردازش به خوبی حفظ شده است. این معیار کمک می‌کند تا اطمینان حاصل شود که مراحل پیش پردازش به طور قابل توجهی ویژگی‌های فرکانس سیگنال‌ها را تغییر نداده است.

۷-۳- معیارهای ارزیابی

در ارزیابی عملکرد مدل‌های یادگیری ماشین، بهویژه در وظایف طبقه‌بندی، استفاده از مجموعه‌ای از معیارها که دید جامعی از دقت و قابلیت اطمینان مدل ارائه می‌دهد، بسیار مهم است. این بخش معیارهای ارزیابی کلیدی مورد استفاده در این مطالعه را مورد بحث قرار می‌دهد: امتیاز F1^۱، فراخوانی^۲، صحت^۳ و دقت^۴. علاوه بر این، استفاده از اعتبار سنجی متقطع k-fold طبقه‌بندی شده^۵، به ویژه اهمیت آن هنگام کار با مجموعه داده‌های کوچک توضیح داده شده است.

۷-۳-۱- دقت

دقت نسبت مشاهدات مثبت پیش بینی شده صحیح را به کل مثبت‌های پیش بینی شده اندازه می‌گیرد. زمانی که هزینه مثبت کاذب بالا باشد این پارامتر بسیار مهم است.

$$\text{Precision} = \frac{\text{True Positive (TP)}}{\text{True Positive (TP)} + \text{False Positive (FP)}}$$

¹ F1 Score

² Recall

³ Accuracy

⁴ Precision

⁵ Stratified K-Fold Cross Validation

به عنوان مثال، در تشخیص پزشکی، پیش‌بینی یک فرد سالم به عنوان بیمار (ثبت کاذب) می‌تواند منجر به درمان‌های غیر ضروری شود. دقت به حداقل رساندن چنین خطاهایی کمک می‌کند.

۲-۷-۳- فراخوانی

فراخوانی نسبت مشاهدات مثبت پیش‌بینی شده درست را از میان همه موارد مثبت واقعی اندازه‌گیری می‌کند. بر روی به حداقل رساندن منفی‌های کاذب تمرکز می‌کند.

$$\text{Recall} = \frac{\text{True Positive (TP)}}{\text{True Positive (TP)} + \text{False Negatives (FN)}}$$

فراخوانی در مسائلی که از دست دادن یک مورد مثبت عواقب جدی دارد بسیار مهم است. به عنوان مثال، در تشخیص بیماری، از دست دادن یک تشخیص (منفی کاذب) به مراتب بدتر از هشدار کاذب است.

۳-۷-۳- امتیاز F1

امتیاز F1 ترکیبی از دو معیار دقت و فراخوانی است. از آنجایی که هر دو معیار دقت و فراخوانی در محاسبه امتیاز F1 نقش دارند، امتیاز F1 بالاتر نشان‌دهنده عملکرد بهتر است. همان‌طور که در فرمول این معیار نیز مشخص است، به دلیل وجود عملگر ضرب در صورت مخرج، اگر از میزان یکی از معیارهای دقت یا فراخوانی کاسته شود، امتیاز F1 بسیار نزولی می‌شود. در نتیجه امتیاز F1 یک مدل یادگیری ماشین بالاست، اگر نمونه‌های مثبت پیش‌بینی شده در حقیقت نیز مثبت بوده و هیچ نمونه مثبتی به اشتباه منفی پیش‌بینی نشده باشد.

$$F1 Score = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

امتیاز F1 وزن یکسانی به دو معیار دقت و بازیابی می‌دهد. امتیاز F1 زمانی سودمند است که تعادل بین دقت و فراخوانی لازم باشد. این معیار یک معیار واحد را ارائه می‌دهد که هر دو را نشان می‌دهد و معیار جامع تری از عملکرد مدل را در شرایطی که عدم تعادل داده یا هزینه‌های خطا نابرابر وجود دارد ارائه می‌دهد.

۴-۷-۳- صحت

raigترین معیار برای ارزیابی یک مدل یادگیری ماشین، که در حقیقت شاخص چندان واضحی برای عملکرد نیست. زمانی که تعداد نمونه‌های هر دسته یا کلاس اختلاف زیادی با یکدیگر داشته باشند،

استفاده از این معیار پیشنهاد نمی‌شود.

$$\text{Accuracy} = \frac{\text{True Positive (TP)} + \text{True Negative (TN)}}{\text{TP} + \text{False Positive (FP)} + \text{TN} + \text{False Negative (FN)}}$$

به عنوان مثال، یک مدل تشخیص سرطان را تصور کنید. در شرایط عادی، احتمال سرطان داشتن بسیار پایین بوده و از میان هر ۱۰۰ بیمار، تنها ۱۰ نفر مبتلا هستند. ما نمی‌خواهیم مراجعه کننده‌ای که سرطان داشته را با تشخیص منفی نادرست یا FN نادیده بگیریم. قرار دادن همه بیماران در دسته افرادی که سرطان ندارند، صحتی ۹۰ درصد را نتیجه می‌دهد. در واقع مدل یادگیری ماشین بدون این‌که کار خاصی کرده باشد و تنها با تشخیص سرطان برای همه بیماران به این درصد رسیده است. به همین خاطر است که به معیارهای دقیق‌تری نیاز داریم.

۷-۵- روشن اعتبارسنجی متقابل

اعتبار سنجی متقابل k-fold طبقه بندی شده یک تکنیک ارزیابی است که برای ارزیابی عملکرد مدل‌های یادگیری ماشین، به‌ویژه زمانی که با مجموعه داده‌های نامتعادل یا کوچک سروکار داریم، استفاده می‌شود. برخلاف اعتبارسنجی متقابل k-fold استاندارد، k-fold طبقه بندی شده تضمین می‌کند که توزیع در هر لایه برای هر کلاس همان توزیعی است که هر کلاس در مجموعه داده دارد، و تخمین دقیق و قابل اعتمادتری از عملکرد مدل ارائه می‌دهد. در این روش، مجموعه داده‌ها به‌گونه‌ای که نسبت‌های کلاس در هر لایه حفظ می‌شود، به k لایه تقسیم می‌شود. هر لایه یک بار به عنوان مجموعه اعتبار سنجی عمل می‌کند، در حالی که k-1 تا لایه باقی مانده برای آموزش مدل استفاده می‌شود. این فرآیند k بار تکرار می‌شود و نتایج به‌منظور ارائه معیارهای عملکرد نهایی، میانگین می‌شوند.

مزایا اعتبار سنجی متقابل k-fold طبقه بندی شده در زیر بررسی شده است:

۱. حفظ توزیع کلاس:

- توزیع کلی کلاس را در هر لایه حفظ می‌کند و اطمینان می‌دهد که کلاس اقلیت به درستی در هر ارزیابی نمایش داده می‌شوند. اما در صورت استفاده از اعتبار سنجی متقابل k-fold سنتی ممکن است منجر به لایه‌هایی با توزیع کلاس نابرابر شود که می‌تواند نتایج عملکرد را منحرف کند.

۲. نتایج قابل اعتمادتر در مجموعه داده‌های کوچک:

- تضمین می‌کند که همه کلاس‌ها به طور مداوم ارزیابی می‌شوند و معیاری واقعی از توانایی مدل برای مدیریت داده‌های نامتعادل ارائه می‌دهد. برای مجموعه داده‌های کوچکی که نماینده هر یک از کلاس‌ها برای ارزیابی دقیق بسیار مهم است مفید است. اما در صورت استفاده از اعتبار سنجی متقابل k-fold سنتی تقسیم‌های تصادفی می‌تواند لایه‌ای ایجاد

کند که ممکن است به اندازه کافی داده‌های کلی را نشان ندهند.

فصل ۴: مدل پیشنهادی

۱-۴ - مقدمه

در این فصل، ما یک ارزیابی جامع از رویکرد و مدل پیش‌پردازش پیشنهادی خود ارائه می‌کنیم که بر اثربخشی روش‌های پیش‌پردازش داده‌ها در تمایز بین اختلال شناختی خفیف (MCI) و کنترل‌های سالم (HC) تمرکز دارد. هدف این فصل اعتبارسنجی تاثیر تکنیک‌های پیش‌پردازش جدید ما بر کیفیت سیگنال، استخراج ویژگی، و در نهایت، عملکرد طبقه‌بندی در مقایسه با رویکرد مقاله پایه است. این فصل با مقایسه نتایج روش‌های پیش‌پردازش داده‌ها، تجزیه و تحلیل کیفیت سیگنال و ارزیابی اثربخشی آنها با استفاده از آزمون‌های آماری آغاز می‌شود. این تحلیل مقایسه‌ای در بر جسته کردن نقاط قوت رویکرد ما و درک سهم آن در عملکرد کلی مدل پیشنهادی بسیار مهم است. در ادامه به ارزیابی کیفیت سیگنال بر اساس ویژگی‌ها و معیارهای انتخاب شده را مورد بحث قرار می‌دهیم. نتایج حاصل از آزمون-Mann-Whitney، که بینش‌هایی را در مورد اهمیت آماری تفاوت‌های بین گروه‌های MCI و HC تحت شرایط مختلف پیش‌پردازش ارائه می‌کند، نیز ارائه شده است. این تست‌ها به تعیین اینکه کدام رویکرد پیش‌پردازش در افزایش تمایز داده‌ها مؤثرer است، کمک می‌کند، بنابراین به تشخیص و طبقه‌بندی بهتر کمک می‌کند. پس از سیگنال‌ها و ارزیابی‌های آماری، به مقایسه دقیق روش پیش‌پردازش پیشنهادی ما در شرایط یکسان با تکنیک‌های پایه که در مقاله پایه اشاره شده است، می‌پردازیم. این مقایسه نه تنها روش‌های پیش‌پردازش را در یک محیط کنترل شده ارزیابی می‌کند، بلکه نتایج را با نتایج گزارش شده در ادبیات موجود مقایسه می‌کند و معیاری برای برتری یا کاستی‌های رویکرد ما ارائه می‌کند.

بخش‌های پایانی این فصل، شامل تحلیل تطبیقی با نتایج مقاله پایه است و نمای کلی یافته‌ها را ارائه می‌دهد. این تجزیه و تحلیل مزایای رویکرد پیش‌پردازش ما را بر جسته می‌کند، و توضیح می‌دهد که چگونه کیفیت سیگنال و عملکرد مدل را بهبود می‌بخشد.

۲-۴ - طراحی مدل: شبکه‌های عصبی گراف زمانی

در این بخش، ما در مورد طراحی و اجرای شبکه‌های عصبی گراف زمانی (TGNN) برای تجزیه و تحلیل داده‌های طیف‌سنجی مادون قرمز نزدیک (fNIRS) بحث می‌کنیم. TGNN‌ها به طور خاص برای مدیریت داده‌های گراف زمانی طراحی شده اند که در آن هر دو ویژگی گره و ساختار گراف در طول زمان تغییر می‌کنند. در میان معماری‌های مختلف TGNN، ما GConvLSTM و GconvGRU را بررسی کردیم. دلیل بررسی این دو مدل توانایی آن‌ها در استفاده از ویژگی‌های گره و یال باهم، برای یادگیری است. این قابلیت برای مدل سازی دقیق تعاملات پویا بین مناطق مغز بسیار مهم است. با مقایسه این دو مدل، ما GconvGRU را به دلیل عملکرد برتر آن در مجموعه داده‌های محدود و تولناکی آن در یادگیری

مؤثر وابستگی‌های مکانی و زمانی، برای مطالعه خود انتخاب کردیم.

۱-۲-۴- معماری TGNN برای داده‌های fNIRS

معماری TGNN انتخاب شده برای این تحقیق، GconvGRU است، که ترکیبی از شبکه‌های کانولوشن گراف (GCN) و واحدهای بازگشتی دردار^۱ (GRU) است. GconvGRU به طور موثر هم وابستگی‌های فضایی را در هر تصویر لحظه‌ای گراف و هم وابستگی‌های زمانی را در بین تصاویر لحظه‌ای گراف متوالی ثبت می‌کند. در اینجا یک بررسی دقیق از نحوه عملکرد GconvGRU و نحوه پردازش داده‌های گرافی با ویژگی‌های گره و ویژگی‌های یال ارائه شده است.

هر گره در گراف مربوط به یک کانال fNIRS است و هر گره دارای شش ویژگی است که مشخصه‌های سیگنال مختلف را نشان می‌دهند. این ویژگی‌ها اطلاعات زمانی دقیقی را در هر گره به مدل ارائه می‌دهد و توانایی آن برای تمایز بین حالات مختلف مغز افزایش را می‌دهد. یال‌های بین گره‌ها نشان دهنده اتصال عملکردی بین کانال‌ها هستند و دارای چهار ویژگی در هر یال هستند. این ویژگی‌ها شامل معیارهایی مانند کوواریانس، PLI (شاخص تاخیر فاز)، همبستگی متقابل و فاصله زمانی پویا (DTW) است که قدرت و پویایی اتصال را به تصویر می‌کشد.

۱. داده‌های ورودی و نمایش گراف:

- ویژگی‌های گره: هر گره در گراف کانالی از دستگاه fNIRS را نشان می‌دهد، با شش ویژگی استخراج شده از سیگنال‌ها، از جمله ویژگی‌های حداکثر، حداقل، و انحراف استاندارد برای HbO و HbR. این ویژگی‌ها اطلاعات حیاتی سیگنال‌های fNIRS را در بر می‌گیرند که نشان‌دهنده الگوهای فعالیت مغز است.
- وزن یال‌ها: یال‌ها با یک بردار ۴ عنصری وزن داده شده‌اند که معیارهای اتصال مختلف را ثبت می‌کند، مانند کوواریانس، شاخص تاخیر فاز (PLI)، همبستگی متقابل، و پیچش زمانی پویا (DTW) فاصله این وزن‌ها نمایش دقیقی از روابط بین کانال‌ها ارائه می‌کنند و بینشی را در مورد جنبه‌های مختلف اتصال مغز ارائه می‌کنند.

۲. تبدیل وزن یال‌ها:

- مدل پیشنهادی از یک لایه تبدیل برای کاهش بردار ۴ عنصری وزن یال به یک مقدار عددی واحد استفاده می‌کند. این تبدیل خطی برای ساده کردن وزن لبه‌های چند بعدی به شکلی سازگار با عملیات کانولوشن گراف ضروری است. این تبدیل به حفظ اطلاعات مربوطه از تمام اقدامات اتصال کمک می‌کند و آنها را مستقیماً در لایه‌های بعدی قابل استفاده می‌کند.

¹ Gated Recurrent Unit

3. لایه‌های TGNN

مدل پیشنهادی از دو لایه GConvGRU انباشته شده استفاده می‌کند، که هر یک کانولوشن گراف را با واحدهای بازگشتی دروازه‌دار ترکیب می‌کند و شبکه را قادر می‌سازند از اطلاعات مکانی (ساختار گراف) و زمانی (توالی در طول زمان) بیاموزد:

- اولین لایه GConvGRU: اولین لایه بازگشتی ویژگی‌های گره ورودی و وزن یال‌های تبدیل شده را پردازش می‌کند و وابستگی‌های زمانی بین مراحل زمانی متوالی را یاد می‌گیرد و در عین حال ساختار گراف را نیز در نظر می‌گیرد.
- به دلیل کوچک بودن مجموعه داد حذف تصادفی^۱ برای جلوگیری از بیش برآش^۲ و افزایش تعمیم با حذف تصادفی وزن‌ها در طول یادگیری اعمال می‌شود.
- دومین لایه GConvGRU: خروجی از لایه اول به لایه دوم GConvGRU وارد می‌شود که ویژگی‌های گره آموخته شده را بیشتر اصلاح می‌کند. این لایه دوم درک زمانی و مکانی داده‌ها را عمیق‌تر می‌کند و به مدل اجازه می‌دهد تا الگوهای پیچیده‌تری را ثبت کند.
- حذف تصادفی برای حفظ استحکام مدل اعمال می‌شود.

4. لایه خروجی:

- پس از پردازش از طریق لایه‌های مکرر، ویژگی‌های گره به روز شده از یک لایه خطی^۳ عبور داده می‌شود که ویژگی‌های پنهان را به بعد خروجی مورد نظر نگاشت می‌کند.

عملیات کانولوشن گراف را در چارچوب GRU ادغام می‌کند و به آن اجازه می‌دهد تا به طور همزمان وابستگی‌های فضایی بین گره‌ها و روابط زمانی را در مراحل زمانی ثبت کند. اجزای کلیدی GconvGRU به شکل زیر است:

- روابط فضایی بین گره‌ها را با جمع‌آوری ویژگی‌های هر گره و همسایه‌های آن استخراج می‌کند. درهنگام این عملیات کمک می‌کند تا اطلاعات ساختاری محلی را در هر تصویر لحظه‌ای گراف جمع‌آوری شود و توانایی مدل را برای یادگیری از اتصالات قوی و ضعیف پویا را افزایش می‌دهد.
- واحد بازگشتی دروازه‌ای (GRU): وابستگی‌های زمانی بین عکس‌های فوری گراف را با استفاده از گیت‌ها برای کنترل جریان اطلاعات مدیریت می‌کند و تضمین می‌کند که

¹ Dropout

² Overfit

³ Linear Layer

مرتبه‌ترین داده‌های تاریخی حفظ می‌شوند در حالی که اطلاعات کمتر مرتبط را دور می‌اندازند. این جنبه مدل سازی زمانی برای درک چگونگی تکامل ویژگی‌های گره و ساختارهای گراف بسیار مهم است.

با ادغام کانولوشن گراف با واحدهای بازگشتی دروازه‌ای، این مدل می‌تواند به طور موثری از اتصال مکانی و تکامل زمانی سیگنال‌های مغزی بیاموزد. تغییر وزن یال‌ها، مدل را قادر می‌سازد تا از معیارهای اتصال جامع استفاده کند و توانایی آن را برای تمایز بین MCI و کنترل‌های سالم افزایش دهد. این طراحی RecurrentGCN را به ابزاری قدرتمند برای تجزیه و تحلیل پویایی شبکه‌های مغز تبدیل می‌کند.

۲-۲-۴- جزئیات پیاده سازی

در این بخش، شرح جامعی از معماری شبکه مورد استفاده، با تمرکز بر روش‌شناسی و ابزار خاص، از جمله کتابخانه گراف زمانی PyTorch، ابعاد ورودی و خروجی، و اجرای اعتبارسنجی متقاطع طبقه‌بندی شده^۱ در این مطالعه ارائه می‌دهیم. هدف این توضیح ارائه بینش به معماری، فرآیند آموزش و استراتژی‌های ارزیابی مدل است. ساخت گراف‌های زمانی و پیاده‌سازی مدل پیشنهادی با استفاده از کتابخانه‌های PyTorch و Pytorch Geometric Temporal، که به طور خاص از مازول «GConvGRU» استفاده کردیم، که برای مدیریت گراف‌های زمانی با ویژگی‌های در حال تکامل گره و یال طراحی شده است.

۱. استفاده از کتابخانه PyTorch Geometric Temporal

- پیاده‌سازی مدل شبکه عصبی از کتابخانه PyTorch Geometric Temporal استفاده می‌کند، توسعه PyTorch که در شبکه‌های عصبی گراف مکانی-زمانی تخصص دارد. این کتابخانه لایه‌ها و توابع از پیش ساخته شده‌ای را ارائه می‌دهد که به طور موثر داده‌های گراف زمانی را مدیریت می‌کند و آن را برای کارهایی که شامل توالی‌های زمانی و تعاملات گره در طول زمان است ایده آل می‌کند. PyG Temporal به مدل اجازه می‌دهد تا وابستگی‌های زمانی و روابط مکانی را به طور همزمان ترکیب کند و توانایی آن را برای یادگیری از ساختارهای داده گراف زمانی افزایش دهد.

۲. قابلیت کنترل وزنه‌های لبه:

- وزن لبه‌ها با استفاده از یک لایه خطی ('Edge_weight_transform') تبدیل می‌شوند. این تبدیل بردار را به یک عدد واحد کاهش می‌دهد که با عملیات کانولوشن گراف سازگار است. سپس خروجی این لایه به همراه ویژگی‌های گره‌ها به عنوان ورودی به لایه‌های

¹ Stratified K-Fold Cross Validation

GConvGRU داده می‌شود.

۳. اعتبارسنجی مقاطع k-fold طبقه بندی شده:

- برای اطمینان از ارزیابی مدل، ما از اعتبار سنجی مقاطع k-fold طبقه بندی شده استفاده کردیم. این رویکرد، مجموعه داده را به k لایه تقسیم می‌کند و در عین حال نسبت کلاس‌ها را در هر لایه حفظ می‌کند، که به ویژه هنگام استفاده از مجموعه داده‌های نامتعادل مهم است.

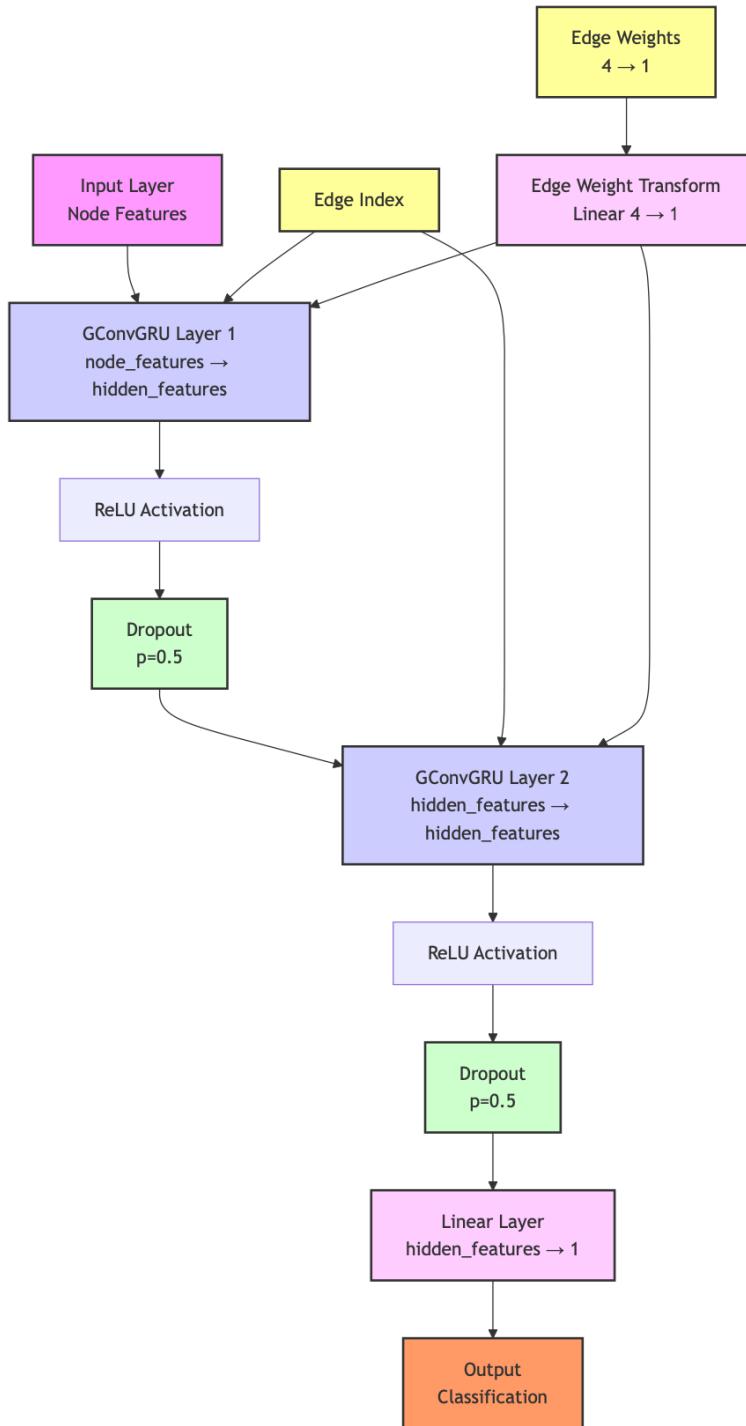
- معیارهای عملکرد: بعد از k تکرار، معیارهای عملکرد (صحت، دقت، فراخوانی، امتیاز F1) در تمام موارد به طور میانگین محاسبه می‌شوند و تخمین قابل اعتمادتری از عملکرد مدل ارائه می‌دهند.

۴. جزئیات پیاده سازی:

- مدل با استفاده از ترکیبی از داده‌های زمانی و مکانی آموزش داده می‌شود تا هم وابستگی‌های زمانی و هم روابط فضایی بین گره‌ها را به تصویر بکشد. نرمال سازی دسته ای^۱ و لایه‌های حذف برای جلوگیری از بیش برازش و بهبود تعییم استفاده می‌شود. فرآیند آموزش با استفاده از بهینه ساز Adam با زمان بندی نرخ یادگیری^۲ انجام شده است.

¹ Batch Normalization

² Learning Rate



شکل (۱-۴) (جزئیات شبکه پیشنهادی

لایه نهایی نقش مهمی در تبدیل نمایش‌های گراف‌های آموخته شده به پیش‌بینی‌های معنادار برای کار طبقه‌بندی دودویی ما دارد. لایه خروجی مدل RGCN مابه صورت یک تبدیل خطی منفرد پیاده سازی شده است که در آن **hidden_features** ابعاد حالت پنهان تولید شده توسط لایه GConvGRU قبلی را نشان می‌دهد و **output_features** برابر با ۱ تنظیم شده است که مطابق با وظیفه طبقه‌بندی دودویی ما است. این لایه خطی نمایش‌های پنهان با ابعاد بالا را به یک مقدار عددی نگاشت می‌کند، که

می تواند به عنوان یک logit برای طبقه بندی باینری استفاده شود.
فرآیند طبقه بندی شامل تبدیل خروجی مدل به احتمال و سپس به یک پیش بینی باینری است.
این امر در مدل پیشنهادی ما از طریق مراحل زیر حاصل می شود:

- logit خروجی با استفاده از تابع سیگموید^۱ به احتمال تبدیل می شود: تابع سیگموید
- خروجی با ارزش واقعی را در محدوده $[0, 1]$ نگاشت می کند و یک تفسیر احتمالی را ارائه می دهد.

طبقه بندی مبتنی بر آستانه: آستانه ۰.۵۷ برای احتمال به دست آوردن طبقه بندی باینری نهایی اعمال می شود و این آستانه به صورت تجربی برای متعادل کردن دقت و فراخوانی در زمینه مسئله کاربردی خاص ما انتخاب شد. دلیل انتخاب آستانه مشخص شده نسبت داده های MCI به کل داده است
تابع زیان^۲:

مدل پیشنهادی با استفاده از آنتروپی متقاطع باینری با لاجیت ها^۳ به عنوان تابع زیان اولیه آموزش داده شده است: این تابع زیان، فعال سازی سیگموید و زیان Binary Cross-Entropy را در یک عملیات ترکیب می کند و پایداری عددی بهتری نسبت به محاسبات جداگانه سیگموید و Binary Cross-Entropy ارائه می دهد[130].

برای افزایش قابلیت های تعمیم مدل و جلوگیری از بیش برازش، ما نظم دهی L1^۴ را در تابع زیان خود وارد کردیم: نظم دهی L1 باعث ایجاد پراکندگی در پارامتر های مدل می شود، که به طور بالقوه منجر به مدل قابل تفسیر تر و بهبود عملکرد در داده های دیده نشده می شود [131].

انتخاب binary cross-entropy به عنوان تابع زیان ما به دلیل مبنای نظری آن در تئوری اطلاعات و اثربخشی آن در وظایف طبقه بندی باینری است [132]. نسخه لاجیت این تابع زیان به دلیل ثبات عددی افزایش یافته آن انتخاب شد، که به ویژه در مدل های مبتنی بر گراف که در آن مقیاس ویژگی های گره می تواند به طور قابل توجهی متفاوت باشد، مهم است.

ادغام نظم دهی L1 با هدف ما برای ساختن مدلی که به خوبی به ساختارهای گراف نادیده تعمیم می دهد، همسو است. با تشویق پراکندگی، هدف ما کاهش اتكای مدل به الگوهای گرافی خاصی است که ممکن است در داده های آموزشی ما بیش از حد نشان داده شوند. انتخاب آستانه طبقه بندی ۰.۵۷، به جای ۰.۵، بر اساس مشاهدات تجربی عملکرد مدل ما بر روی داده های اعتبار سنجی انجام شد. این افزایش جزئی در آستانه به کاهش مثبت های کاذب کمک می کند.

¹ Sigmoid

² Loss

³ Binary Cross-Entropy with Logits

⁴ L1 Regularization

در نتیجه، این انتخاب‌های طراحی برای لایه خروجی، روش طبقه‌بندی و تابع ضرر به طور همانگونه کار می‌کنند تا مدلی را ایجاد کنند که برای طبقه‌بندی باینری مبتنی بر گراف خاص ما مناسب باشد، قدرت پیش‌بینی را با قابلیت تعمیم‌پذیری و الزامات خاص دامنه متعادل کند. در شکل (۴-۱) نحوه اتصال لایه‌ها و شمای کلی شبکه پیشنهادی به تصویر کشیده شده است.

۴-۳- مقایسه پیش‌پردازش داده‌ها

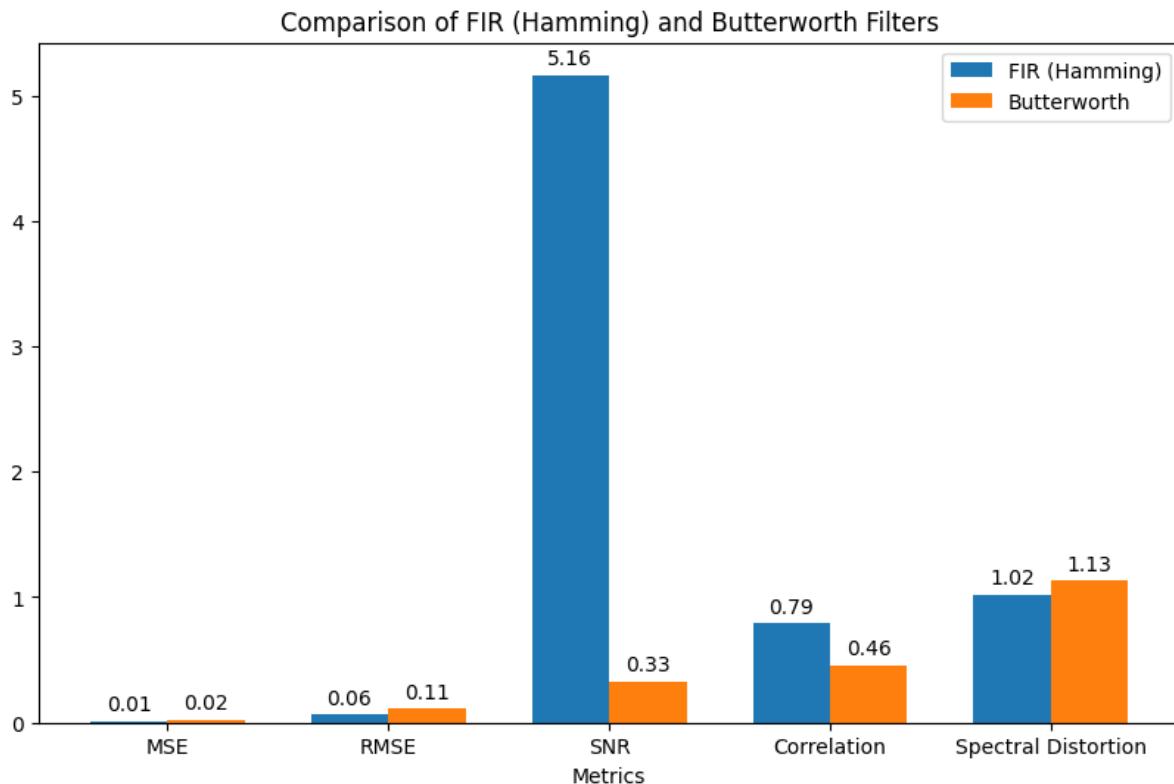
در این بخش به مقایسه دو روش پیش پردازش داده می‌پردازیم. روش‌های پیش‌پردازش داده‌های مورد استفاده در این مطالعه به‌طور قابل توجهی با روش‌های مورد استفاده در مقاله پایه متفاوت است. هدف هر دو رویکرد پاکسازی و آماده سازی داده‌ها برای تجزیه و تحلیل است، اما آن‌ها از تکنیک‌ها و توالی‌های متفاوتی استفاده می‌کنند. در اینجا یک مقایسه دقیق انجام می‌دهیم:

- اعمال فیلتر میان گذر Butterworth مرتبه چهارم (۰.۱۵-۰.۰۰۱۸ هرتز)
 - استفاده از الگوریتم detrend رویکرد ما:
 - حذف مقادیر پرت از سیگنال
 - استفاده از الگوریتم detrend
 - استفاده از TDDR برای تصحیح مصنوعات حرکتی
 - اعمال فیلتر میان گذر (Hamming Window) FIR مرتبه ۲۵۰ (۰/۱-۰/۰۱ هرتز) اعمال شد.
 - نرمال سازی هر کanal

۴-۳-۱- نتایج ارزیاب سگنا

پیش پردازش سیگنال‌ها در بهبود عملکرد کلی هر سیستم پردازش سیگنال بسیار مهم است. در این بخش، عملکرد دو نوع فیلتر پرکاربرد و استفاده شده در این دو روش را با هم مقایسه می‌کنیم: FIR با استفاده از پنجره همینگ و فیلتر Butterworth IIR. معیارهای ارزیابی مورد استفاده برای این مقایسه عبارتند از: میانگین مربعات خطأ (MSE)، میانگین مربعات خطای ریشه (RMSE)، نسبت سیگنال به نویز (SNR)، همبستگی و اعوجاج طیفی. میانگین مربعات خطأ (MSE) و ریشه میانگین مربعات خطأ (RMSE): همانطور که از نمودار میله‌ای شکل ۲-۴ مشاهده می‌شود، فیلتر FIR از نظر MSE و RMSE بهتر از فیلتر Butterworth عمل می‌کند و به ترتیب به مقادیر ۰.۰۶ و ۰.۰۱ در مقایسه با ۰.۰۲ و ۰.۱۱.

برای فیلتر Butterworth می‌رسد. این نشان می‌دهد که فیلتر FIR سیگنال پاک‌تری با نرخ خطای کمتر تولید می‌کند و آن را در به حداقل رساندن نویز و حفظ ویژگی‌های سیگنال مورد نظر مؤثرer می‌کند.

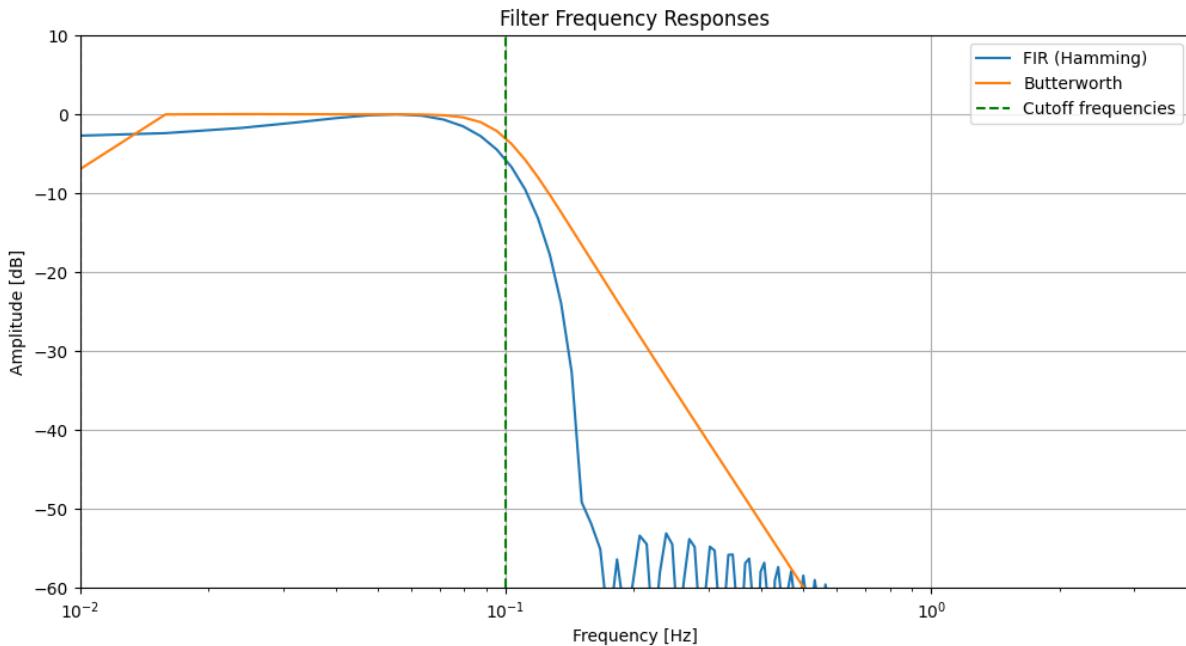


شکل (۲-۴) مقایسه کیفیت سیگنال فیلتر شده با استفاده از دو نوع فیلتر دو روش پیش‌پردازش

فیلتر FIR به طور قابل توجهی از فیلتر Butterworth از نظر SNR با مقدار ۵.۱۶ در مقایسه با ۰.۳۳ عملکرد بهتری دارد. SNR بالاتر نشان می‌دهد که فیلتر FIR در حفظ یکپارچگی سیگنال اصلی و در عین حال سرکوب موثر نویز بسیار برتر است. این یک عامل حیاتی است، به ویژه در مسائلی که وضوح سیگنال در آن‌ها اهمیت دارد. مقادیر همبستگی بین سیگنال‌های فیلتر شده و اصلی برای FIR (Hamming) ۰.۷۹ و برای Butterworth ۰.۴۶ است. این نشان می‌دهد که فیلتر FIR بیشتر ویژگی‌های سیگنال اصلی را حفظ می‌کند و مطابقت نزدیک‌تری با داده‌های فیلتر نشده ارائه می‌دهد. این ویژگی به ویژه در کاربردهایی مانند پردازش سیگنال زیست‌پزشکی، که در آن حفظ ویژگی‌های سیگنال مهم است، اهمیت دارد. فیلتر Butterworth دارای اعوجاج طیفی کمی بالاتر (۱.۱۳) در مقایسه با فیلتر FIR (Hamming) ۱.۰۲ است. این نشان می‌دهد که هر دو فیلتر سطحی از تغییر پاسخ فرکانس را معرفی می‌کنند. با این حال، فیلتر FIR کمی بهتر سیگنال را پردازش کرده است. به حداقل رساندن اعوجاج طیفی برای حفظ ساختار هارمونیک سیگنال‌ها، به ویژه در کاربردهای صوتی و سیگنال‌های مغزی بسیار مهم است.

شکل ۳-۴ پاسخ فرکانسی هر دو فیلتر را نشان می‌دهد. فیلتر FIR در مقایسه با فیلتر Butterworth نوار انتقالی واضح‌تر و تضعیف قابل توجهی در فرکانس فیلتر نشان می‌دهد. این ویژگی در

کاربردهایی که نیاز به قطع تند و حداقل نشت سیگنال در خارج از فرکانس فیلتر دارند، سودمند است.



شکل (۳-۴) مقایسه پاسخ فرکانسی دو نوع فیلتر استفاده شده در دو روش پیش‌پردازش

از تجزیه و تحلیل های بالا، واضح است که فیلتر FIR در اکثر معیارها، به ویژه در کاهش نویز و حفظ یکپارچگی سیگنال، بهتر از فیلتر Butterworth عمل می‌کند. ویژگی‌های قطع واضح‌تر و همبستگی بهتر با سیگنال اصلی، رویکرد FIR Hamming را به یک انتخاب ارجح در سناریوهایی که فیلتر کردن با حفظ اصالت و مشخصات حیاتی سیگنال مهم است، تبدیل می‌کند. در مقایسه با استفاده مقاله پایه از فیلتر Butterworth، فیلتر FIR Hamming بهبود قابل توجهی در کیفیت سیگنال ایجاد می‌کند و آن را به یک رویکرد پیش‌پردازش برتر برای مسائلی که دقت و کاهش نویز را در اولویت قرار دارد تبدیل می‌کند.

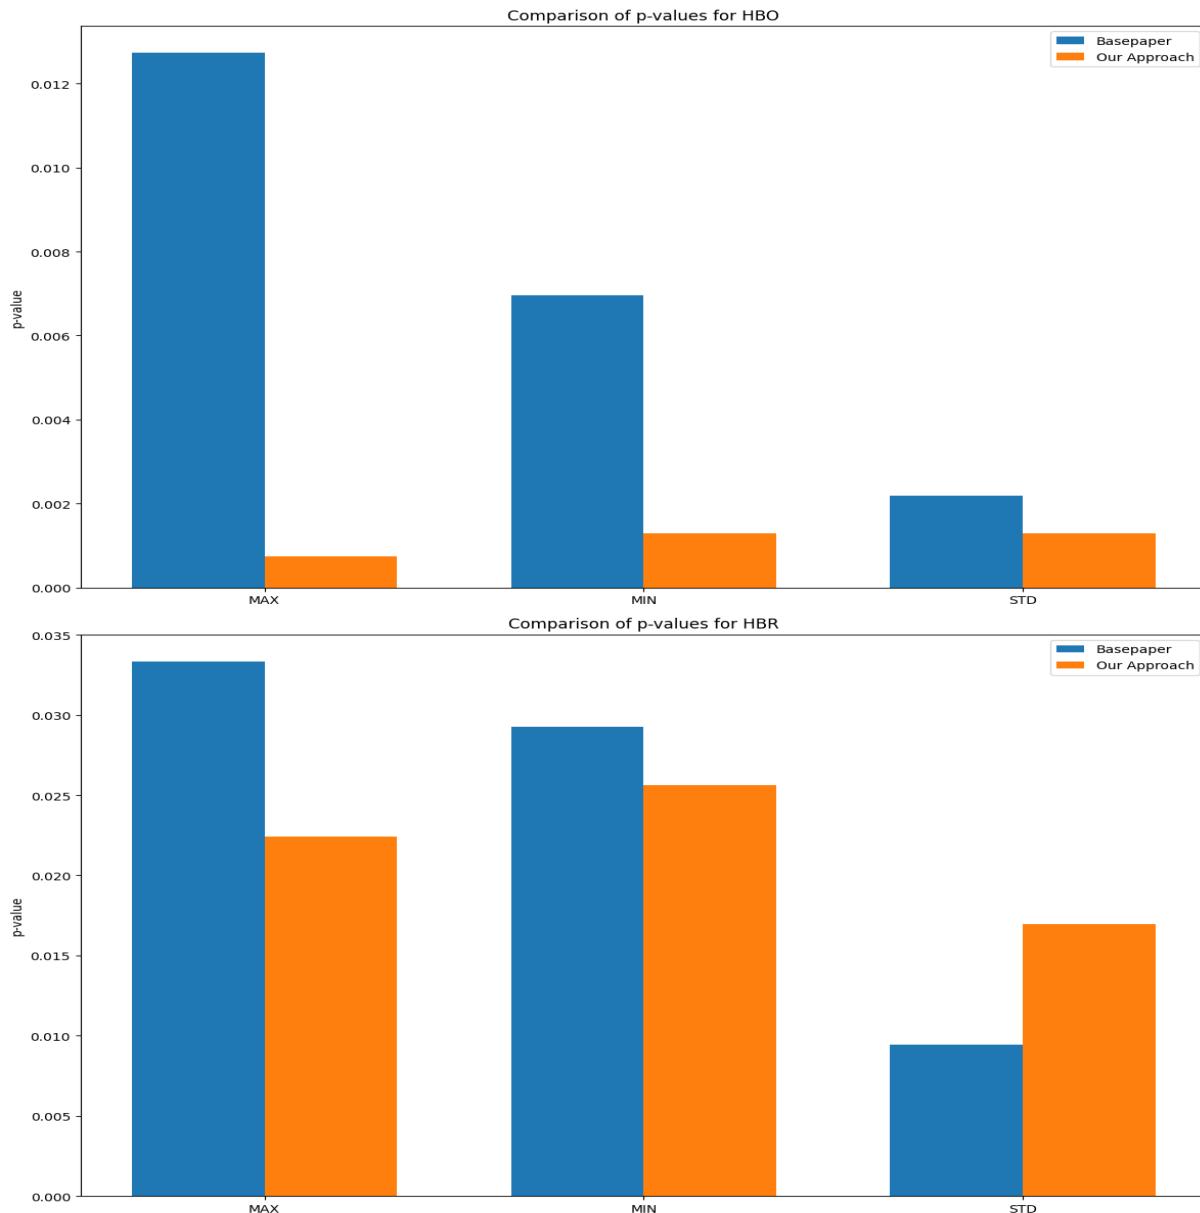
۲-۳-۴- نتایج آزمون تجزیه و تحلیل آماری

برای ارزیابی بیشتر اثربخشی رویکردهای پیش‌پردازش پیشنهادی و مقاله پایه، ما یک تجزیه و تحلیل آماری انجام دادیم تا مشخص کنیم کدام روش پیش‌پردازش بین دو گروه اختلال شناختی خفیف (MCI) و کنترل سالم (HC) تمایز بیشتری به وجود می‌آورد. این تجزیه و تحلیل بسیار مهم است زیرا مستقیماً بر استحکام و قابلیت اطمینان قدم‌های بعدی مانند طبقه بنده تأثیر می‌گذارد. آزمون Mann-Whitney U، یک آزمون آماری برای مقایسه توزیع ویژگی‌های انتخاب شده بین گروه‌های MCI و HC استفاده شد. دلایل استقاده از این آزمون در این مطالعه در زیر آمده است:

- ماهیت نلپارامتری: آزمون من ویتنی توزیع نرمال داده‌ها را فرض نمی‌کند، و آن را برای داده‌های fNIRS مناسب می‌کند، که اغلب به دلیل تنوع بیولوژیکی، نویز و مصنوعات از توزیع

نرمال پیروی نمی‌کنند. این تست هنگام مقایسه داده‌های توزیع شده غیرنرمال، که در مطالعات تصویربرداری عصبی رایج است، ایده‌آل است.

- مقایسه میانه‌ها: برخلاف آزمون‌های پارامتریک مانند آزمون t که میانگین‌ها را با هم مقایسه می‌کنند، آزمون من ویتنی میانه‌های دو گروه را مقایسه می‌کند. از آنجایی که داده‌های fNIRS را می‌توان با مقادیر شدید منحرف کرد، تمرکز بر میانه‌ها معیار قوی‌تری از تمایل مرکزی برای ارزیابی تفاوت‌های گروهی ارائه می‌دهد.
- کاربرد در اندازه نمونه کوچک: آزمون Mann-Whitney قدرت و اعتبار خود را حتی با مجموعه داده‌های کوچک‌تر حفظ می‌کند و نتایج قلب اعتمادی را بدون نیاز به حجم نمونه بزرگ ارائه می‌دهد.



شکل (۴-۴) مقایسه آماری تاثیر دو روش پیش‌پردازش

در شکل (۴-۴) نتایج مقایسه دو روش پیش‌پردازش برای HBO (هموگلوبین اکسیژن دار) و HBR (هموگلوبین بدون اکسیژن) ارلئه شده است، که در آن مقادیر p برای هر رویکرد پیش‌پردازش در ویژگی‌های کلیدی ترسیم شده است: MAX، MIN، و STD. مقادیر p پایین‌تر نشان‌دهنده تفاوت آماری بیشتر بین دو گروه است، به این معنی که رویکرد پیش‌پردازش به طور موثری تمایز ویژگی بین MCI و HC را افزایش می‌دهد.

۱. مقایسه دو روش پیش‌پردازش برای HBO:

مقدار p برای رویکرد مقاله پایه تقریباً ۰.۰۱۲ است، در حالی که رویکرد ما دارای مقدار p قابل توجهی نزدیک به صفر است. این کاهش آشکار نشان می‌دهد که روش پیش‌پردازش ما جدایی بین MCI و HC را به میزان بسیار بیشتری افزایش می‌دهد.

MIN: روندهای مشابهی با ویژگی MIN مشاهده می‌شود، جایی که رویکرد ما مقدار p بسیار کمتری را در مقایسه با مقاله پایه نشان می‌دهد و توانایی برتر آن را برای تمایز بین دو گروه تقویت می‌کند.

STD: برای ویژگی انحراف استاندارد، رویکرد ما دوباره مقدار p پایین‌تری را در مقایسه با مقاله پایه نشان می‌دهد، اگرچه تفاوت کمتر از معیارهای MAX و MIN است. با این وجود، کاهش مداوم در مقادیر p در تمام معیارها نشان می‌دهد که رویکرد پیش پردازش مابه طور موثر تفاوت‌های بین دو گروه را برجسته می‌کند.

۲. مقایسه دو روش پیش‌پردازش برای HBO:

MAX: رویکرد پیش پردازش ما در مقایسه با مقاله پایه (تقریباً ۰.۰۲ در مقابل ۰.۰۳) مقدار p کمتری را به همراه دارد که نشان دهنده قدرت تمایز بهبود یافته بین MCI و HC است.

MIN: برای ویژگی حداقل، رویکرد ما همچنین مقدار p کمتری را در مقایسه با مقاله پایه نشان می‌دهد، که نشان دهنده اثربخشی بیش‌تر روش ما در تمایز بین دو گروه است.

STD: اگرچه رویکرد مقاله پایه دارای مقدار p نسبتاً پایینی برای ویژگی STD است، رویکرد ما همچنان عملکرد بهتری را با مقدار p کمتر نشان می‌دهد و برتری کلی آن را برجسته می‌کند.

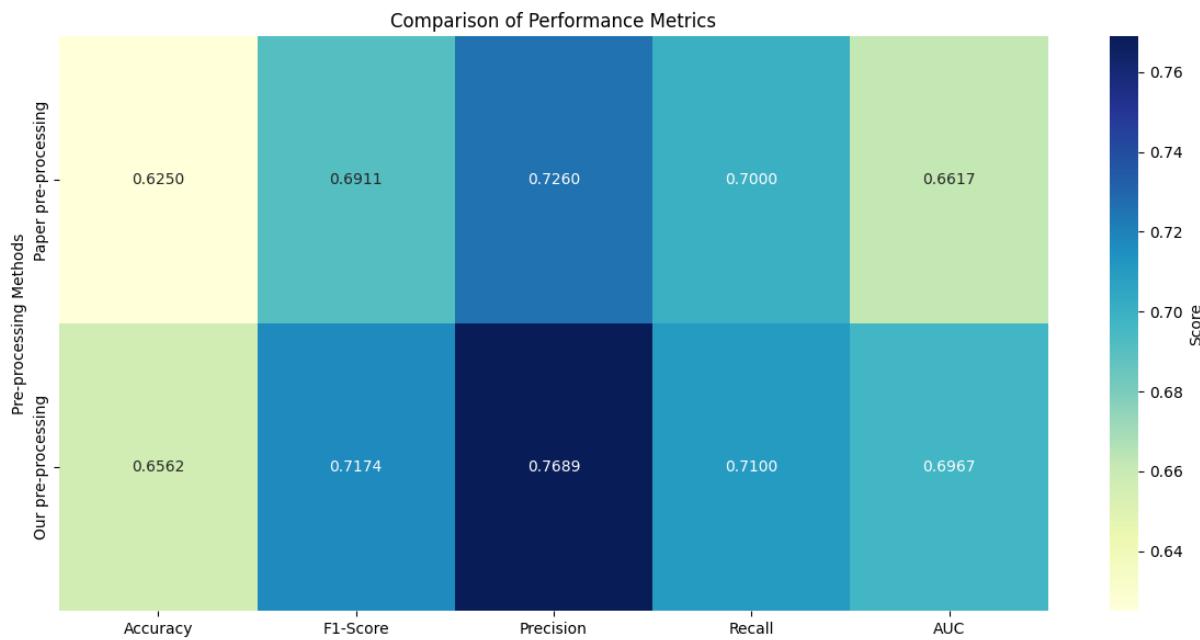
نتایج آماری آزمون Mann-Whitney به وضوح نشان می‌دهد که رویکرد پیش پردازش ما به طور قابل توجهی بهتر از روش پایه استفاده شده در مقاله پایه است. مقادیر p پایین‌تر از روش مقاله پایه در معیارهای MAX، MIN، و STD برای معیارهای HBO و HBR نشان می‌دهد که روش ما به طور مؤثرتری بین گروههای MCI و HC متمايز می‌شود. این تفکیک پذیری افزایش یافته برای بهبود دقت وظایف طبقه بندهی بعدهی حیاتی است و استحکام استراتژی پیش پردازش ما را در کاربردهای عملی نشان می‌دهد. بنابراین، رویکرد ما نه تنها در سرکوب نویز و حفظ سیگنال موثرter است، بلکه در افزایش قابلیت تمایز ویژگی‌ها نیز مؤثر است و آن را به یک انتخاب پیش پردازش برتر در زمینه تجزیه و تحلیل داده‌های بالینی تبدیل می‌کند.

۴-۴- ارزیابی نتایج

هدف این فصل، مقایسه و ارزیابی کامل رویکرد پیش پردازش پیشنهادی و تأثیر آن بر عملکرد طبقه‌بندهی اختلال شناختی خفیف (MCI) در مقابل کنترل‌های سالم (HC) با استفاده از داده‌های fNIRS است. این بخش برای ارزیابی سیستماتیک اثربخشی تکنیک پیش‌پردازش پیشنهادی و مقایسه آن با تکنیک‌های مورد استفاده در مقاله پایه، تمرکز بر معیارهای ارزیابی کلیدی و عملکرد مدل در شرایط مشابه، ساختار یافته است.

۴-۱-۴- مقایسه پیش پردازش پیشنهادی در شرایط یکسان

این بخش عملکرد مدل XGBoost را هنگامی که برای مجموعه داده‌های پیش پردازش شده با استفاده از دو رویکرد متمایز روش پیش پردازش پیشنهادی ما و رویکرد پیش پردازش مقاله پایه اعمال می‌شود، ارزیابی می‌کند. این مقایسه برای ارزیابی اثربخشی هر تکنیک پیش پردازش در شرایط یکسان، حصول اطمینان از ارزیابی منصفانه تأثیر آنها بر عملکرد طبقه‌بندی، حیاتی است.



شکل ۴-۵ مقایسه عملکرد دو روش پیش پردازش در XGBoost

باتوجه به شکل ۴-۵ داده‌های پردازش شده توسط روش پیش پردازش ما عملکرد بهتری را در شرایط یکسان برای طبقه‌بندی دو گروه نشان داده است. در زیر به بررسی این شکل و نتایج آن می‌پردازیم:

- ۱. صحت:**

معیار صحت، نسبت پیش‌بینی‌های صحیح مدل به همه پیش‌بینی‌ها اندازه‌گیری می‌کند. روش پیش پردازش ما به دقت ۰.۶۵۶۲ در مقایسه با ۰.۶۲۵۰ از روش مقاله پایه دست یافت. این بهبود نشان می‌دهد که رویکرد ما به طور موثرتری کیفیت سیگنال و فرآیند استخراج ویژگی را افزایش می‌دهد و منجر به طبقه‌بندی دقیق‌تر گروه‌های MCI (اختلال شناختی خفیف) و HC (کنترل سالم) می‌شود.

۲. امتیاز F1:

امتیاز F1، میانگین هارمونیک دقت و فراخوانی، برای درک اینکه مدل چقدر تعادل بین مثبت کاذب و منفی کاذب را متعادل می‌کند، بسیار مهم است. رویکرد پیش پردازش ما امتیاز F1 ۰.۷۱۷۴ را به دست آورد که از امتیاز مقاله پایه ۰.۶۹۱۱ بهتر بود. این امتیاز بالاتر نشان می‌دهد که روش ما در تشخیص هر دو گروه MCI و HC متعادل‌تر است، و به ویژه در سناریوهای بالینی که دقت بالا و فراخوانی بالا ضروری هستند، ارزشمند است.

۳. دقت:

دقت نشان دهنده توانایی مدل برای شناسایی فقط موارد مثبت واقعی بدون احتساب موارد مثبت کاذب است. با امتیاز دقت ۰.۷۶۸۹، روش پیش پردازش ما به طور قابل توجهی بهتر از رویکرد مقاله پایه است که امتیاز ۰.۷۲۶۰ را کسب کرده است. این نشان می‌دهد که روش ما احتمال طبقه‌بندی اشتباه را کاهش می‌دهد، که منجر به شناسایی قابل اطمینان‌تر موارد MCI، یک عامل مهم در کاربردهای بالینی است.

۴. فراخوانی:

فراخوانی، توانایی مدل را برای شناسایی همه موارد مرتبط (مثبت‌های واقعی) می‌سنجد. رویکرد پیش پردازش ما فراخوانی ۰.۷۱۰۰ را کمی بیشتر از فراخوان مقاله پایه ۰.۷۰۰۰ به دست می‌آورد. اگرچه این بهبود اندک است، اما همچنان نشان دهنده عملکرد بهتر در ثبت موارد مثبت واقعی است، و تضمین می‌کند که بیماران MCI کمتری در طبقه‌بندی نادیده گرفته می‌شوند.

۵. AUC^۱ (منطقه زیر منحنی):

امتیاز AUC یک ارزیابی جامع از توانایی مدل برای تمایز بین کلاس‌ها در تنظیمات آستانه مختلف ارائه می‌دهد. ۰.۶۹۶۷ AUC برای روش پیش پردازش ما در مقایسه با ۰.۶۶۱۷ از مقاله پایه، قابلیت تمایز برتر رویکرد ما را برجسته می‌کند. این بهبود تأیید می‌کند که پیش پردازش ما به مدل اجازه می‌دهد تا بین گروه‌های MCI و HC تمایز بهتری داشته باشد.

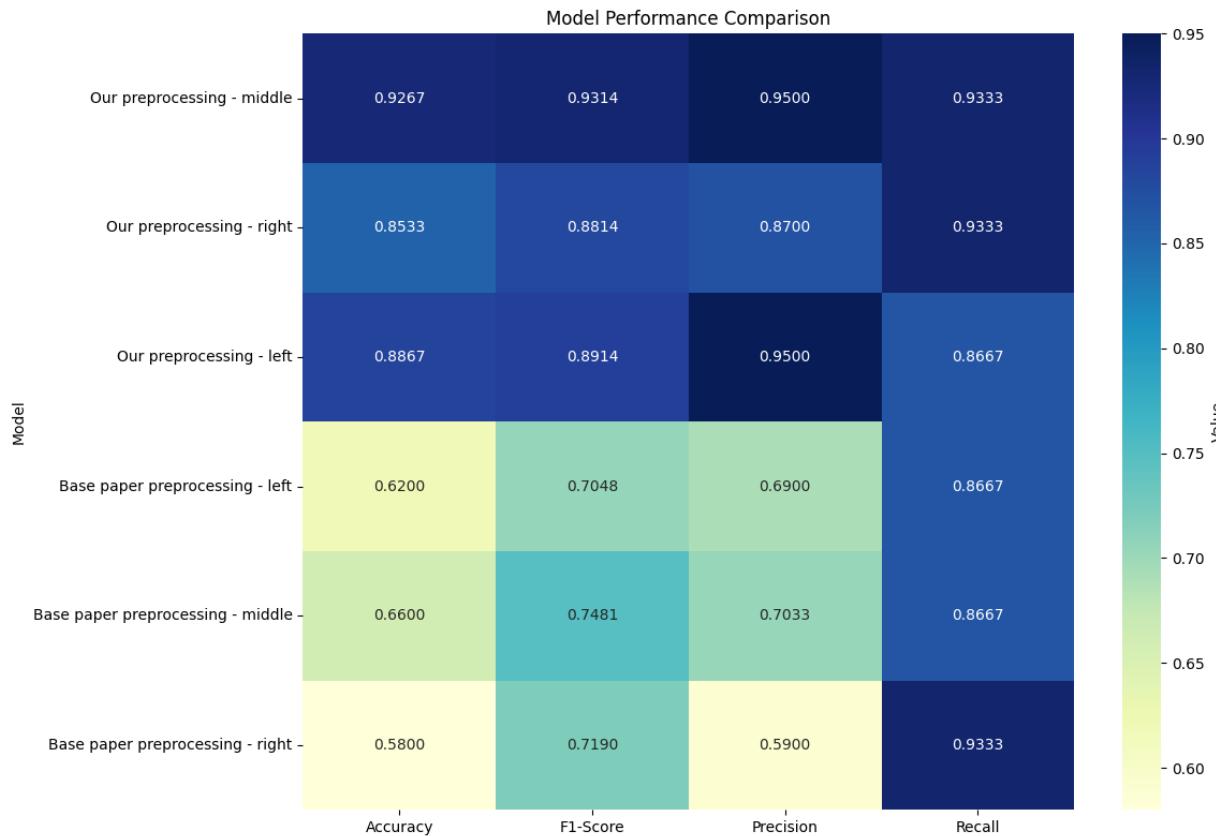
تجزیه و تحلیل مقایسه‌ای عملکرد XGBoost نشان می‌دهد که روش پیش پردازش پیشنهادی ما به طور مداوم از رویکرد مقاله پایه در تمام معیارهای کلیدی، از جمله صحت، امتیاز F1، دقت، فراخوانی و AUC بهتر عمل می‌کند. این نتایج نشان می‌دهد که تکنیک پیش پردازش ما در پالایش داده‌ها، بهبود کیفیت سیگنال و استخراج ویژگی‌های مرتبط برای طبقه‌بندی مؤثرer است. در نتیجه، نتایج تایید می‌کنند که روش پیش پردازش ما پیشرفت قابل توجهی را نسبت به رویکرد مقاله پایه ارائه می‌کند. این پیشرفت نه تنها عملکرد مدل‌های یادگیری ماسیونی مانند XGBoost را افزایش می‌دهد، بلکه پیامدهای گسترده‌تری برای توسعه ابزارهای تشخیصی مطمئن‌تر و دقیق‌تر در تحقیقات مبتنی بر تصویربرداری عصبی دارد.

۴-۳-۲- مقایسه با نتایج مقاله پایه

در این بخش، عملکرد مدل پیشنهادی خود را که از یک شبکه عصبی گراف زمانی استفاده می‌کند، با مدل‌های مورد استفاده در مقاله پایه، به ویژه مدل‌های یادگیری (GraphConvGRU)

^۱ Area Under the Curve

انتقالی^۱ (VGG19) و مدل‌های یادگیری ماشین سنتی KNN، LDA، SVM مقایسه می‌کنیم. رویکرد ما بر طبقه‌بندی افراد مبتلا به اختلال شناختی خفیف (MCI) و کنترل سالم (HC) با استفاده از یک استراتژی پیش‌پردازش داده بهتر و طبقه‌بندی مبتتنی بر گراف زمانی، با هدف پیشی گرفتن از مدل‌های به کار رفته در مطالعه پایه تمرکز دارد.

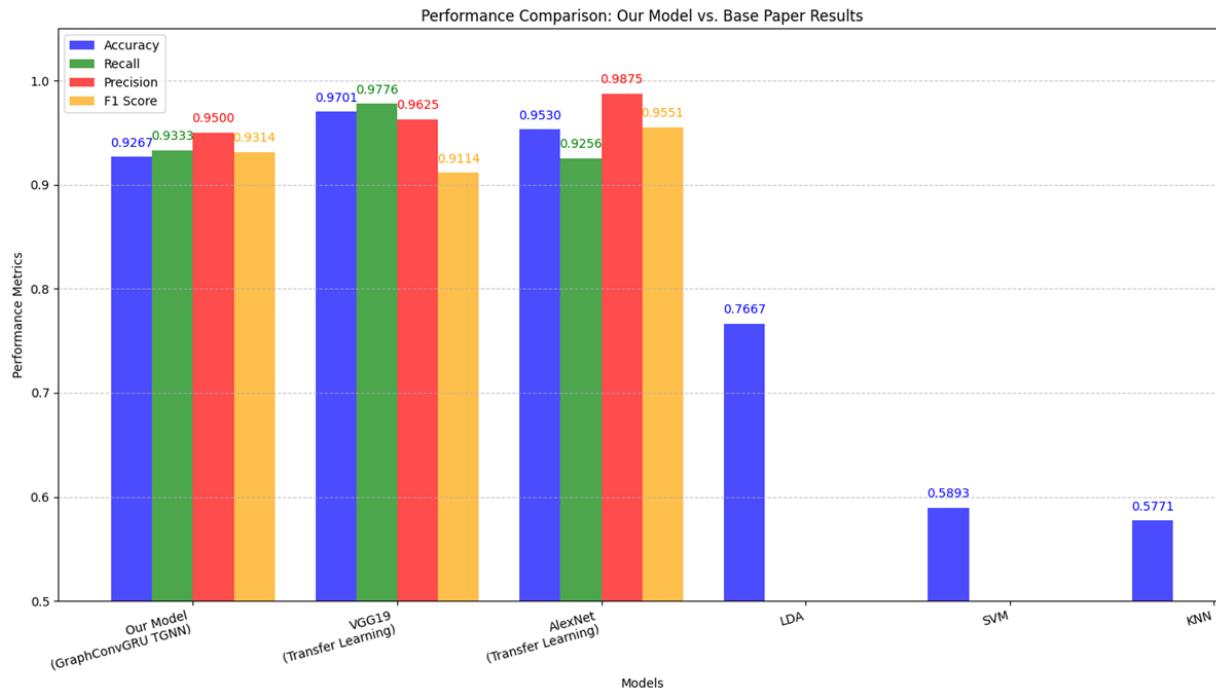


شکل ۴-۶) عملکرد مدل پیشنهادی در دو مجموعه داد و نواحی مختلف پیشانی

مطالعه ما با ارزیابی عملکرد مدل GraphConvGRU در دو رویکرد پیش‌پردازش متمایز آغاز شد: روش جدید ما و رویکرد مورد استفاده در مقاله پایه. این مقایسه برای درک تأثیر پیش‌پردازش بر عملکرد مدل بسیار مهم است. شکل ۴-۶، معیارهای عملکرد مدل GraphConvGRU ما را با استفاده از هر دو روش پیش‌پردازش نشان می‌دهد. همانطور که از نقشه حرارتی مشهود است، رویکرد پیش‌پردازش ما به طور مداوم از روش مقاله پایه در تمام معیارها و مناطق قشر جلوی پیشانی (PFC) بهتر عمل می‌کند. این پیشرفت بر اهمیت پیش‌پردازش موثر در تجزیه و تحلیل داده‌های fNIRS برای طبقه‌بندی MCI تاکید می‌کند. یک یافته قابل توجه از تجزیه و تحلیل ما عملکرد برتر در ناحیه قشر پیشانی میانی (PFC) در مقایسه با PFC چپ و راست است. دو ناحیه چپ و راست قشر جلوی پیشانی (PFC) تقریباً یکسان ظاهر شدند. یکی از نوآوری‌های این مطالعه بررسی نواحی مختلف قشر جلوی پیشانی است. با توجه به شکل ۴-

¹ Transfer Learning

۶ PFC میانی به طور مداوم عملکرد بالاتری را در تمام معیارها نشان می‌دهد، که نشان می‌دهد این منطقه ممکن است دارای ویژگی‌های متمایز‌کننده‌تری برای طبقه‌بندی MCI با استفاده از داده‌های fNIRS باشد.



شکل ۷-۴) مقایسه عملکرد مدل پیشنهادی با دو مدل برتر مقاله پایه (یادگیری انتقالی^۱) و روش‌های یادگیری ماشین پایه

شکل ۷-۴) مقایسه ای بین مدل ما و رویکردهای یادگیری انتقال (VGG19 و AlexNet) مورد استفاده در مقاله پایه ارائه می‌کند. در حالی که مدل‌های یادگیری انتقالی دقیق‌تر کمی بالاتری را نشان می‌دهند، مدل GraphConvGRU ما عملکرد رقابتی را نشان می‌دهد، به ویژه از نظر معیارهای سراسر دقیق، یادآوری، صحت و امتیاز F1 متعادل‌تر از دو مدل مقاله پایه است.

مدل ما به طور قابل توجهی بهتر از روش‌های یادگیری ماشین سنتی مورد استفاده در مقاله پایه است. بهبود قابل توجه در دقیق‌تر (بیش از ۲۹ درصد) اثربخشی رویکرد ما را در مقایسه با تکنیک‌های یادگیری ماشین معمولی برجسته می‌کند.

در حالی که مدل‌های یادگیری انتقال در برخی موارد دقیق‌تر از خود نشان داشند، مدل GraphConvGRU ما چندین مزیت قابل توجه ارائه می‌دهد:

- عملکرد متعادل: مدل ما عملکرد سازگارتر و متعادل‌تری را در تمام معیارها نشان می‌دهد.
- این تعادل در کاربردهای بالینی که هر دو مثبت کاذب و منفی کاذب می‌توانند عواقب قبل توجهی داشته باشند بسیار مهم است.

¹ Transfer Learning

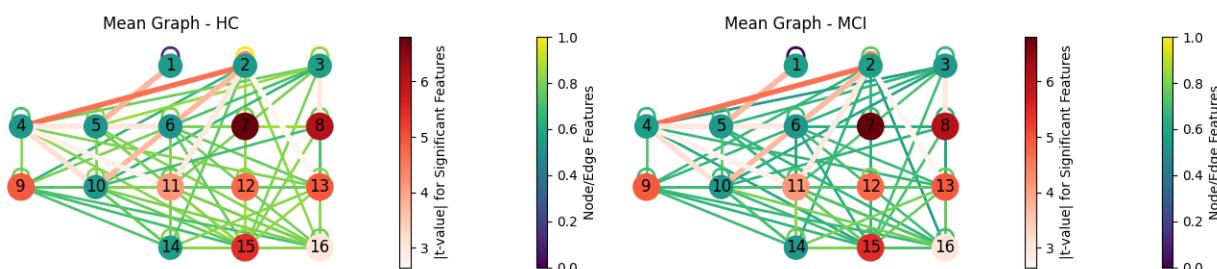
- دینامیک زمانی: برخلاف مدل های یادگیری انتقا ، GraphConvGRU ما می تولند دینامیک زمانی داده های fNIRS را که برای طبقه بندی دقیق MCI ضروری است، ضبط کرده و از آن استفاده کند. این توانایی برای مدل سازی الگوهای فعالیت مغز وابسته به زمان، یک مزیت کلیدی در تحلیل تصویربرداری عصبی است.
- معماری خاص: مدل ما به طور خاص برای داده های fNIRS طراحی شده است، برخلاف مدل های یادگیری انتقال که از قبل بر روی مجموعه داده های تصویر عمومی آموزش دیده اند. این تخصص امکان استخراج ویژگی های ظرفیتری را که متناسب با داده های تصویربرداری عصبی است، فراهم می کند.
- کارایی محاسباتی: در مقایسه با مدل های یادگیری انتقال عمیق مانند VGG19 و AlexNet، GraphConvGRU ما به پارامترهای کمتر و منابع محاسباتی کمتری نیاز دارد و آن را برای برنامه های بالینی مناسب تر می سازد که در آن تجزیه و تحلیل سریع و کارآمد منابع بسیار مهم است.
- تفسیرپذیری: مدل های مبتنی بر گراف اغلب قابلیت تفسیر بهتری را در مقایسه با مدل های یادگیری عمیق جعبه سیاه ارائه می دهند. این تفسیرپذیری در کاربردهای پزشکی ارزشمند است و به طور بالقوه بینش هایی را در مورد الگوهای عصبی مرتبط با MCI ارائه می دهد.
- سازگاری: رویکرد ما می توان به راحتی با ساختارهای داده های مختلف fNIRS و طرح های تجربی تطبیق داد و آن را برای مطالعات مختلف علوم اعصاب گسترش داد.
- یادگیری سرتاسری: مدل ما مستقیماً از داده های fNIRS از پیش پردازش شده یاد می گیرد، و به طور بالقوه الگوهای ظرفی را که ممکن است رویکردهای یادگیری انتقالی (که بر استخراج کننده های ویژگی از پیش آموزش دیده تکیه می کنند) از دست بدهنند، می آموزد. در نتیجه، در حالی که مدل های یادگیری انتقال دقت کمی بالاتری را در برخی از معیارها نشان دادند، مدل GraphConvGRU ما یک رویکرد متعادل تر، تخصصی تر و قابل تفسیرتر برای طبقه بندی MCI با استفاده از داده های fNIRS ارائه می دهد. عملکرد رقابتی، همراه با توانایی ثبت پویایی های زمانی و مزایای عملی متعدد، مدل ما را به عنوان یک ابزار ارزشمند هم برای کاربردهای بالینی و هم برای تحقیقات بیشتر در تشخیص اختلالات شناختی قرار می دهد.

۴-۵- تحلیل نتایج و جمع بندی

در این بخش، نتایج مدل پیشنهادی خود را تجزیه و تحلیل می کنیم و عملکرد رویکرد خود را با مدل های مقاله پایه مقایسه می کنیم. مطالعه ما بر طبقه بندی گروه های اختلال شناختی خفیف (MCI) و کنترل سالم (HC) با استفاده از داده های هموگلوبین اکسیژن دار (HbO) و هموگلوبین بدون اکسیژن

(HbR)، در کنار تکنیک‌های پیش پردازش نوآورانه و شبکه‌های عصبی گراف زمانی متمرکز بود. گنجاندن داده‌های HbR و رویکردهای پیش‌پردازش پیش‌رفته به طور قابل توجهی توانایی مدل را برای گرفتن الگوهای عصبی معنی دار در شرایط حالت استراحت، افزایش داد. به طور سنتی، اکثر مطالعات تصویربرداری عصبی، داده‌های HbO را به دلیل همبستگی قوی آن با فعالیت عصبی در اولویت قرار می‌دهند و از داده‌های HbR استفاده نمی‌کنند. با این حال، تجزیه و تحلیل ما نشان داد که داده‌های HbR اطلاعات اضافی و معنی داری را ارائه می‌دهد که به طور قابل توجهی MCI را از HC در شرایط حالت استراحت متمایز می‌کند. ادغام داده‌های HbO و HbR به مدل ما اجازه داد تا نمای جامع‌تری از همودینامیک مغزی را به تصویر بکشد و عملکرد طبقه‌بند را افزایش دهد.

روش پیشنهادی پیش‌پردازش ما، از جمله فیلتر سیگنال، کاهش نویز، و ساخت گراف زمانی، در بهینه سازی کیفیت داده‌های ورودی بسیار مهم بودند. این مراحل پیش‌پردازش منجر به نمایش دقیق‌تر و قابل اطمینان‌تر از تعاملات عصبی، برخلاف روش‌های پیش‌پردازش ساده‌تر مورد استفاده در مقاله پایه شد. نتایج ما قویاً نشان می‌دهد که روش‌های پیش‌پردازش صرفاً مراحل آماده‌سازی نیستند، بلکه برای موفقیت کلی حالت ضروری هستند. استفاده از گراف‌های زمانی به ما این امکان را داد تا روابط پویا بین نواحی مغز را مدل کنیم و جنبه‌های عملکردی و ساختاری تعاملات عصبی را به تصویر بکشیم. برخلاف ویژگی‌های ثابتی که در مدل‌های یادگیری ماشین سنتی استفاده می‌شود، گراف‌های زمانی چارچوبی برای ارزیابی تغییرات در طول زمان ارائه می‌کنند که منجر به درک عمیق‌تری از نحوه ارتباط مناطق مختلف مغز در MCI در مقابل HC می‌شود.

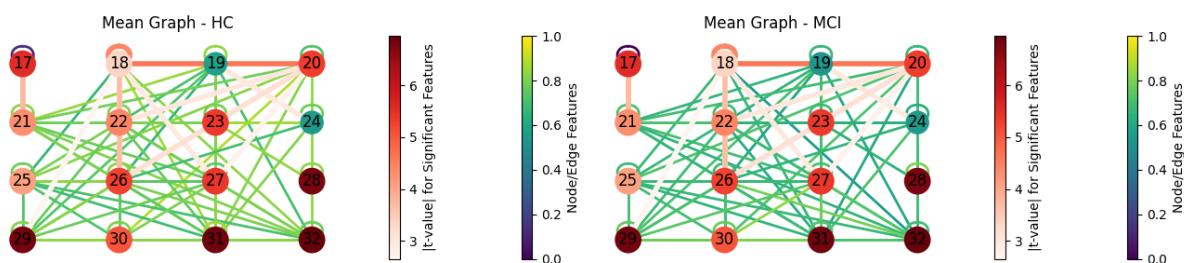


شکل ۸-۴ مقایسه میانگین ویژگی‌ها و روابط کanal‌ها در دو گروه در قسمت راست پیشانی

شکل ۸-۴ و جدول ۴-۱ نمایانگر تفاوت‌های دو گروه در میانگین ویژگی‌های انتخاب شده است. یال‌ها و گره‌هایی که طیف رنگ قرمز را دارند کانال‌ها و روابطی هستند که تفاوت قابل ملاحظه‌ای بین دو گروه ایجاد کرده‌اند. با استفاده از ازمون Mann Whitney با سطح معنادار ۰.۰۱ یال‌ها و گره‌هایی که تفاوت معناداری ایجاد کرده‌اند مشخص شدند. با بررسی شکل متوجه می‌شویم که کانال‌های مرکزی سمت راست پیشانی جلویی تفاوت عمدی را در سمت راست پیشانی جلویی ایجاد کرده‌اند. درحالی که افراد کنترل سالم دارای روابط عملکردی قوی تری بین کانال‌ها هستند.

جدول ۱۰-۴) مقایسه میانگین تمام ویژگی‌های گره‌های بین دو گروه در قسمت راست پیش‌پیشانی

Node	Node Feature (MCI)	Node Feature (HC)	t-value	p-value	Significant
1	0.08523711	0.07489523	0.9106	0.3629	FALSE
2	0.08719321	0.06984132	1.8094	0.0709	FALSE
3	0.06923558	0.09255166	-2.0501	0.0408	FALSE
4	0.08045265	0.06221421	1.5409	0.1239	FALSE
5	0.06512415	0.05705543	0.914	0.3611	FALSE
6	0.05836861	0.04062972	2.2049	0.0278	FALSE
7	0.05311354	0.1399346	-6.7978	0	TRUE
8	0.04559474	0.11256568	-6.0994	0	TRUE
9	0.10622485	0.04958991	4.9114	0	TRUE
10	0.05998698	0.05864417	0.1513	0.8798	FALSE
11	0.03318002	0.06318206	-4.1283	0	TRUE
12	0.05255136	0.10612094	-4.7347	0	TRUE
13	0.04541551	0.10992646	-4.9299	0	TRUE
14	0.05880383	0.08106507	-2.3817	0.0175	FALSE
15	0.06287085	0.12874848	-5.4592	0	TRUE
16	0.03752342	0.06062393	-3.038	0.0025	TRUE

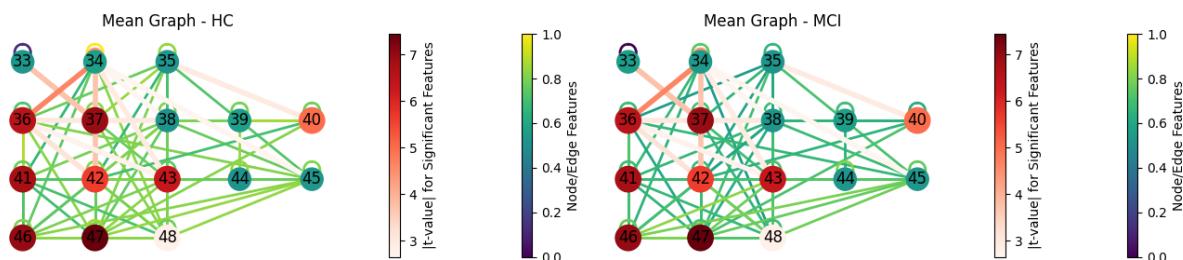


شکل ۱۰-۴) مقایسه میانگین ویژگی‌ها و روابط کanal‌ها در دو گروه در قسمت میانی پیشانی

شکل ۹-۴ و جدول ۲-۴ تفاوت‌های دو گروه در میانگین ویژگی‌های انتخاب شده نشان می‌دهد. یال‌ها و گره‌هایی که طیف رنگ قرمز را دارند کanal‌ها و روابطی هستند که تفاوت قابل ملاحظه‌ای بین دو گروه ایجاد کرده‌اند. با بررسی شکل متوجه می‌شویم که تقریباً تمام کanal‌های مرکزی پیشانی جلویی تفاوت چشمگیری را بین دو گروه در خودجای داده‌اند. در حالی که افراد کنترل سالم مانند قسمت راستی پیشانی جلویی دارای روابط عملکردی قوی تری بین کanal‌ها هستند.

جدول ۲۰-۴) مقایسه میانگین تمام ویژگی‌های گره‌های بین دو گروه در قسمت میانی پیش‌پیشانی

Node	Node Feature (MCI)	Node Feature (HC)	t-value	p-value	Significant
17	0.03517371	0.08966658	-5.5751	0	TRUE
18	0.05865122	0.09633609	-3.3426	0.0009	TRUE
19	0.05356162	0.08827149	-2.2781	0.0231	FALSE
20	0.02254949	0.05101791	-5.334	0	TRUE
21	0.05490535	0.1079014	-4.3028	0	TRUE
22	0.04333774	0.10472214	-4.4358	0	TRUE
23	0.03724355	0.11529058	-5.3627	0	TRUE
24	0.06753084	0.06435019	0.2159	0.8291	FALSE
25	0.04120316	0.0756516	-4.0939	0	TRUE
26	0.02888062	0.08022343	-5.2587	0	TRUE
27	0.02214536	0.06901287	-5.4016	0	TRUE
28	0.04291783	0.12534133	-6.776	0	TRUE
29	0.02109206	0.06593862	-6.8238	0	TRUE
30	0.07054478	0.14639364	-5.042	0	TRUE
31	0.04396729	0.12624028	-6.8664	0	TRUE
32	0.04155471	0.10609178	-6.9537	0	TRUE



شکل ۲۰-۴) مقایسه میانگین ویژگی‌ها و روابط کاتال‌ها در دو گروه در قسمت چپ پیشانی

شکل ۲۰-۴ و جدول ۲۰-۴ تفاوت‌های دو گروه در میانگین ویژگی‌های انتخاب شده نشان می‌دهد. یال‌ها و گره‌هایی که طیف رنگ قرمز را دارند کانال‌ها و روابطی هستند که تفاوت قابل ملاحظه‌ای بین دو گروه ایجاد کرده‌اند. با بررسی شکل متوجه می‌شویم که مانند قسمت راست پیشانی جلویی اکثر کانال‌های مرکزی قسمت چپ پیشانی جلویی تفاوت چشمگیر را بین دو گروه بوجود آورده است. در حالی که افراد کنترل سالم مانند قسمت راستی و مرکزی پیشانی جلویی دارای روابط عملکردی قوی‌تری بین کانال‌ها هستند.

جدول ۴-۳) مقایسه میانگین تمام ویژگی‌های گره‌های بین دو گروه در قسمت چپ پیش‌بیانی

Node	Node Feature (MCI)	Node Feature (HC)	t-value	p-value	Significant
33	0.07912548	0.0562975	2.0537	0.0404	FALSE
34	0.06849628	0.08553663	-1.5011	0.1338	FALSE
35	0.0513323	0.05083762	0.0496	0.9604	FALSE
36	0.03408295	0.09142266	-6.5182	0	TRUE
37	0.02938361	0.08611702	-6.9657	0	TRUE
38	0.05543506	0.04059904	1.8382	0.0665	FALSE
39	0.0860775	0.08241398	0.2916	0.7707	FALSE
40	0.06981661	0.02638013	4.9876	0	TRUE
41	0.05327187	0.14550598	-6.7854	0	TRUE
42	0.04276358	0.0907331	-5.6384	0	TRUE
43	0.03873217	0.091386	-6.3168	0	TRUE
44	0.0513139	0.0481681	0.3984	0.6905	FALSE
45	0.05906174	0.06264	-0.3225	0.7472	FALSE
46	0.03219261	0.08358015	-7.0021	0	TRUE
47	0.04557621	0.1256678	-7.4366	0	TRUE
48	0.0284096	0.04501208	-2.7812	0.0056	TRUE

مطالعه ما یک مورد قانع‌کننده برای اثربخشی استفاده از داده‌های HbO و HbR در ارتباط با تکنیک‌های پیش‌پردازش پیشرفت‌هه و شبکه‌های عصبی گراف زمانی ارائه می‌کند. ترکیبی از این رویکردها به ما این امکان را می‌دهد که اطلاعات دقیق و مرتبط بالینی را که اغلب در مدل‌های سنتی نادیده گرفته می‌شوند، به دست آوریم.

جدول ۴-۴) مقایسه میانگین ویژگی‌های سیگنال در دو گروه

Attribute	HC Average	MCI Average	P-Value	Significant
min	-0.2753796	-0.1441837	2.16E-85	Significant
max	0.28359536	0.14474167	6.55E-88	Significant
mean	-1.01E-19	6.42E-19	0.81006306	Not Significant
std	0.10607179	0.05642898	4.06E-86	Significant
slope	-6.72E-22	-7.44E-22	0.91741348	Not Significant

یافته‌ها نشان می‌دهند که مدل ما با استفاده از نقاط قوت منحصر به فرد تجزیه و تحلیل گراف زمانی، عملکرد بهتری از روش‌های پایه دارد، و ابزاری قوی و قابل اعتماد برای تمایز MCI از HC ارائه

می‌کند. در نتیجه، ادغام پردازش داده‌های پیچیده، استخراج ویژگی مبتنی بر گراف، و اطلاعات جامع همودینامیک به طور قابل توجهی توانایی ما را برای طبقه بندی دقیق حالات شناختی ارتقا داده است. این تحقیق اهمیت استفاده از رویکردهای مناسب برای داده‌های تصویربرداری عصبی، به ویژه در هنگام بررسی اختلالات پیچیده مانند MCI را برجسته می‌کند.

مطالعه ما مزایای استفاده از داده‌های HbR، تکنیک‌های پیش‌پردازش، و شبکه‌های عصبی گراف زمانی را برای طبقه‌بندی حالت‌های شناختی برجسته می‌کند. یافته‌ها بر چندین نکته حیاتی تأکید می‌کنند:

- شبکه‌های عصبی گراف زمانی (TGNN) برای ثبت روابط پیچیده و پویا در داده‌های عصبی بسیار مؤثر هستند و آن‌ها را به ویژه برای کاربردهای علوم اعصاب ارزشمند می‌سازند. TGNN‌ها نمای دقیقی از اتصال مغز ارائه می‌دهند که می‌تواند تفاوت‌های ظریف در عملکرد عصبی را آشکار کند و توانایی ما را برای طبقه‌بندی و درک شرایط عصبی مانند MCI افزایش دهد.
- داده‌های HbR در حالت استراحت معنی‌دار هستند: استفاده از داده‌های HbR در کنار داده‌های HbO بینش بیشتری در مورد عملکرد مغز، به ویژه در شرایط استراحت، ارائه می‌دهد. این رویکرد دوگانه به ما این امکان را می‌دهد که طیف وسیع‌تری از تغییرات همودینامیک را ثبت کنیم و دقت مدل طبقه‌بندی خود را بهبود ببخشیم.
- رویکردهای پیش‌پردازش بسیار مهم هستند: پیش‌پردازش پیشرفته نقشی اساسی در بهبود عملکرد مدل ایفا می‌کند. روش پیش‌پردازش پیشنهادی ما کیفیت داده‌ها را بهبود بخشید، امکان استخراج دقیق تری از ویژگی‌ها را فراهم کرد و در نهایت منجر به نتایج طبقه‌بندی بهتر شد. این امر اهمیت طراحی دقیق مراحل پیش‌پردازش برای بهینه سازی اطلاعات وارد شده به مدل‌ها را برجسته می‌کند.
- ناحیه میانی پیش‌پیشانی: طبق بررسی مدل ما بهترین عملکرد را از کانال‌های میانی قسمت پیش‌پیشانی بدست آورد. یکی از دلیل‌های عملکرد بهتر این ناحیه نسبت به بقیه قسمت‌ها می‌تواند ورود نور محیطی کمتر به این ناحیه و کمتر بودن نویز کلنان‌های این ناحیه نسبت به نواحی چپ و راست پیش‌پیشانی می‌توان عنوان کرد. چندین مطالعه [134] [133] [135] که از fMRI برای به بررسی اختلال شناختی خفیف یا آلزایمر در حالت استراحت پرداخته‌اند به این ناحیه از پیش‌پیشانی اشاره کرده‌اند و این ناحیه را جز مناطقی مشخص کرده‌اند که تفاوت عملکردی بین افراد دارای اختلال شناختی خفیف با افراد سالم هست. البته به دلیل عمق نفوذ کمتر fNIRS نسبت به fMRI مطالعه این ناحیه با دستگاه fNIRS به بررسی بیش‌تری نیاز دارد.
- عملکرد متفاوت دوگروه: با توجه به میانگین ویژگی‌های گره‌ها و یال‌های میان آن‌ها، همانطور که در شکل‌های ۴-۸، ۴-۹ و ۴-۱۰ مشخص شده است، افراد دارای اختلال

شناختی خفیف دارای میانگین پایین‌تری از ویژگی‌های عملکردی (یال‌ها) نسبت به افراد کنترل سالم هستند. این الگو در تمامی نواحی پیش‌پیشانی دیده می‌شود. علاوه بر این موارد، طبق جدول ۴-۴ داده‌های افراد کنترل سالم دارای حداکثر و حداقل بزرگتری (قدر مطلق آن) نسبت به افراد دارای اختلال شناختی خفیف است. افراد کنترل سالم همچنین دارای انحراف معیار بیشتری نسبت به گروه دارای اختلال شناختی خفیف هستند و این نشان‌دهنده ثبات بیشتر تغییرات HbO, HbR در افراد MCI هست.

در نتیجه، ترکیبی از یکپارچه سازی داده‌ها، پیش‌پردازش، و مدل سازی گراف زمانی به طور قابل توجهی توانایی ما را برای طبقه بندی MCI و HC افزایش می‌دهد. این یافته‌ها نه تنها اثربخشی رویکرد ما را تأیید می‌کند، بلکه زمینه را برای تحقیقات آینده با استفاده از TGNN در علوم اعصاب فراهم می‌کند و پتانسیل این روش‌ها را برای ارائه بینش عمیق‌تر در مورد عملکرد مغز و سلامت شناختی تقویت می‌کند.

فصل ۵: جمع‌بندی و پیشنهاد‌ها

۱-۵ - مقدمه

هدف این فصل ارائه یک نمای کلی جامع از یافته‌های تحقیق ما، با تأکید بر مشارکت‌های جدید، نتایج کلیدی و پیامدهای عملی است. کار ما بر روی تشخیص اختلال شناختی خفیف (MCI) با استفاده از داده‌های طیف‌سنجی مادون قرمز نزدیک (fNIRS)، استفاده از تکنیک‌های پیش‌پردازش پیشرفته و استفاده از شبکه‌های عصبی گراف زمانی (TGNN) متمرکز بود. این مطالعه مهم است زیرا به نیاز به روش‌های تشخیص زودهنگام، غیرتهاجمی و دقیق برای MCI، پیش‌ساز بیماری آلزایمر که به طور قبلی توجهی بر سلامت شناختی در جمعیت‌های مسن تأثیر می‌گذارد، می‌پردازد. ما از یک رویکرد منحصر به‌فرد استفاده کردیم که سیگنال‌های اکسی هموگلوبین (HbO) و دئوکسی هموگلوبین (HbR) را با هم ترکیب می‌کرد و نشان می‌داد که HbR، که اغلب در مطالعات سنتی نادیده گرفته می‌شود، اطلاعات ارزشمندی به‌ویژه در اندازه‌گیری‌های حالت استراحت ارائه می‌دهد. این رویکرد دوگانه به ما امکان داد تا طیف وسیع تری از تغییرات همودینامیک را ثبت کنیم، در نتیجه استحکام طبقه بندی MCI را بهبود بخشد. علاوه بر این، تحقیقات ما یک خط لوله پیش‌پردازش نواورانه را معرفی کرد که با روش‌های مرسوم متفاوت بود و تکنیک‌های حذف مصنوع پیشرفته و تقویت سیگنال را در خود جای داد. این پیش‌پردازش برای افزایش کیفیت داده و در نتیجه، عملکرد مدل TGNN ما بسیار مهم بود. چارچوب TGNN در مدل‌سازی پویایی‌های زمانی و مکانی فعالیت مغز به‌ویژه قدرتمند بود و عملکرد برتر را در مقایسه با مدل‌های یادگیری ماشین سنتی مورد استفاده در مطالعات پایه نشان داد. با ساختن گراف‌های زمانی، می‌توانیم به طور موثر روابط پیچیده بین نواحی مغز را به تصویر بکشیم، گره‌ها و اتصالات حیاتی را شناسایی کنیم که بین MCI و کنترل‌های سالم (HC) تفاوت دارند.

علاوه بر این، تجزیه و تحلیل ما نشان داد که قشر پیش‌پیشانی میانی (PFC) نقش مهمی در تمایز MCI از HC ایفا می‌کند و اهمیت تجزیه و تحلیل هدفمند مناطق مغز را در علوم اعصاب شناختی برجسته می‌کند. یافته‌ها بر اثربخشی TGNN در کاربردهای علوم اعصاب، به‌ویژه برای درک پویایی‌های پیچیده مغز و تشخیص حالات پاتولوژیک تأکید می‌کنند.

در این فصل، ما همچنین محدودیت‌های مطالعه خود را مورد بحث قرار می‌دهیم، مانند محدودیت‌های دستگاه fNIRS مورد استفاده و اندازه داده نسبتاً کوچک، و پیشنهاداتی را برای جهت‌های تحقیقاتی آینده ارائه می‌کنیم که می‌تواند کارایی و کاربرد روش‌های پیشنهادی ما را بیشتر افزایش دهد.

۵-۲- نوآوری

نوآوری اصلی مطالعه ما در ادغام چندین روش برای بهبود تشخیص MCI نهفته است:

- استفاده از شبکه‌های عصبی گراف زمانی (TGNN): ما از TGNN برای تجزیه و تحلیل داده‌های fNIRS استفاده کردیم و ویژگی‌های زمانی و مکانی فعالیت مغز را ثبت کردیم. این رویکرد ما را قادر ساخت تا تعاملات عصبی پیچیده را مدل‌سازی کنیم و عملکرد طبقه‌بندی را در مقایسه با مدل‌های یادگیری ماشین سنتی افزایش دهیم.
- استراتژی انتخاب ویژگی: ما ویژگی‌ها را بر اساس وزن XGBoost و نتایج آماری از آزمون من ویتنی انتخاب کردیم. این فرآیند انتخاب تضمین کرد که مرتبط ترین و متمایزترین ویژگی‌ها در مدل گنجانده شده است و دقت نتایج طبقه‌بندی ما را بهبود می‌بخشد.
- گنجاندن داده‌های HbR: در حالی که HbO معمولاً در تصویربرداری عصبی استفاده می‌شود، مطالعه ما داده‌های HbR را شامل می‌شود که نشان می‌دهد حاوی اطلاعات معنی داری در طول اندازه گیری‌های حالت استراحت است. ترکیب HbO و HbR دید جامع تری از تغییرات همودینامیک مرتبط با MCI ارائه کرد.
- رویکرد پیش پردازش جدید: تکنیک‌های پیش پردازش ما متمایز از روش‌های سنتی بود و بر فیلتر کردن پیشرفت و استراتژی‌های حذف مصنوعات تمرکز داشت. این رویکرد مناسب به طور قلبل توجهی کیفیت سیگنال‌های fNIRS را بهبود بخشید و عملکرد کلی مدل TGNN را افزایش داد.
- شناسایی مناطق بحرانی مغز: تجزیه و تحلیل ما قشر پیش پیشانی میانی (PFC) را به عنوان یک منطقه بحرانی که در آن مهم ترین تفاوت بین MCI و HC مشاهده شد، بررسی کرد. این یافته بر نقش مناطق خاص مغز در زوال شناختی تاکید می‌کند و از رویکردهای هدفمند برای تحقیقات آینده پشتیبانی می‌کند.

۳-۵- محدودیت‌ها

علیرغم نتایج امیدوارکننده، مطالعه ما با چندین محدودیت رو برو بود:

- محدودیت‌های دستگاه fNIRS: دستگاه fNIRS مورد استفاده در مطالعه ما فاقد کanal‌های

- جداسازی کوتاه^۱ بود که برای حذف مؤثر نویز خارج مغزی از سیگنال‌ها بسیار مهم است [136]. این محدودیت به طور بالقوه بر دقت نتایج ما تأثیر می‌گذارد زیرا سیگنال‌های خارج مغزی مانند امواج فشار خون، تنفس و ضربان قلب نمی‌توانند به طور کامل فیلتر شوند.
- پوشش محدود مناطق مغز: دستگاه ما داده‌های کل سر را نمی‌گیرد و تجزیه و تحلیل را به مناطق خاصی از مغز محدود می‌کند. یک پوشش جامع تر احتمالاً نمایش دقیق تری از عملکرد مغز ارائه می‌دهد و تمایز بین MCI و HC را بهبود می‌بخشد.
 - عدم داده‌های چندوجهی: ترکیب fNIRS با سایر روش‌های تصویربرداری عصبی مانند EEG می‌تواند قابلیت‌های تشخیص را با ارائه اطلاعات تکمیلی در مورد فعالیت مغز افزایش دهد. فقدان داده‌های EEG در مطالعه ما یک محدودیت قابل توجه بود که می‌تواند در تحقیقات آینده مورد توجه قرار گیرد.
 - مجموعه داده کوچک: مجموعه داده ما نسبتاً کوچک بود که استحکام و قابلیت تعمیم یافته‌ها را محدود می‌کرد. مجموعه داده‌های بزرگ‌تر برای آموزش مدل‌های پیچیده‌تر و اعتبارسنجی نتایج در میان جمعیت‌های مختلف ضروری هستند.

۴-۵- پیشنهادها

بر اساس یافته‌ها و محدودیت‌های مطالعه ما، توصیه‌های زیر را برای تحقیقات آتی پیشنهاد می‌کنیم:

- ترکیب داده‌های EEG و fNIRS: ترکیب داده‌های EEG و fNIRS می‌تواند نمای کلی تری از فعالیت عصبی ارائه دهد و تغییرات الکتریکی و همودینامیک مغز را ثبت کند. این رویکرد چندوجهی می‌تواند دقت طبقه‌بندی حالت شناختی را بهبود بخشد و بینش عمیق‌تری در مورد مکانیسم‌های MCI ارائه دهد.
- استفاده از کanal‌های جداسازی کوتاه: کanal‌های جداسازی کوتاه برای حذف سیگنال‌های خارج مغزی ضروری هستند و در نتیجه کیفیت داده‌های fNIRS را افزایش می‌دهند. پیشنهاد می‌شود مطالعات آینده از دستگاه‌های مجهز به کanal‌های کوتاه برای جداسازی مؤثرتر فعالیت مغزی از منابع نویز استفاده کنند.
- پوشش کامل سر با دستگاه‌های پیشرفته fNIRS: قشر جلوی پیشانی از مزايا بدون موی پوشاننده برخوردار است، که می‌تواند اثرات پراکنده‌گی و ضعیف نور شدن را کاهش دهد. این مطالعه فقط وضعیت استراحت در قشر جلوی مغز را بررسی می‌کند. با این حال نشان داده شد که شبکه حالت پیش فرض ممکن است امکان بالایی برای شناسایی نشانگرهای زیستی

¹ Short Separation Channels

مفید برای تشخیص MCI داشته باشد. استفاده از دستگاه‌های fNIRS که می‌تواند داده‌های کل سر را ضبط کنند، ارزیابی کامل تری از عملکرد مغز ارائه می‌دهند و امکان تمایز دقیق تر MCI از HC را فراهم می‌کنند. پوشش کامل سر همچنین می‌تواند شناسایی مناطق اضافی مغز را که در زوال شناختی دخیل هستند، تسهیل کند.

- مجموعه داده‌های بزرگتر و متنوع: گسترش مجموعه داده به گونه‌ای که جمعیتی بزرگتر و متنوع تر را شامل شود، یافته‌ها را تقویت کرده و تعمیم پذیری نتایج را بهبود می‌بخشد. تحقیقات آینده باید بر گرداوری مجموعه داده‌های گستردۀ ای متتمرکز شود که ویژگی‌های جمعیت شناختی و بالینی مختلف را در بر می‌گیرد.
- تکنیک‌های پیش پردازش پیشرفته: اصلاح مداوم روش‌های پیش پردازش برای بهینه سازی کیفیت داده‌ها بسیار مهم است. مطالعات آتی باید استفاده از روش‌های فیلترینگ پیشرفته و کاهش نویز را بررسی کنند.
- افزایش قابلیت تفسیرپذیری مدل: برای بهبود کاربرد بالینی مدل پیشنهادی، بررسی روش‌های تفسیرپذیر مناسب شبکه‌های گراف زمانی در تصویربرداری عصبی می‌تواند به کاربرد بالینی این روش و افزایش دانش در این زمینه کمک کند، مانند استفاده از:
 ۱. تجسم الگوهای زمانی فعالیت و اتصال مغز
 ۲. تکنیک‌های مختلف هوش مصنوعی قابل توضیح (مانند LIME، SHAP)

اگرچه مدل پیشنهادی ما دقت تشخیص رضایت‌بخشی را ارائه می‌کند اما محدودیت‌هایی برای این مطالعه وجود دارد. مطالعه ما پتانسیل TGNN، پیش پردازش پیشرفته، و ادغام داده‌های HbR برای تشخیص MCI را نشان می‌دهد. علیرغم برخی محدودیت‌ها، روش‌های پیشنهادی به طور قابل توجهی عملکرد طبقه بندی را بهبود بخشدند و بر اهمیت نوآوری در تجزیه و تحلیل تصویربرداری عصبی تأکید می‌کنند. تحقیقات آینده باید بر اساس این یافته‌ها با ترکیب داده‌های چندوجهی، گسترش مجموعه داده‌ها و استفاده از فناوری‌های تصویربرداری عصبی پیشرفته برای افزایش بیشتر درک و تشخیص MCI باشد.

فصل ٦: مراجع

مراجع

- [١] Mammone N, Ieracitano C, Adeli H, Bramanti A, Morabito FC . "Permutation Jaccard Distance-Based Hierarchical Clustering to Estimate EEG Network Density Modifications in MCI Subjects. IEEE Trans Neural Netw Learn Syst. 2018 Feb 5. doi: 10.1109/TNNLS.2018.2791644. Epub ahead of print. PMID: 29994428 .".
- [٢] M. -K. Kang and K. -S. Hong . "Application of Deep Learning Techniques to Diagnose Mild Cognitive Impairment: Functional Near-Infrared Spectroscopy Study," 2021 21st International Conference on Control, Automation and Systems (ICCAS), Jeju, Korea, Republic of, 2021, pp. 2036-2042 ."
- [٣] Knopman DS, Petersen RC. . "Mild cognitive impairment and mild dementia: a clinical perspective. Mayo Clin Proc. 2014;89(10):1452-1459 .".
- [٤] W. N. X. Y. Y. W. Zhibin Liu . "Effects of combined acupuncture and eugenol on learning-memory ability and antioxidation system of hippocampus in Alzheimer disease rats via olfactory system stimulation ,Journal of Traditional Chinese Medicine ,Volume 33, Issue 3 ."٢٠١٣ ،
- [٥] ٢٠٢٠ Alzheimer's disease facts and figures. Alzheimers Dement. . "2020 Mar 10. doi: 10.1002/alz.12068. Epub ahead of print. PMID: 32157811 .".
- [٦] Snowden MB, Steinman LE, Bryant LL, et al. . "Dementia and co-occurring chronic conditions: a systematic literature review to identify what is known and where are the gaps in the evidence? Int J Geriatr Psychiatry. 2017;32(4):357-371 .".
- [٧] Yiannopoulou, K. G & ,Papageorgiou, S. G. . "(2012). Current and future treatments for Alzheimer's disease. Therapeutic Advances in Neurological Disorders, 6(1), 19-33. <https://doi.org/10.1177/1756285612461679> ."
- [٨] Taylor, C. A., Greenlund, S. F., McGuire, L. C., Lu, H., and Croft, J. B. (2017). . "Taylor, C. A., Greenlund, S. F., McGuire, L. C., Lu, H., and Croft, J. B. (2017) ."(
- [٩] Hebert, L. E., Weuve, J., Scherr, P. A., and Evans, D. A. (2013). . "Alzheimer disease in the United States (2010-2050) estimated using the 2010 census. Neurology 80, 1778–1783. doi: 10.1212/WNL.0b013e31828726f5 ."
- [١٠] Alzheimer Association (2019). . "Alzheimer's disease facts and figures report. Alzheimers Dement. 15, 321–387. doi: 10.1016/j.jalz.2019.01.010 ."
- [١١] Gordon, B. A., Blazey, T. M., Su, Y., Hari-Raj, A., Dincer, A., Flores, S., et al. (2018). . Spatial patterns of neuroimaging biomarker change in individuals from families with autosomal dominant alzheimer's disease: a longitudinal study. Lancet Neurol. 17, 241–250. doi: 10.1016/S1474-4422(18)3 0028-0 ."
- [١٢] Patterson, C. (2018) . "World Alzheimer Report 2018-The State of the Art of Dementia Research: New Frontiers. Alzheimer's Disease International, 1-48. <https://www.alz.co.uk/news/world-alzheimer-report-2018-state-of-art-of-dementia-research-new-frontiers> ."
- [١٣] Reid LM, MacLullich AM. . " Subjective memory complaints and cognitive impairment in older people. Dement Geriatr Cogn Disord. 2006;22(5-6):471-85. doi: 10.1159/000096295. Epub 2006 Oct 16. PMID: 17047326 .".

- [¹⁴] Yiannopoulou, K.-G., and Papageorgiou, S. G. (2013). " Current and future treatments for alzheimer's disease. Ther. Adv. Neurol. Disord. 6, 19–33. doi: 10.1177/1756285612461679 ."
- [¹⁵] Yeung MK, Sze SL, Woo J, Kwok T, Shum DH, Yu R, Chan AS. "Altered Frontal Lateralization Underlies the Category Fluency Deficits in Older Adults with Mild Cognitive Impairment: A Near-Infrared Spectroscopy Study. Front Aging Neurosci. 2016 Mar 29;8:59. doi: 10.3389/fnagi.2016.00059 .".
- [¹⁶] Litvan, I., Goldman, J.G., Tröster, A.I., Schmand, B.A., Weintraub, D., Petersen, R.C., Mollenhauer, B., Adler, C.H., Marder, K., Williams-Gray, C.H., et al., 2012. "Diagnostic criteria for mild cognitive impairment in Parkinson's disease: Movement Disorder Society Task Force Guidelines. Mov. Disord. 27 (3), 349–356 .".
- [¹⁷] Roberts R, Knopman DS "Classification and epidemiology of MCI. Clin Geriatr Med. 2013; 29(4): 753– 772. <https://doi.org/10.1016/j.cger.2013.07.003> PMID: 24094295 ."
- [¹⁸] Petersen RC, Lopez O, Armstrong MJ, et al "Practice guideline update summary: Mild cognitive impairment: Report of the Guideline Development, Dissemination, and Implementation Subcommittee of the American Academy of Neurology. Neurology. 2018; 90(3): 126–135. <https://doi.org/10.1212/WNL.000000000000> ."
- [¹⁹] Weintraub, S., Wicklund, A., Salmon, D. (2012). "The Neuropsychological Profile of Alzheimer Disease. Cold Spring Harbor Perspectives in Medicine, 2(4): a006171. <https://doi.org/10.1101/cshperspect.a006171> ."
- [²⁰] Mayo Clinic 2024 "<https://www.mayoclinic.org/diseases-conditions/mild-cognitive-impairment/symptoms-causes/syc-20354578> ."
- [²¹] J.M. Górriz, I. Álvarez-Illán, A. Álvarez-Marquina, J.E. Arco, M. Atzmueller, F. Ballarini, E. Barakova, G. Bologna, P. Bonomini, G. Castellanos-Dominguez, D. Castillo-Barnes, S.B. Cho, R. Contreras, J.M. Cuadra, E. Domínguez, F. Domínguez-Mateos, R.J. Du "Computational approaches to Explainable Artificial Intelligence: Advances in theory, applications and trends ,Information Fusion , Volume 100 , 10.1940 , 2023 , ISSN 1566-2535 , <https://doi.org/10.1016/j.inffus.2023.101945> .".
- [²²] Suk HI, Lee SW, Shen D "Alzheimer's Disease Neuroimaging Initiative. Deep ensemble learning of sparse regression models for brain disease diagnosis. Med Image Anal. 2017 Apr;37:101-113. doi: 10.1016/j.media.2017.01.008. Epub 2017 Jan 24. PMID: 28167394; PMCID: PMC5808465 .".
- [²³] Winblad B, Palmer K, Kivipelto M, Jelic V, Fratiglioni L, Wahlund LO, et al "Mild cognitive impairment--beyond controversies, towards a consensus: report of the International Working Group on Mild Cognitive Impairment. J Intern Med. 2004;256(3):240–6 .".
- [²⁴] Gong LL, Tao FY. "The effect of biopsychosocial holistic care models on the cognitive function and quality of life of elderly patients with mild cognitive impairment: a randomized trial. Ann Palliat Med. 2021 May;10(5):5600-5609. doi: 10.21037/apm-21-966. PMID: 34107724 .".
- [²⁵] Surianarayanan, C., Lawrence, J. J., Chelliah, P. R., Prakash, E & ,Hewage, C. (2022). "Convergence of Artificial Intelligence and Neuroscience towards the Diagnosis of Neurological Disorders—A Scoping Review. Sensors, 23(6), 3062. <https://doi.org/10.3390/s23063062> ."

- [۲۶] Ravi, D., Wong, C., Deligianni, F., Berthelot, M., Andreu-Perez, J., Lo, B., et al. (2017) ‘Deep learning for health informatics. IEEE J. Biomed. Heal. Informatics 21, 4–21. doi: 10.1109/JBHI.2016.2636665 .”
- [۲۷] Mamoshina, P., Vieira, A., Putin, E., and Zhavoronkov, A. ‘(2016). Applications of deep learning in biomedicine. Mol. Pharm. 13, 1445–1454. doi: 10.1021/acs.molpharmaceut.5b00982 .”
- [۲۸] Tanveer, M. A., Khan, M. J., Qureshi, M. J., Naseer, N., and Hong, K.-S. (2019). ‘ “Enhanced drowsiness detection using deep learning: an fNIRS Study. IEEE Access 7, 137920–137929. doi: 10.1109/ACCESS.2019.2942838 .”
- [۲۹] Shen, D., Wu, G & ,Suk, H. ‘ Deep Learning in Medical Image Analysis. Annual Review of Biomedical Engineering. 19, 221–248 (2017).”.
- [۳۰] Z. Wu, S. Pan, F. Chen, G. Long, C. Zhang and P. S. Yu ‘ ”A Comprehensive Survey on Graph Neural Networks,” in IEEE Transactions on Neural Networks and Learning Systems, vol. 32, no. 1, pp. 4-24, Jan. 2021, doi: 10.1109/TNNLS.2020.2978386 .”.
- [۳۱] Harris, J. L., Kiran, S., Marquardt, T. P & ,Fleming, V. B. (2008). ‘ “Communication Wellness Check-Up ©: Age-related changes in communicative abilities. Aphasiology, 22(7–8), 813–825.
<https://doi.org/10.1080/02687030701818034> .”
- [۳۲] Fleming, V. B & ,Harris, J. L. (2008a). ‘ “Complex discourse production in mild cognitive impairment: Detecting subtle changes. Aphasiology, 22(7–8), 729–740.
<https://doi.org/10.1080/02687030701803762> .”
- [۳۳] Sanford, A. M. (2017) ‘ “Mild Cognitive Impairment. Clinics in Geriatric Medicine, 33(3), 325337. <https://doi.org/10.1016/j.cger.2017.02.005> .”
- [۳۴] Sabbagh MN, Boada M, Borson S, Chilukuri M, Dubois B, Ingram J, Iwata A, Porsteinsson AP, Possin KL, Rabinovici GD, Vellas B, Chao S, Vergallo A, Hampel H ‘Early Detection of Mild Cognitive Impairment (MCI) in Primary Care. J Prev Alzheimers Dis. 2020;7(3):165-170. doi: 10.14283/jpad.2020.21. PMID: 32463069 .”.
- [۳۵] Petersen RC, Roberts RO, Knopman DS, et al. ‘ “Mild Cognitive Impairment: Ten Years Later. Arch Neurol. 2009;66(12):1447–1455.
doi:10.1001/archneurol.2009.266 .”
- [۳۶] Albert MS, DeKosky ST, Dickson D, Dubois B, Feldman HH, Fox NC, Gamst A, Holtzman DM, Jagust WJ, Petersen RC, Snyder PJ, Carrillo MC, Thies B, Phelps CH ‘The diagnosis of mild cognitive impairment due to Alzheimer’s disease: recommendations from the National Institute on Aging-Alzheimer’s Association workgroups on diagnostic guidelines for Alzheimer’s disease. Alzheimers Dement. 2011 May;7(3):270-9. doi: 1 .”
- [۳۷] Nasreddine ZS, Phillips NA, Bédirian V, Charbonneau S, Whitehead V, Collin I, Cummings JL, Chertkow H. ‘The Montreal Cognitive Assessment, MoCA: a brief screening tool for mild cognitive impairment. J Am Geriatr Soc. 2005 Apr;53(4):695-9. doi: 10.1111/j.1532-5415.2005.53221.x. Erratum in: J Am Geriatr Soc. 2019 Sep;67(9):1991. doi: 10.1111/jgs.15925. PMID .”:
- [۳۸] Dubois B, Feldman HH, Jacova C, Hampel H, Molinuevo JL, Blennow K, DeKosky ST, Gauthier S, Selkoe D, Bateman R, Cappa S, Crutch S, Engelborghs S, Frisoni GB, Fox NC, Galasko D, Habert MO, Jicha GA, Nordberg A, Pasquier F, Rabinovici G, Robert P, Rowe C, S ‘Advancing research diagnostic criteria for

Alzheimer's disease: the IWG-2 criteria. *Lancet Neurol.* 2014 Jun;13(6):614-29. doi: 10.1016/S1474-4422(14)70090-0. Erratum in: *Lancet Neurol.* 2014 Aug;13(8):757. PMID: 24849862 .".

- [^{¶¶}] Petersen RC, Lopez O, Armstrong MJ, Getchius TSD, Ganguli M, Gloss D, Gronseth GS, Marson D, Pringsheim T, Day GS, Sager M, Stevens J, Rae-Grant A . "Practice guideline update summary: Mild cognitive impairment: Report of the Guideline Development, Dissemination, and Implementation Subcommittee of the American Academy of Neurology. *Neurology.* 2018 Jan 16;90(3):126-135. doi: 10.1212/WNL.0000000000004826 ."
- [^{¶·}] Gauthier S, Reisberg B, Zaudig M, Petersen RC, Ritchie K, Broich K, Belleville S, Brodaty H, Bennett D, Chertkow H, Cummings JL, de Leon M, Feldman H, Ganguli M, Hampel H, Scheltens P, Tierney MC, Whitehouse P, Winblad B; " International Psychogeriatric Association Expert Conference on mild cognitive impairment. *Mild cognitive impairment. Lancet.* 2006 Apr 15;367(9518):1262-70. doi: 10.1016/S0140-6736(06)68542-5. PMID: 16631882 .".
- [^{¶¶}] Jack CR Jr, Bennett DA, Blennow K, Carrillo MC, Dunn B, Haeberlein SB, Holtzman DM, Jagust W, Jessen F, Karlawish J, Liu E, Molinuevo JL, Montine T, Phelps C, Rankin KP, Rowe CC, Scheltens P, Siemers E, Snyder HM, Sperling R; Contributors. "NIA-AA Research Framework: Toward a biological definition of Alzheimer's disease. *Alzheimers Dement.* 2018 Apr;14(4):535-562. doi: 10.1016/j.jalz.2018.02.018. PMID: 29653606; PMCID: PMC5958625 .".
- [^{¶¶}] Anderson ND. "State of the science on mild cognitive impairment (MCI). *CNS Spectrums.* 2019;24(1):78-87. doi:10.1017/S1092852918001347 ."
- [^{¶¶}] Bennett DA, Schneider JA, Bienias JL, Evans DA, Wilson RS. " Mild cognitive impairment is related to Alzheimer disease pathology and cerebral infarctions. *Neurology* 2005;64:834–841 .".
- [^{¶¶}] Di Carlo A, Lamassa M, Baldereschi M, et al. ". CIND and MCI in the Italian elderly: frequency, vascular risk factors, progression to dementia. *Neurology* 2007;68:1909–1916 ."
- [^{¶¶}] Stern Y. "Cognitive reserve in aging and Alzheimer's disease. *Lancet Neurol.* 2012; 11(11): 1006–1012 .".
- [^{¶¶}] Ströhle A, Schmidt DK, Schultz F, et al "Drug and exercise treatment of Alzheimer disease and mild cognitive impairment: a systematic review and meta-analysis of effects on cognition in randomized controlled trials. *Am J Geriatr Psychiatry.* 2015; 23 (12): 1234–1249 .".
- [^{¶¶}] Baker LD, Frank LL, Foster-Schubert K, et al. "Effects of aerobic exercise on mild cognitive impairment: a controlled trial. *Arch Neurol.* 2010; 67(1): 71–79 .".
- [^{¶¶}] Singh B, Parsaik AK, Mielke MM, et al "Association of Mediterranean diet with mild cognitive impairment and Alzheimer's disease: a systematic review and meta-analysis .".
- [^{¶¶}] Singh B, Parsaik AK, Mielke MM, et al " Association of Mediterranean diet with mild cognitive impairment and Alzheimer's disease: a systematic review and meta-analysis. *J Alzheimers Dis.* 2014; 39(2): 271–282 .".
- [^{¶·}] Bayer-Carter JL, Green PS, Montine TJ, et al. "Diet interventions and cerebrospinal fluid markers in amnestic mild cognitive impairment. *Arch Neurol.* 2011; 68(6): 743–752 .".

- [◦◦] Belleville S, Hudon C, Bier N, et al. MEMO + " Efficacy, durability, and effect of cognitive training and psychosocial intervention in individuals with mild cognitive impairment. *J Am Geriatr Soc.* 2018; 66(4): 655–663 .".
- [◦◦] Belleville S, Gilbert B, Fontaine F, Gagnon L, Ménard E, Gauthier S ‘ “Improvement of episodic memory in persons with mild cognitive impairment and healthy older adults: evidence from a cognitive intervention program. *Dement Geriatr Cogn Disord.* 2006; 22(5–6): 486–489 .".
- [◦◦] Jeong JH, Na HR, Choi SH, et al. ‘ “Group- and home-based cognitive interventions for patients with mild cognitive impairment: a randomized controlled trial. *Psychother Psychosom.* 2016; 85(4): 198–207 .".
- [◦◦] Schmitter-Edgecombe M, Dyck DG ‘ “Cognitive rehabilitation multi- family group intervention for individuals with mild cognitive impairment and their care-partners. *J Int Neuropsychol Soc.* 2014; 20(9): 897–908 .".
- [◦◦] Hoshi, Y & .M. Tamura. 1993. ‘ “Dynamic multichannel near- infrared optical imaging of human brain activity. *J. Appl. Physiol.* 75: 1842–1846 .".
- [◦◦] Plichta, M.M., M.J. Herrmann, C.G. Baehne, et al ‘ “2006. Event-related functional near-infrared spectroscopy (fNIRS): are the measurements reliable? *Neuroimage* 31: 116–124 .".
- [◦◦] Lloyd-Fox, S., A. Blasi & C.E. Elwell. 2010. ‘ “ Illuminating the developing brain: the past, present and future of func- tional near infrared spectroscopy. *Neurosci. Biobehav. Rev.* 34: 269–284 .".
- [◦◦] Obrig, H. 2014. ‘ “NIRS in clinical neurology—a “promising” tool? *Neuroimage* 85: 535–546 .".
- [◦◦] Yuçel, M.A., J.J. Selb, T.J. Huppert, et al. 2017 ‘ “Functional near infrared spectroscopy: enabling routine functional brain imaging. *Curr. Opin. Biomed. Eng.* 4: 78–86 .".
- [◦◦] Scholkmann, F., S. Kleiser, A.J. Metz, et al. 2014 ‘ “A review on continuous wave functional near-infrared spectroscopy and imaging instrumentation and methodology instru- mentation and methodology. *Neuroimage* 85: 6–27 .".
- [◦◦] Pinti P, Tachtsidis I, Hamilton A, Hirsch J, Aichelburg C, Gilbert S, Burgess PW ‘ “The present and future use of functional near-infrared spectroscopy (fNIRS) for cognitive neuroscience. *Ann N Y Acad Sci.* 2020 Mar;1464(1):5-29. doi: 10.1111/nyas.13948. Epub 2018 Aug 7. PMID: 30085354; PMCID: PMC6367070 .".
- [◦◦] Scholkmann, F., S. Kleiser, A.J. Metz, et al. 2014. ‘ “ A review on continuous wave functional near-infrared spectroscopy and imaging instrumentation and methodology instru- mentation and methodology. *Neuroimage* 85: 6–27 .".
- [◦◦] Ferrari M, Quaresima V. ‘ “A brief review on the history of human functional near-infrared spectroscopy (fNIRS) development and fields of application. *Neuroimage.* 2012 Nov 1;63(2):921-35. doi: 10.1016/j.neuroimage .".
- [◦◦] Tachtsidis, I & .F. Scholkmann. 2016. ‘ “False positives and false negatives in functional near-infrared spectroscopy: issues, challenges, and the way forward. *Neurophotonics* 3: 31405 .".
- [◦◦] Herold, F., P. Wiegel, F. Scholkmann, et al. 2017. ‘ “Functional near-infrared spectroscopy in movement science: a system- atic review on cortical activity in postural and walking tasks. *Neurophotonics* 4: 41403 .".
- [◦◦] “<https://www.artinis.com/theory-of-nirs> ."

- [۷۷] Roche-Labarbe, N., F. Wallois, E. Ponchel, et al. 2007. "Coupled oxygenation oscillation measured by NIRS and intermittent cerebral activation on EEG in premature infants. *Neuroimage* 36: 718–727 .".
- [۷۸] Herrmann, M.J., J.B.M. Langer, C. Jacob, et al. '2008. Reduced prefrontal oxygenation in Alzheimer's disease during verbal fluency tasks. *Am. J. Geriatr. Psychiatry* 16: 125–135 .".
- [۷۹] Balakrishnan, B., Dasgupta, M., Gajewski, K. et al. "Low near infrared spectroscopic somatic oxygen saturation at admission is associated with need for lifesaving interventions among unplanned admissions to the pediatric intensive care unit. *J Clin Monit Comput* 32, 89–96 (2018). <https://doi.org/10.1007/s108> ."
- [۷۰] Hoffman, G. M., Ghanayem, N. S., Scott, J. P., Tweddell, J. S., Mitchell, M. E., and Mussatto, K. A. (2017) "Postoperative cerebral and somatic near-infrared spectroscopy saturations and outcome in hypoplastic left heart syndrome. *Ann. Thorac. Surg.* 103, 1527–1535. doi: 10.1016/j.athoracsur.2016.09.100 ."
- [۷۱] Hong, K. S., and Yaqub, M. A. (2019). "Application of functional near-infrared spectroscopy in the healthcare industry: a review. *J. Innov. Opt. Health Sci.* 12:1930012. Hoshi, Y., Kobay ."
- [۷۲] Cutini, S., Moro, S. B & , Bisconti, S. (2012). "Functional near Infrared Optical Imaging in Cognitive Neuroscience: An Introductory Review. *Journal of Near Infrared Spectroscopy*. <https://doi.org/10.1255/jnirs.969> ."
- [۷۳] Scholkmann F, Kleiser S, Metz AJ, Zimmermann R, Mata Pavia J, Wolf U, Wolf M. "A review on continuous wave functional near-infrared spectroscopy and imaging instrumentation and methodology. *Neuroimage*. 2014 Jan 15;85 Pt 1:6-27. doi: 10.1016/j.neuroimage.2013.05.004. Epub 2013 May 16. PMID: 23684868 .".
- [۷۴] Zhang, Y & , Zhu, C. (2020). "Assessing Brain Networks by Resting-State Dynamic Functional Connectivity: An fNIRS-EEG Study. *Frontiers in Neuroscience*, 13, 497285. <https://doi.org/10.3389/fnins.2019.01430> ."
- [۷۵] Binder, J. R. (2011) "Functional MRI is a valid noninvasive alternative to Wada testing. *Epilepsy Behav.* 20, 214–222. doi: 10.1016/j.yebeh.2010.08.004 ."
- [۷۶] Gallagher, A., Theriault, M., Maclin, E., Low, K., Gratton, G., Fabiani, M., et al. '(2007). Near-infrared spectroscopy as an alternative to the Wada test for language mapping in children, adults and special populations. *Epileptic Disord.* 9, 241–255. doi: 10.1684/epd.2007.0118 ."
- [۷۷] Watanabe, E., Maki, A., Kawaguchi, F., Takashiro, K., Yamashita, Y., Koizumi, H., et al. (1998). "Non-invasive assessment of language dominance with near-infrared spectroscopic mapping. *Neurosci. Lett.* 256, 49–52 .".
- [۷۸] Wroblewski, G. J., Matsuo, K., Hirata, K., Matsubara, T., Harada, K., Watanabe, Y., et al. (2017) "Effects of task language and second-language proficiency on the neural correlates of phonemic fluency in native Japanese speakers: a functional near-infrared spectroscopy study. *Neuroreport* 28, 884–889. doi: 10.1097/WNR.000000000000852 ."
- [۷۹] Chen, W., Wagner, J., Heugel, N., Sugar, J., Lee, Y., Conant, L., Malloy, M., Heffernan, J., Quirk, B., Zinos, A., Beardsley, S. A., Prost, R & , Whelan, H. T. (2020) "Functional Near-Infrared Spectroscopy and Its Clinical Application in the Field of Neuroscience: Advances and Future Directions. *Frontiers in Neuroscience*, 14, 540710. <https://doi.org/10.3389/fnins.2020.00724> ."

- [⁸] Budohoski KP, Czosnyka M, Smielewski P, Kasprowicz M, Helmy A, Bulters D, Pickard JD, Kirkpatrick PJ. ‘Impairment of cerebral autoregulation predicts delayed cerebral ischemia after subarachnoid hemorrhage: a prospective observational study. *Stroke*. 2012 Dec;43(12):3230-7. doi: 10.1161/STROKEAHA.112.669788. Epub 2012 Nov 13. PMID: 23150652 .”
- [⁸¹] Andersen, A. V., Simonsen, S. A., Schytz, H. W., and Iversen, H. K. (2018). ‘ “Assessing low-frequency oscillations in cerebrovascular diseases and related conditions with near-infrared spectroscopy: a plausible method for evaluating cerebral autoregulation? *Neurophotonics* 5:030901. doi: 10.1117/1.NPh.5.3.030901 .”
- [⁸²] Ayers, M. D., and Lawrence, D. K. (2015). ‘Near-infrared spectroscopy to assess cerebral perfusion during head-up tilt-table test in patients with syncope. *Congenit. Heart Dis.* 10, 333–339. doi: 10.1111/chd.12236 .”
- [⁸³] Kadamtai, P., Sugar, J. J., Quirk, B. J., Mehrvar, S., Chelimsky, G. G., Whelan, H. T., et al. (2018). ‘Near-infrared spectroscopy muscle oximetry of patients with postural orthostatic tachycardia syndrome. *J. Innov. Opt. Health Sci.* 11:1850026. doi: 10.1142/S1793545818500268 .”
- [⁸⁴] Lankford, J., Numan, M., Hashmi, S. S., Gourishankar, A., and Butler, I. J. (2015). ‘ “Cerebral blood flow during HUTT in young patients with orthostatic intolerance. *Clin. Auton. Res.* 25, 277–284. doi: 10.1007/s10286-015-0295-9 .”
- [⁸⁵] Goadsby, P. J., Holland, P. R., Martins-Oliveira, M., Hoffmann, J., Schankin, C., and Akerman, S. (2017). ‘Pathophysiology of migraine: a disorder of sensory processing. *Physiol. Rev.* 97, 553–622. doi: 10.1152/physrev.00034.2015 .”
- [⁸⁶] Shinoura, N., and Yamada, R. (2005). ‘Decreased vasoreactivity to right cerebral hemisphere pressure in migraine without aura: a near-infrared spectroscopy study. *Clin. Neurophysiol.* 116, 1280–1285. doi: 10.1016/j.clinph.2005.01.016 .”
- [⁸⁷] Viola, S., Viola, P., Litterio, P., Buongarzone, M. P., and Fiorelli, L. (2010). ‘ “Pathophysiology of migraine attack with prolonged aura revealed by transcranial Doppler and near infrared spectroscopy. *Neurol. Sci.* 31(Suppl. 1), S165–S166. doi: 10.1007/s10072-010-0318-1 .”
- [⁸⁸] Pourshoghi, A., Danesh, A., Tabby, D. S., Grothusen, J., and Pourrezaei, K. (2015). ‘Cerebral reactivity in migraine patients measured with functional near-infrared spectroscopy. *Eur. J. Med. Res.* 20:96. doi: 10.1186/s40001-015-0190-9 .”
- [⁸⁹] Pinti P, Tachtsidis I, Hamilton A, Hirsch J, Aichelburg C, Gilbert S, Burgess PW ‘ “The present and future use of functional near-infrared spectroscopy (fNIRS) for cognitive neuroscience. *Ann N Y Acad Sci* 1464: 5–29, 2020. doi:10.1111/nyas.13948 .”
- [⁹⁰] Notte C, Alionte C, Strubakos CD. ‘ “The efficacy and methodology of using near-infrared spectroscopy to determine resting-state brain networks. *J Neurophysiol.* 2024 Apr 1;131(4):668-677. doi: 10.1152/jn.00357.2023. Epub 2024 Feb 28. PMID: 38416714 .”
- [⁹¹] Jessen, F., Wiese, B., Bachmann, C., Eifflaender-Gorfer, S., Haller, F., Kolsch, H., et al. (2010). ‘Prediction of dementia by subjective memory impairment: effects of severity and temporal association with cognitive impairment. *Arch. Gen. Psychiatry* 67, 414–422. doi: 10.1001/archgenpsychiatry.2010.30 .”
- [⁹²] Meilan, J. J. G., Martinez-Sanchez, F., Martinez-Nicolas, I., Llorente, T. E., and Carro, J. (2020) ‘Changes in the rhythm of speech difference between people with

nondegenerative mild cognitive impairment and with preclinical dementia. Behav. Neurol. 2020:4683573. doi: 10.1155/2020/4683573 ."

- [¹³] Mueller, K. D., Hermann, B., Mecollari, J., and Turkstra, L. S. (2018). "Connected speech and language in mild cognitive impairment and Alzheimer's disease: a review of picture description tasks. J. Clin. Exp. Neuropsychol. 40, 917–939. doi: 10.1080/13803395.2018.1446513 ."
- [¹⁴] Hong, K. S., and Yaqub, M. A. (2019). "Application of functional near-infrared spectroscopy in the healthcare industry: a review. J. Innov. Opt. Health Sci. 12:1930012 .".
- [¹⁵] Vermeij, A., Kessels, R. P. C., Heskamp, L., Simons, E. M. F., Dautzenberg, P. L. J., and Claassen, J. (2017). "Prefrontal activation may predict working-memory training gain in normal aging and mild cognitive impairment. Brain Imaging Behav. 11, 141–154. doi: 10.1007/s11682-016-9508-7 ."
- [¹⁶] Yeung, M. K., Sze, S. L., Woo, J., Kwok, T., Shum, D. H., Yu, R., et al. (2016). "Yeung, M. K., Sze, S. L., Woo, J., Kwok, T., Shum, D. H., Yu, R., et al. (2016 .)".
- [¹⁷] Uemura, K., Shimada, H., Doi, T., Makizako, H., Tsutsumimoto, K., Park, H., et al. (2016). "Uemura, K., Shimada, H., Doi, T., Makizako, H., Tsutsumimoto, K., Park, H., et al. (2016 .)".
- [¹⁸] Nguyen, T., Kim, M., Gwak, J., Lee, J. J., Choi, K. Y., Lee, K. H., et al. (2019). "Investigation of brain functional connectivity in patients with mild cognitive impairment: a functional near-infrared spectroscopy (fNIRS) study. J. Biophotonics 12:e201800298. doi: 10.1002/jbio.201800298 ."
- [¹⁹] Yang D, Hong KS. "Quantitative Assessment of Resting-State for Mild Cognitive Impairment Detection: A Functional Near-Infrared Spectroscopy and Deep Learning Approach. J Alzheimers Dis. 2021;80(2):647-663. doi: 10.3233/JAD-201163. PMID: 33579839 .".
- [²⁰] Li, R., Rui, G., Chen, W., Li, S., Schulz, P & , Yingchung, Z. (2018). "Early Detection of Alzheimer's Disease Using Non-Invasive Near-Infrared Spectroscopy. Frontiers in Aging Neuroscience, 10(366). <https://doi:10.3389/fnagi.2018.00366> .".
- [²¹] Li, R., Rui, G., Chen, W., Li, S., Schulz, P & , Yingchung, Z. (2018) "Early Detection of Alzheimer's Disease Using Non-Invasive Near-Infrared Spectroscopy. Frontiers in Aging Neuroscience, 10(366). <https://doi:10.3389/fnagi.2018.00366> .".
- [²²] Deziel, Julia K., ""An fNIRS Investigation of the Prefrontal Cortical Processing Demands Associated with a Communication Based Assessment for Mild Cognitive Impairment" (2020). UVMHonorsCollegeSenior Theses. 340 .".
- [²³] Chen, W., Wagner, J., Heugel, N., Sugar, J., Lee, Y., Conant, L., Malloy, M., Heffernan, J., Quirk, B., Zinos, A., Beardsley, S. A., Prost, R & , Whelan, H. T. (2020) " Functional Near-Infrared Spectroscopy and Its Clinical Application in the Field of Neuroscience: Advances and Future Directions. Frontiers in Neuroscience, 14, 540710. <https://doi.org/10.3389/fnins.2020.00724> ."
- [²⁴] Y. He, L. Wang, Y.F. Zang, L.X. Tian, X.Q. Zhang, K.C. Li, T.Z. Jiang "iang, Regional coherence changes in the early stages of Alzheimer's disease: a combined structural and resting-state functional MRI study, Neuroimage 35 (2007) 488–500 .".
- [²⁵] Van Dijk KR, Hedden T, Venkataraman A, Evans KC, Lazar SW, Buckner RL. " Intrinsic functional connectivity as a tool for human connectomics: theory, properties, and optimization. J Neurophysiol. 2010 Jan;103(1):297-321. doi:

- 10.1152/jn.00783.2009. Epub 2009 Nov 4. PMID: 19889849; PMCID: PMC2807224 .".
- [¹·⁷] Ferreira LK, Busatto GF. 2013. "Resting-state functional connectivity in normal brain aging. *Neuroscience and Biobehavioral Reviews* 37(3):384–400 DOI 10.1016/j.neubiorev.2013.01.017 .".
- [¹·⁸] Esposito R, Mosca A, Pieramico V, Cieri F, Cera N, Sensi SL. 2013. ' "Characterization of resting state activity in MCI individuals. *PeerJ* 1:e135 <https://doi.org/10.7717/peerj.135> ."
- [¹·⁹] Niu H, He Y. ' "Resting-state functional brain connectivity: lessons from functional near-infrared spectroscopy. *Neuroscientist*. 2014 Apr;20(2):173–88. doi: 10.1177/1073858413502707. Epub 2013 Sep 10. PMID: 24022325 .".
- [¹·¹] <https://memgraph.com/blog/introduction-to-node-embedding> .
- [¹·²] Kipf, T. N & „Welling, M. (2016). ' " Semi-Supervised Classification with Graph Convolutional Networks. *ArXiv*. /abs/1609.02907 ."
- [¹·³] Ying, R., He, R., Chen, K., Eksombatchai, P., Hamilton, W. L & „Leskovec, J. (2018). ' " Graph Convolutional Neural Networks for Web-Scale Recommender Systems. *ArXiv*. <https://doi.org/10.1145/3219819.3219890> ."
- [¹·⁴] Ioannis Konstas, Vassilios Stathopoulos, and Joemon M. Jose. ' "On social networks and collaborative recommendation. In Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval, SIGIR '09, page 195–202, New York, NY, USA, 2009. Association for Computing Machinery .".
- [¹·⁵] Caleb C. Noble and Diane J. Cook. ' "Graph-based anomaly detection. In Proceedings of the Ninth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, KDD '03, page 631–636, New York, NY, USA, 2003. Association for Computing Machinery .".
- [¹·⁶] Michael Färber, Frederic Bartscherer, Carsten Menne, and Achim Rettinger. ' "Linked data quality of DBpedia, Freebase, Opencyc, Wikidata, and YAGO. *Semantic Web*, 9(1):77–129, 2018 .".
- [¹·⁷] Nikhil Goyal, Harsh Vardhan Jain, and Sayan Ranu. Graphgen: ' "A scalable approach to domainagnostic labeled graph generation. In Proceedings of The Web Conference 2020, WWW '20, page 1253–1263, New York, NY, USA, 2020. Association for Computing Machinery .".
- [¹·⁸] Ling Zhao, Yujiao Song, Chao Zhang, Yu Liu, Pu Wang, Tao Lin, Min Deng, and Haifeng Li. ' "T-gcn: A temporal graph convolutional network for traffic prediction. *IEEE Transactions on Intelligent Transportation Systems*, 21(9):3848–3858, 2020 .".
- [¹·⁹] Alex Fout, Jonathon Byrd, Basir Shariat, and Asa Ben-Hur. ' "Protein interface prediction using graph convolutional networks. In I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, editors, *Advances in Neural Information Processing Systems*, volume 30. Curran Associates, Inc .",.
- [¹·¹] Jiaxuan You, Rex Ying, and Jure Leskovec. Position-aware graph neural networks. In Kamalika Chaudhuri and Ruslan Salakhutdinov, editors, ' "Proceedings of the 36th International Conference on Machine Learning, ICML 2019, 9–15 June 2019, Long Beach, California, USA, volume 97 of *Proceedings of Machine Learning Research*, pages 7134–7143. PMLR, 2019 .".

- [۱۱۹] M. S. Kazemi, "Dynamic graph neural networks," in Graph Neural Networks: Foundations, Frontiers, and Applications, L. Wu, P. Cui, J. Pei, and L. Zhao, Eds. Singapore: Springer Singapore, 2022, pp. 323–349 ..

[۱۲۰] Xu, M., Wang, H., Ni, B., Guo, H& .amp; Tang, J.. (2021) . "Self-supervised Graph-level Representation Learning with Local and Global Structure". i<Proceedings of the 38th International Conference on Machine Learning>i ,<in> i<Proceedings of Machine Learning Research>i ."۱۱۰۰۸-۱۳۹:۱۱۰۴۸ <

[۱۲۱] Zhang, L., Wang, L., Zhu, D. (2020). . Recovering Brain Structural Connectivity from Functional Connectivity via Multi-GCN Based Generative Adversarial Network. In: Martel, A.L., et al. Medical Image Computing and Computer Assisted Intervention – MICCAI 2020. MICCAI 2020. Lecture Notes in Co ."

[۱۲۲] Wang, L., Li, K & ,Hu, X. P. (2021). . "Graph convolutional network for fMRI analysis based on connectivity neighborhood. Network Neuroscience, 5(1), 83-95. https://doi.org/10.1162/netn_a_00171 ."

[۱۲۳] Sunil G, Gowtham S, Bose A, Harish S, Srinivasa G. . "Graph neural network and machine learning analysis of functional neuroimaging for understanding schizophrenia. BMC Neurosci. 2024 Jan 2;25(1):2. doi: 10.1186/s12868-023-00841-0. PMID: 38166747; PMCID: PMC10759601 .".

[۱۲۴] Cui, H., Dai, W., Zhu, Y., Kan, X., Chen Gu, A. A., Lukemire, J., Zhan, L., He, L., Guo, Y & ,Yang, C. (2023) . "BrainGB: A Benchmark for Brain Network Analysis with Graph Neural Networks. IEEE Transactions on Medical Imaging, 42(2), 493. <https://doi.org/10.1109/TMI.2022.3218745> ."

[۱۲۵] Fan, Z., Gao, Z., Xu, L., Yu, J & ,Li, J. (2024). . "Identification of autism spectrum disorder based on functional near-infrared spectroscopy using dynamic multi-attribute spatio-temporal graph neural network. Biomedical Signal Processing and Control, 94, 106364. <https://doi.org/10.1016/j.bspc.2024.106364> ."

[۱۲۶] Han C, Jo S, Jo I, Kim E, Park M, et al. . "An adaptation of the Korean mini-mental state examination (K-MMSE) in elderly Koreans: demographic influence and population-based norms (the AGE study). Elsevier. 2008;47:302–310 .".

[۱۲۷] Fishburn, F. A., Ludlum, R. S., Vaidya, C. J., and Medvedev, A. V. (2019). . "Temporal derivative distribution repair (TDDR): a motion correction method for fNIRS. Neuroimage 184, 171–179. doi: 10.1016/j.neuroimage.2018.09.025 ."

[۱۲۸] Yang D, Hong KS . " Quantitative Assessment of Resting-State for Mild Cognitive Impairment Detection: A Functional Near-Infrared Spectroscopy and Deep Learning Approach. J Alzheimers Dis. 2021;80(2):647-663. doi: 10.3233/JAD-201163. PMID: 33579839 .".

[۱۲۹] Korhonen V, Hiltunen T, Myllylä T, Wang X, Kantola J, Nikkinen J, Zang YF, LeVan P, Kiviniemi V (2014) . "Synchronous multiscale neuroimaging environment for critically sampled physiological analysis of brain function: Hepta-scan concept. Brain Connect 4, 677-689 .".

[۱۳۰] Ian Goodfellow and Yoshua Bengio and Aaron Courville . "Deep Learning MIT Press 2016 ."

[۱۳۱] Tibshirani, Robert. . "Regression Shrinkage and Selection via the Lasso." Journal of the Royal Statistical Society. Series B (Methodological) 58, no. 1 (1996): 267–88. <http://www.jstor.org/stable/2346178> .".

[۱۳۲] Murphy, Kevin (2012). . "Machine Learning: A Probabilistic Perspective. MIT. ISBN 978-0262018029 .".

- [133] Eyler LT, Elman JA, Hatton SN, Gough S, Mischel AK, Hagler DJ, Franz CE, Docherty A, Fennema-Notestine C, Gillespie N, Gustavson D, Lyons MJ, Neale MC, Panizzon MS, Dale AM, Kremen WS . "Resting State Abnormalities of the Default Mode Network in Mild Cognitive Impairment: A Systematic Review and Meta-Analysis. *J Alzheimers Dis.* 2019;70(1):107-120. doi: 10.3233/JAD-180847. PMID: 31177210; PMCID: PMC6697380 .".
- [134] Yan T, Wang W, Yang L, Chen K, Chen R, Han Y. . "Rich club disturbances of the human connectome from subjective cognitive decline methods for Alzheimer's disease and its prodromal stages. *Neuroimage.* (2017) 155:530–48. doi: 10.1016/j.neuroimage.2017.03.057 ."
- [135] Cao Y, Yang H, Zhou Z, Cheng Z, Zhao X. . "Abnormal Default-Mode Network Homogeneity in Patients With Mild Cognitive Impairment in Chinese Communities. *Front Neurol.* 2021 Feb 11;11:569806. doi: 10.3389/fneur.2020.569806. PMID: 33643176; PMCID: PMC7905225 .".
- [136] Wyser D, Mattille M, Wolf M, Lambercy O, Scholkmann F, Gassert R. . "Short-channel regression in functional near-infrared spectroscopy is more effective when considering heterogeneous scalp hemodynamics. *Neurophotonics.* 2020 Jul;7(3):035011. doi: 10.1117/1.NPh.7.3.035011. Epub 2020 Sep 29. PMID: 33029548; PMCID: PMC752373 .".
- [137] Yeung MK, Sze SL, Woo J, Kwok T, Shum DH, Yu R, Chan AS. . "Altered Frontal Lateralization Underlies the Category Fluency Deficits in Older Adults with Mild Cognitive Impairment: A Near-Infrared Spectroscopy Study. *Front Aging Neurosci.* 2016 Mar 29;8:59. doi: 10.3389/fnagi.2016.00059 .".
- [138] Raichle ME. . "the brain's default mode network. *Annu Rev Neurosci.* 2015 Jul 8;36:433-47. doi: 10.1146/annurev-neuro-071013-014030 .".
- [139] Gallagher, A., Theriault, M., Maclin, E., Low, K., Gratton, G., Fabiani, M., et al. . "(2007). Near-infrared spectroscopy as an alternative to the Wada test for language mapping in children, adults and special populations. *Epileptic Disord.* 9, 241–255. doi: 10.1684/epd.2007.0118 .".
- [140] Viola, S., Viola, P., Litterio, P., Buongarzone, M. P., and Fiorelli, L. (2010). . "Pathophysiology of migraine attack with prolonged aura revealed by transcranial Doppler and near infrared spectroscopy. *Neurol. Sci.* 31(Suppl. 1), S165–S166. doi: 10.1007/s10072-010-0318-1 .".

Abstract

Mild Cognitive Impairment (MCI) refers to slight impairments in memory or thinking that do not significantly affect the ability to live independently or perform most daily tasks. In MCI, the individual or their close relatives notice changes in how they think or remember things. MCI often presents the early symptoms of more severe cognitive impairments or Alzheimer's disease and is associated with aging. Early diagnosis of MCI can prevent the progression to Alzheimer's disease. When working with individuals who have cognitive disorders, there are limited cognitive assessment tools available to diagnose baseline functioning, MCI, and Alzheimer's disease. Given the progressive nature of these conditions, early detection of MCI is crucial for managing the disease and choosing therapeutic strategies that could delay the progression of Alzheimer's disease. While some behavioral criteria exist, tools for assessing and diagnosing MCI and other cognitive disorders need further development and expansion. One of the tools for evaluating and diagnosing cognitive disorders is functional Near-Infrared Spectroscopy (fNIRS). This study proposes a graph-based deep learning approach. The study aims to distinguish between individuals with MCI and healthy controls by analyzing resting-state data recorded using fNIRS. Temporal Graph Neural Networks (TGNNs) were employed to understand complex temporal dependencies and structural patterns in brain data. Further research is required to examine other brain regions to gain better insights into the functional mechanisms of the brain in MCI and Alzheimer's disease, thereby identifying more useful assessment tools. Resting-state fNIRS data were collected from both MCI and healthy individuals. Resting-state data are particularly valuable as they reflect the brain's intrinsic activity without external stimuli, providing a baseline for cognitive functioning. Moreover, designed tasks for disease diagnosis can sometimes be challenging and uncomfortable for patients. Resting-state recordings can reveal subtle differences in connectivity and activation patterns that might not be evident in task-based assessments. Temporal graphs were constructed from the recorded fNIRS data to model dynamic interactions and connectivity patterns among different brain regions over time. The proposed graph network classified participants based on these temporal graphs. The results show that temporal graph networks effectively distinguish between individuals with MCI and healthy controls, highlighting distinct activation and connectivity patterns in different brain regions. The use of cross-validation methods such as 5-fold stratified cross validation confirms the generalizability of the model. The results demonstrate the effectiveness of the proposed approach, with the best performance achieved by the GconvGRU model, which achieved an accuracy of 92.67%, precision of 95.00%, F1 score of 93.14%, and recall of 93.33%. These findings establish a precise, non-invasive, AI-based criterion for diagnosing MCI, which outperforms similar models and previous approaches to some extent. This study highlights the potential of graph-based temporal analysis of resting-state fNIRS data in distinguishing between individuals with MCI and healthy individuals, aiding in early diagnosis and monitoring of MCI patients.

Keywords:

Mild Cognitive Impairment, MCI, functional Near-Infrared Spectroscopy, fNIRS, machine learning models, Temporal Graph Neural Networks, TGNN,



Kharazmi University

Faculty of Engineering

A Thesis Submitted in Partial Fulfillment for the Degree of M.Sc. in Data Mining

Diagnosis of Mild Cognitive Impairment (MCI) using Graph Neural Networks Based on Functional Near-Infrared Spectroscopy (fNIRS) Data

By

Mohommadsadegh Fathi Ozanbolagh

Supervisor

Dr. Mir Mohsen Pedram

Advisor

Dr. Maryam Tayefeh Mahmoodi

September 2024

